

RACER-GT 數學附錄

推導、證明與估計器實作細節

Yi-Hao Lai

大葉大學財務金融學系

2026-07-28 • 版本 1.5.0

摘要

本附錄收錄方法論主文中未完整展開的推導，並逐項說明軟體實際實作的估計器。撰寫原則是「可被查核」：每個結果都對應到計算它的模組與函式，讀者可以自行驗證程式與數學是否一致。實作與教科書估計器有三處刻意的差異，本文明確標示並說明理由，而不是留給讀者自己發現。

目錄

1	符號	3
2	穩健 edge 估計	3
2.1	估計式	3
2.2	Edge 估計的變異數	3
3	圖形加權最小平方	4
3.1	Normal equations	4
3.2	由殘差得到的診斷	4
3.3	對數常態偏誤修正	5
4	變異成分	6
4.1	期望均方	6
4.2	Generalizability 與 dependability 係數	6

5	受限下的 consensus 權重	7
5.1	Shrinkage 共變異數	7
5.2	殘差共變異數的分辨力上界	7
5.3	有效 pull 數	8
5.4	每日標準誤	8
6	頻率 benchmark	9
6.1	解	9
6.2	Exact 模式	10
7	測量誤差修正	10
7.1	動差修正	10
7.2	SIMEX	10
8	數學與程式的對應	11

1 符號

表 1: 全文符號對照。

符號	值域	意義
t	$1, \dots, T$	歷史日曆日期
i	$1, \dots, N$	complete pull (一次完整歷史重建)
j, k	$1, \dots, J$	chunk (固定查詢視窗)
d, s, r	—	collection day 、 stream 、 technical replicate
Y_{jt}	$[0, 100]$	原始 GT 值，日期 t 、 chunk j
a_j, ℓ_j	$\mathbb{R}_{>0}, \mathbb{R}$	chunk 尺度與其對數， $\ell_j = \log a_j$
X_t	$\mathbb{R}_{>0}$	共同尺度下的潛在訊號
Z_{it}	$\mathbb{R}$	pull i 在日期 t 的校準值
Σ	$\mathbb{R}^{N \times N}$	跨 pull 殘差共變異數
$\mathbf{w}$	Δ^{N-1}	consensus 權重， $\mathbf{1}^\top \mathbf{w} = 1$
$c_{\min}$	$\mathbb{R}_{>0}$	進入 overlap edge 的最小原始值
$m_{\min}$	$\mathbb{N}$	edge 所需最少可用重疊日數

2 穩健 edge 估計

2.1 估計式

對 **edge** (j, k) ，令 $r_1, \dots, r_n$ 為可用重疊日上的 **log ratio** $\log Y_{jt} - \log Y_{kt}$ 。Huber location 估計解

$$\sum_{i=1}^n \psi_c \left(\frac{r_i - \hat{\mu}}{\hat{\sigma}} \right) = 0, \quad \psi_c(u) = \max\{-c, \min(c, u)\}, \quad (1)$$

以 **iteratively reweighted least squares** 求解。令 $w_i = \psi_c(u_i)/u_i$ 、 $u_i = (r_i - \mu)/\hat{\sigma}$ ，更新式為

$$\mu^{(m+1)} = \frac{\sum_i w_i^{(m)} r_i}{\sum_i w_i^{(m)}}, \quad (2)$$

即對超出 $c\hat{\sigma}$ 的觀察值降權的加權平均。尺度 $\hat{\sigma}$ 採正規化後的 **median absolute deviation**。

2.2 Edge 估計的變異數

M-estimator 的教科書漸近變異數為

$$\text{Var}(\hat{\mu}) \approx \frac{\hat{\sigma}^2}{n} \cdot \frac{\mathbb{E}[\psi_c(u)^2]}{(\mathbb{E}[\psi'_c(u)])^2}. \quad (3)$$

實作採用其有限樣本的加權版本：以最終 Huber 權重 $w_i = \psi_c(u_i)/u_i$ 定義有效樣本數，

$$n_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}, \quad \hat{v}_{jk} = \frac{\hat{\sigma}_{\text{robust}}^2}{\max(n_{\text{eff}}, 1)}, \quad (4)$$

即 Kish 式的權重集中度修正。兩式在常態且 $c = 1.345$ 下數值接近（效率因子約 1.04），但它們不是同一個估計量：前者是漸近結果，後者對「少數觀察值實質主導該 edge」的情形反應更直接。此處明確標示 `overlap.py` 的 `huber_location` 採用的是後者。此變異數成為圖問題中的 edge 精度 $1/\hat{v}_{jk}$ 。有兩個實作細節：

1. 設下界 $\hat{v} \leftarrow \max(\hat{v}, v_{\text{floor}})$ ，否則估計變異數趨近零的 edge 會完全主導 normal equations；
2. 對權重設上界 $1/\hat{v} \leq w_{\text{max}}$ ，理由相同但方向相反。

說明 2.1 (與教科書估計器的差異之一). 上下界不屬於古典 *M-estimation* 理論，是數值防護。作用是限制任一 edge 對全域解的影響力；恰好只有 m_{min} 天且數值幾乎相同的 edge，可能產生假性偏小的變異數。

3 圖形加權最小平方

3.1 Normal equations

令 B 為刪去參考欄後的 incidence matrix、 $\mathbf{r}$ 為堆疊的 edge 估計、 $\Omega = \text{diag}(\hat{v}_e)$ ，則

$$(B^\top \Omega^{-1} B) \hat{\ell} = B^\top \Omega^{-1} \mathbf{r}. \quad (5)$$

矩陣 $L = B^\top \Omega^{-1} B$ 是刪去參考列與欄後的加權 graph Laplacian，亦稱 grounded Laplacian。

命題 3.1 (正定性). 若 G 連通，則 *grounded Laplacian* L 正定。

證明. 對自由節點上任意 $\mathbf{x} \neq \mathbf{0}$ ，將參考項補零延伸為 $\tilde{\mathbf{x}}$ ，則 $\mathbf{x}^\top L \mathbf{x} = \sum_{e=(j,k)} \hat{v}_e^{-1} (\tilde{x}_j - \tilde{x}_k)^2 \geq 0$ ，等號成立僅當 $\tilde{\mathbf{x}}$ 在每個連通分量上為常數。連通性使分量唯一，而參考項為零把該常數釘為零，故 $\tilde{\mathbf{x}} = \mathbf{0}$ ，與假設矛盾。□

3.2 由殘差得到的診斷

配適殘差 $\boldsymbol{\varepsilon} = \mathbf{r} - B\hat{\ell}$ 正是 edge 量測的 cycle inconsistency：對 G 中任一 cycle，邊估計沿環累加理應為零， $\boldsymbol{\varepsilon}$ 衡量其偏離。實作輸出：

- 連通性與分量數；
- L 的 condition number，可揭露僅靠單一弱 edge 維繫的圖；
- 加權殘差平方和，作為 cycle-consistency 統計量；
- 由 $\text{diag}(L^{-1})$ 得到的各節點標準誤。

這些量在 sequential stitching 下都不存在，因為 sequential stitching 只用一條 spanning path，沒有 cycle 可供檢驗。

3.3 對數常態偏誤修正

被修正的是估計量的 Jensen 偏誤，不是資料生成過程中乘法誤差的中位數與平均數之差。設 $\hat{\ell}_j$ 近似常態且 $s_j^2 = \text{Var}(\hat{\ell}_j)$ ，則

$$\mathbb{E}[\exp(-\hat{\ell}_j)] = \exp(-\ell_j) \exp\left(\frac{1}{2}s_j^2\right), \quad (6)$$

故直接以 $\exp(-\hat{\ell}_j)$ 還原會系統性高估 a_j^{-1} 。一階修正為

$$\widehat{a_j^{-1}}_{bc} = \exp\left(-\hat{\ell}_j - \frac{1}{2}s_j^2\right), \quad (7)$$

與主文式 (13) 相同。實作取的 s_j^2 是 graph WLS 的 $\text{diag}(L^{-1})$ 對角元，即 `overlap.py` 中的 `log_scale_variance`。

說明 3.1 (差異之二). 此修正僅在 $\hat{\ell}_j$ 近似常態下精確，且其量級隨可用重疊日數增加而遞減至零——這一點與觀測誤差 ϵ_{jt} 本身的變異數不同，後者不隨樣本數縮小。兩者容易混淆，故此處明確標示實作用的是前者。預設開啟是因為乘法模型本身即指向它；設為可調參數，正是因為在此樣本規模下常態性無法檢定。

4 變異成分

4.1 期望均方

對主文的完全交叉設計 (n_t, n_d, n_s 個層級、 n_r 個 replicate)，動差法方程由期望均方導出。以 $\sigma^2_{\bullet}$ 表示對應效應的成分，

$$\mathbb{E}[\text{MS}_T] = \sigma_E^2 + n_r \sigma_{TDS}^2 + n_r n_s \sigma_{TD}^2 + n_r n_d \sigma_{TS}^2 + n_r n_d n_s \sigma_T^2, \quad (8)$$

$$\mathbb{E}[\text{MS}_{TD}] = \sigma_E^2 + n_r \sigma_{TDS}^2 + n_r n_s \sigma_{TD}^2, \quad (9)$$

$$\mathbb{E}[\text{MS}_{TDS}] = \sigma_E^2 + n_r \sigma_{TDS}^2, \quad (10)$$

$$\mathbb{E}[\text{MS}_E] = \sigma_E^2, \quad (11)$$

D 、 S 、 TS 、 DS 有對應方程。由最高階項往下逐一回代即得各成分。

說明 4.1 (差異之三：負的變異成分). 動差法估計可能為負，而變異數不可能為負。實作預設截斷於零。截斷是標準做法，但會使被截斷的成分產生小幅向上偏誤，並連帶扭曲任何用到它的比值。輸出保留未截斷的原始值，讓讀者看見截斷發生的頻率；頻繁截斷代表設計規模不足以支撐所嘗試的分解。

4.2 Generalizability 與 dependability 係數

相對決策（跨日期排序）：

$$E\rho^2 = \frac{\sigma_T^2}{\sigma_T^2 + \frac{\sigma_{TD}^2}{n_d} + \frac{\sigma_{TS}^2}{n_s} + \frac{\sigma_{TDS}^2}{n_d n_s} + \frac{\sigma_E^2}{n_d n_s n_r}}. \quad (12)$$

絕對決策的 dependability 係數 Φ 另計入 D 與 S 的主效應，因為當分數被單獨解讀（而非與其他日期相比）時，整體平移是有影響的：

$$\Phi = \frac{\sigma_T^2}{\sigma_T^2 + \frac{\sigma_D^2}{n_d} + \frac{\sigma_S^2}{n_s} + \frac{\sigma_{TD}^2}{n_d} + \frac{\sigma_{TS}^2}{n_s} + \frac{\sigma_{DS}^2}{n_d n_s} + \frac{\sigma_{TDS}^2}{n_d n_s} + \frac{\sigma_E^2}{n_d n_s n_r}}. \quad (13)$$

說明 4.2 (σ_{TDS}^2 與 σ_E^2 的除數不同). TDS 交互作用只在 *day* $\times$ *stream* 格上被平均，因此除以 $n_d n_s$ ；純 *replication* 誤差另外在格內被平均 n_r 次，因此除以 $n_d n_s n_r$ 。把兩者併為單一項 $(\sigma_{TDS}^2 + \sigma_E^2)/(n_d n_s n_r)$ 只在 $n_r = 1$ 時成立，在 $n_r > 1$ 時會低估相對誤差變異、從而高估 G 。本文建議的正式設計採 $n_r = 2$ ，正是差異存在的情形。式 (12) 與 `gstudy.py` 的 `generalizability_coefficients` 逐項對應，並由 `tests/test_gstudy.py` 的公式一致性測試持續驗證。

D-study 在 (n_d, n_s, n_r) 網格上評估兩者，把分解轉為可執行的設計建議：對 n_d 與對 n_s 的偏導數，直接回答下一單位投入該花在哪裡。

5 受限下的 consensus 權重

無限制解 $\mathbf{w}^* = \Sigma^{-1}\mathbf{1}/(\mathbf{1}^\top \Sigma^{-1}\mathbf{1})$ 已於主文推導。預設設定改解

$$\min_{\mathbf{w}} \mathbf{w}^\top \hat{\Sigma} \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \quad 0 \leq w_i \leq \bar{w}. \quad (14)$$

命題 5.1 (受限問題適定). 若 $\hat{\Sigma} \succeq 0$ 且 $\bar{w} \geq 1/N$ ，則 (14) 的可行集非空、緊緻且凸，故最小值存在；若 $\hat{\Sigma} \succ 0$ 則唯一。

證明. $\bar{w} \geq 1/N$ 時等權向量 $w_i = 1/N$ 可行，故非空；可行集是超平面與方盒的交集，故緊緻且凸。連續函數在非空緊集上取得最小值。 $\hat{\Sigma} \succ 0$ 時目標嚴格凸，故唯一。□

說明 5.1 (為何需要上界 $\bar{w}$). 若不設上界，當估計出的共變異數恰好讓某個 *pull* 看起來近乎無噪音時，權重會幾乎全部集中其上，*consensus* 退化為單一 *pull*——正是本框架要避免的失效模式。上界以少量理論效率換取「*consensus* 永遠是聚合結果」的保證。

5.1 Shrinkage 共變異數

Ledoit–Wolf 估計式為 $\hat{\Sigma} = (1 - \alpha)S + \alpha F$ ，其中 S 為樣本共變異數、 F 為良置條件的目標、 $\alpha \in [0, 1]$ 使期望 Frobenius 平方損失最小。採用它是因為 N 相對於日期數通常偏小， S^{-1} 相應不穩定。

5.2 殘差共變異數的分辨力上界

$\hat{\Sigma}$ 由殘差估計，而殘差是各 *pull* 減去 ** 由 *pull* 自身構成 ** 的當日中心趨勢。被減數因而與被減的對象相關，這在看到任何資料之前就限制了估出的變異數彼此能相差多少。

命題 5.2 (殘差共變異數的分辨力上界). 設 $Z_{tj} = X_t + e_{tj}$ ， e_{tj} 跨 j 獨立且 $\text{Var}(e_{tj}) = \sigma_j^2$ ，殘差對跨 *pull* 均值取值， $r_{tj} = Z_{tj} - m^{-1} \sum_k Z_{tk}$ 。令 $S = \sum_k \sigma_k^2$ ，則

$$\text{Var}(r_{tj}) = \sigma_j^2 \left(1 - \frac{2}{m}\right) + \frac{S}{m^2}. \quad (15)$$

若 $\sigma_2 = \dots = \sigma_m = \sigma$ 且 $\sigma_1 \rightarrow 0$ ，則

$$\frac{\text{Var}(r_{t2})}{\text{Var}(r_{t1})} \rightarrow \frac{m^2 - m - 1}{m - 1} = m - \frac{1}{m - 1}, \quad (16)$$

此極限 ** 不依賴 σ^{**} 。當 $m = 2$ 時該比值對任意 σ_1, σ_2 恆等於 1。

證明. 令 $\bar{e}_t = m^{-1} \sum_k e_{tk}$ ，則 $r_{tj} = e_{tj} - \bar{e}_t$ 。由獨立性得 $\text{Cov}(e_{tj}, \bar{e}_t) = \sigma_j^2/m$ 與 $\text{Var}(\bar{e}_t) = S/m^2$ ，故 $\text{Var}(r_{tj}) = \sigma_j^2 - 2\sigma_j^2/m + S/m^2$ ，即 (15)。在所述設定下 $S \rightarrow (m-1)\sigma^2$ ，因此 $\text{Var}(r_{t1}) \rightarrow (m-1)\sigma^2/m^2$ 、 $\text{Var}(r_{t2}) \rightarrow \sigma^2[(m-2)/m + (m-1)/m^2] = \sigma^2(m^2 - m - 1)/m^2$ ，兩者之比為 (16)， σ^2 相消。當 $m = 2$ 時因子 $1 - 2/m$ 為零，由 (15) 得 $\text{Var}(r_{t1}) = \text{Var}(r_{t2}) = S/4$ ，與 σ_1, σ_2 無關；更強的是 $r_{t1} = (e_{t1} - e_{t2})/2 = -r_{t2}$ 逐點成立。□

說明 5.2 (這個上界是關於什麼的). 命題 5.2 講的是「對樣本自身取中心趨勢」這件事，不是 *Google Trends* 的性質。凡是由「對同一批觀測的某個統計量取殘差」所估的共變異數都適用，且無論真實比值多大，估出的比值上限大約就是被合併的觀測數。以真實變異數比 4×10^8 模擬， $m = 3, \dots, 10$ 皆與 (16) 相符至 0.6% 以內。

說明 5.3 (中位數被減數). 實作減的是當日中位數而非均值。中位數不是線性泛函，無對應閉式；數值上它在同一 m 範圍內優於均值 3 至 50%，並隨 m 增大收斂到同一上界——它改變常數，不改變結論。

5.3 有效 pull 數

輸出兩個摘要：

$$N_{\text{Kish}} = \frac{1}{\sum_i w_i^2}, \quad N_{\text{spec}} = \frac{(\sum_m \lambda_m)^2}{\sum_m \lambda_m^2}, \quad (17)$$

λ_m 為殘差相關矩陣的特徵值。前者衡量權重集中度，後者衡量變異被共享的程度。兩者僅在權重相等且殘差不相關時等於 N ，在存在 **near-duplicate** 時都會明顯低於 N 。直接把 N 當樣本數會高估精度，這正是 **acceptance rule** 以 N_{spec} 表述的原因。

5.4 每日標準誤

共識數列附有每日標準誤。它不是逐日的變異數估計，而 節 7 的下游修正卻把它當作變異數使用，因此在此給出完整構造。

令 $\hat{X}_t$ 為第 t 日的共識值、 y_{tj} 為 **pull** j 對齊後的值。以前述 $\hat{\Sigma}$ 與 $\mathbf{w}$ 定義

$$s_{\text{base}} = \sqrt{\mathbf{w}^\top \hat{\Sigma} \mathbf{w}}, \quad M_t = \text{med}_j |y_{tj} - \hat{X}_t|, \quad \bar{M} = \text{med}_t M_t. \quad (18)$$

實際輸出的量為

$$\text{se}_t = s_{\text{base}} \cdot \text{clip}\left(\frac{M_t}{\bar{M}}, c_{\text{lo}}, c_{\text{hi}}\right), \quad (c_{\text{lo}}, c_{\text{hi}}) = (0.25, 4), \quad (19)$$

關閉區域項時退化為 $\text{se}_t = s_{\text{base}}$ 。輸出的區間為 $\hat{X}_t \mp 1.96 \text{se}_t$ 。

說明 5.4 (三個低估來源，方向完全相同). 式 (19) 是跨 *pull* 離散度的條件式尺度，不是逐日的 $\text{Var}(\hat{X}_t)$ 估計。有三個彼此獨立的機制把它往下壓，且都不是捨入層級的小事：

1. 倍率上限。離散度真的達到典型日十倍的那一天，只會被報成四倍。上限恰好在不確定性最大的日子上綁住。
2. 局部重新加權未進入變異數。第 t 日若有 *pull* 缺失，共識以可用集合上重新正規化的權重形成，但 s_{base} 只由全域 w 算一次。權重集中於較少 *pull* 會提高真實變異數，而 (19) 除非 M_t 恰好同步上升，否則不會反應。
3. 殘差是對 *pull* 自身的逐日中位數取的。使 N_{spec} 向下偏誤的同一個運算，也壓縮了用以估計 $\hat{\Sigma}$ 的殘差離散度， s_{base} 因而繼承該壓縮。

方向值得與 N_{spec} 對照強調：後者的偏誤是保守的——低估資訊量因而傾向拒絕該批資料。這三者的方向相反。它們讓數列看起來比設計所能支撐的更精確，而那正是會讓任何由它得出的結論更好看的方向。

說明 5.5 (對誤差修正估計量的後果). 節 7.1 的動差修正與誤差校正因素模型，都把 se_t^2 當作已知的 Ω 。一個一致偏小的 Ω 會造成校正不足，而所有輸出診斷仍彼此自治，因此結果讀起來仍像已校正。要偵測這個狀態需要真實的 Ω ，而那恰好是取不到的東西。在 (19) 被真正的逐日變異數取代之前，凡依賴 Ω 大小（而非其存在）的結果，都應理解為以一個下界為條件。

6 頻率 benchmark

6.1 解

$Q \succ 0$ 、 $W \succeq 0$ 、 A 為日對期的聚合矩陣時，

$$x^* = (Q + A^\top W A)^{-1}(Qz + A^\top W b). \quad (20)$$

Q 建構為 $(\lambda_I + \lambda_R)I + \lambda_D D_1^\top D_1$ ，其中 D_1 為一階差分運算子（`benchmark.py` 的 `_difference_penalty` 建構 `shape (n-1, n)`、`offsets [0, 1]` 的差分矩陣後回傳 $D_1^\top D_1$ ）。第一項懲罰偏離日頻 consensus，其中 λ_R 是使 Q 在 $\lambda_I = 0$ 時仍正定的 ridge；第二項懲罰修正路徑的粗糙度。因此 movement preservation 是施加在「修正量」而非「水準」上。一階差分懲罰的是修正路徑的斜率；若改用二階差分則懲罰其曲率，屬於 benchmarking 文獻中另一族估計器，本實作並未採用。

6.2 Exact 模式

Exact 模式把聚合約束 $Ax = b$ 由懲罰改為硬約束，得 KKT 系統

$$\begin{bmatrix} Q & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} Qz \\ b \end{bmatrix}, \quad (21)$$

在 A 為列滿秩時可解。預設為 **soft** 模式，因為低頻 GT 數列本身也帶測量誤差，硬性套用等於把該誤差原封不動轉嫁到日頻數列而不加聲明。

7 測量誤差修正

7.1 動差修正

令 $W_t = X_t + u_t$ 、 M 為控制變數的 **residual maker**、 Ω_u 為測量誤差共變異數。由 $\mathbb{E}[\mathbf{W}^\top M \mathbf{W}] = \mathbb{E}[\mathbf{X}^\top M \mathbf{X}] + \text{tr}(M\Omega_u)$ 與 $\mathbb{E}[\mathbf{W}^\top M \mathbf{Y}] = \beta \mathbb{E}[\mathbf{X}^\top M \mathbf{X}]$ ，

$$\hat{\beta} = \frac{\mathbf{W}^\top M \mathbf{Y}}{\mathbf{W}^\top M \mathbf{W} - \text{tr}(M\Omega_u)}. \quad (22)$$

說明 7.1 (分母本身就是診斷). 分母非正代表：在控制變數被 *partial out* 之後，估計的測量誤差已吃掉全部可觀察的解釋變數變異。實作在此拋出錯誤而非回傳數值。該情況下回傳一個符號翻轉或爆炸的係數，比直接失敗更糟——因為失敗本身帶有資訊：它說明這個建構出的指標在這條迴歸中已無可用訊號。

7.2 SIMEX

對網格 $\lambda \in \{0, \lambda_1, \dots, \lambda_K\}$ ，生成 $W_t(\lambda, b) = W_t + \sqrt{\lambda} \tilde{u}_{tb}$ ($\tilde{u}_{tb}$ 依 Ω_u 抽取)，對 $b = 1, \dots, B$ 估 $\hat{\beta}(\lambda, b)$ 後對 b 平均。以參數曲線 $g(\lambda; \theta)$ 配適 $\{(\lambda, \hat{\beta}(\lambda))\}$ ，回報 $g(-1; \hat{\theta})$ ，即外推至無測量誤差的假想情形。**SIMEX** 與動差修正並列回報而非擇一：兩者一致是古典誤差結構足夠的證據，兩者分歧則是不足的證據。

8 數學與程式的對應

表 2: 各結果的實作位置。

結果	模組	進入點
Huber edge 估計	overlap.py	huber_location
圖形 WLS 與診斷	overlap.py	OverlapGraphCalibrator.fit
Exact/near duplicates	duplicates.py	diagnose_duplicates
變異成分與 D-study	gstudy.py	run_gstudy
設計式參考估計量	consensus.py	fit_design_weighted_consensus
受限 GLS consensus	consensus.py	fit_gls_consensus
Benchmark 解	benchmark.py	temporal_benchmark
Reliability 與收斂	reliability.py	assess_reliability
Acceptance decision tree	decision.py	evaluate_batch
動差修正與 SIMEX	eiv.py	reliability_corrected_ols、 simex_ols