

RACER-GT 數學附錄

推導、證明與估計器實作細節

Yi-Hao Lai

大葉大學財務金融學系

2026-07-28 • 版本 1.5.0

摘要

本附錄收錄方法論主文中未完整展開的推導，並逐項說明軟體實際實作的估計器。撰寫原則是「可被查核」：每個結果都對應到計算它的模組與函式，讀者可以自行驗證程式與數學是否一致。實作與教科書估計器有三處刻意的差異，本文明確標示並說明理由，而不是留給讀者自己發現。

目錄

1	符號	3
2	穩健 edge 估計	3
2.1	估計式	3
2.2	Edge 估計的變異數	3
3	圖形加權最小平方	4
3.1	Normal equations	4
3.2	由殘差得到的診斷	4
3.3	對數常態偏誤修正	5
4	變異成分	6
4.1	期望均方	6
4.2	Generalizability 與 dependability 係數	6

5	受限下的 consensus 權重	7
5.1	Shrinkage 共變異數	7
5.2	多個 chunk 對捨入誤差究竟買到什麼	7
5.3	殘差共變異數的分辨力上界	8
5.4	有效 pull 數	9
5.5	每日標準誤	9
6	頻率 benchmark	11
6.1	解	11
6.2	Exact 模式	11
7	測量誤差修正	12
7.1	動差修正	12
7.2	SIMEX	12
7.3	誤差校正因素分析	12
8	數學與程式的對應	13

1 符號

表 1: 全文符號對照。

符號	值域	意義
t	$1, \dots, T$	歷史日曆日期
i	$1, \dots, N$	complete pull (一次完整歷史重建)
j, k	$1, \dots, J$	chunk (固定查詢視窗)
d, s, r	—	collection day 、 stream 、 technical replicate
Y_{jt}	$[0, 100]$	原始 GT 值，日期 t 、 chunk j
a_j, ℓ_j	$\mathbb{R}_{>0}, \mathbb{R}$	chunk 尺度與其對數， $\ell_j = \log a_j$
X_t	$\mathbb{R}_{>0}$	共同尺度下的潛在訊號
Z_{it}	$\mathbb{R}$	pull i 在日期 t 的校準值
Σ	$\mathbb{R}^{N \times N}$	跨 pull 殘差共變異數
$\mathbf{w}$	Δ^{N-1}	consensus 權重， $\mathbf{1}^\top \mathbf{w} = 1$
$c_{\min}$	$\mathbb{R}_{>0}$	進入 overlap edge 的最小原始值
$m_{\min}$	$\mathbb{N}$	edge 所需最少可用重疊日數

2 穩健 edge 估計

2.1 估計式

對 **edge** (j, k) ，令 $r_1, \dots, r_n$ 為可用重疊日上的 **log ratio** $\log Y_{jt} - \log Y_{kt}$ 。Huber location 估計解

$$\sum_{i=1}^n \psi_c \left(\frac{r_i - \hat{\mu}}{\hat{\sigma}} \right) = 0, \quad \psi_c(u) = \max\{-c, \min(c, u)\}, \quad (1)$$

以 **iteratively reweighted least squares** 求解。令 $w_i = \psi_c(u_i)/u_i$ 、 $u_i = (r_i - \mu)/\hat{\sigma}$ ，更新式為

$$\mu^{(m+1)} = \frac{\sum_i w_i^{(m)} r_i}{\sum_i w_i^{(m)}}, \quad (2)$$

即對超出 $c\hat{\sigma}$ 的觀察值降權的加權平均。尺度 $\hat{\sigma}$ 採正規化後的 **median absolute deviation**。

2.2 Edge 估計的變異數

M-estimator 的教科書漸近變異數為

$$\text{Var}(\hat{\mu}) \approx \frac{\hat{\sigma}^2}{n} \cdot \frac{\mathbb{E}[\psi_c(u)^2]}{(\mathbb{E}[\psi'_c(u)])^2}. \quad (3)$$

實作採用其有限樣本的加權版本：以最終 Huber 權重 $w_i = \psi_c(u_i)/u_i$ 定義有效樣本數，

$$n_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}, \quad \hat{v}_{jk} = \frac{\hat{\sigma}_{\text{robust}}^2}{\max(n_{\text{eff}}, 1)}, \quad (4)$$

即 Kish 式的權重集中度修正。兩式在常態且 $c = 1.345$ 下數值接近（效率因子約 1.04），但它們不是同一個估計量：前者是漸近結果，後者對「少數觀察值實質主導該 edge」的情形反應更直接。此處明確標示 `overlap.py` 的 `huber_location` 採用的是後者。此變異數成為圖問題中的 edge 精度 $1/\hat{v}_{jk}$ 。有兩個實作細節：

1. 設下界 $\hat{v} \leftarrow \max(\hat{v}, v_{\text{floor}})$ ，否則估計變異數趨近零的 edge 會完全主導 normal equations；
2. 對權重設上界 $1/\hat{v} \leq w_{\text{max}}$ ，理由相同但方向相反。

說明 2.1 (與教科書估計器的差異之一). 上下界不屬於古典 *M-estimation* 理論，是數值防護。作用是限制任一 edge 對全域解的影響力；恰好只有 m_{min} 天且數值幾乎相同的 edge，可能產生假性偏小的變異數。

3 圖形加權最小平方

3.1 Normal equations

令 B 為刪去參考欄後的 incidence matrix、 $\mathbf{r}$ 為堆疊的 edge 估計、 $\Omega = \text{diag}(\hat{v}_e)$ ，則

$$(B^\top \Omega^{-1} B) \hat{\ell} = B^\top \Omega^{-1} \mathbf{r}. \quad (5)$$

矩陣 $L = B^\top \Omega^{-1} B$ 是刪去參考列與欄後的加權 graph Laplacian，亦稱 grounded Laplacian。

命題 3.1 (正定性). 若 G 連通，則 *grounded Laplacian* L 正定。

證明. 對自由節點上任意 $\mathbf{x} \neq \mathbf{0}$ ，將參考項補零延伸為 $\tilde{\mathbf{x}}$ ，則 $\mathbf{x}^\top L \mathbf{x} = \sum_{e=(j,k)} \hat{v}_e^{-1} (\tilde{x}_j - \tilde{x}_k)^2 \geq 0$ ，等號成立僅當 $\tilde{\mathbf{x}}$ 在每個連通分量上為常數。連通性使分量唯一，而參考項為零把該常數釘為零，故 $\tilde{\mathbf{x}} = \mathbf{0}$ ，與假設矛盾。□

3.2 由殘差得到的診斷

配適殘差 $\boldsymbol{\varepsilon} = \mathbf{r} - B\hat{\ell}$ 正是 edge 量測的 cycle inconsistency：對 G 中任一 cycle，邊估計沿環累加理應為零， $\boldsymbol{\varepsilon}$ 衡量其偏離。實作輸出：

- 連通性與分量數；
- L 的 condition number，可揭露僅靠單一弱 edge 維繫的圖；
- 加權殘差平方和，作為 cycle-consistency 統計量；
- 由 $\text{diag}(L^{-1})$ 得到的各節點標準誤。

這些量在 sequential stitching 下都不存在，因為 sequential stitching 只用一條 spanning path，沒有 cycle 可供檢驗。

3.3 對數常態偏誤修正

被修正的是估計量的 Jensen 偏誤，不是資料生成過程中乘法誤差的中位數與平均數之差。設 $\hat{\ell}_j$ 近似常態且 $s_j^2 = \text{Var}(\hat{\ell}_j)$ ，則

$$\mathbb{E}[\exp(-\hat{\ell}_j)] = \exp(-\ell_j) \exp\left(\frac{1}{2}s_j^2\right), \quad (6)$$

故直接以 $\exp(-\hat{\ell}_j)$ 還原會系統性高估 a_j^{-1} 。一階修正為

$$\widehat{a_j^{-1}}_{bc} = \exp\left(-\hat{\ell}_j - \frac{1}{2}s_j^2\right), \quad (7)$$

與主文式 (13) 相同。實作取的 s_j^2 是 graph WLS 的 $\text{diag}(L^{-1})$ 對角元，即 `overlap.py` 中的 `log_scale_variance`。

說明 3.1 (差異之二). 此修正僅在 $\hat{\ell}_j$ 近似常態下精確，且其量級隨可用重疊日數增加而遞減至零——這一點與觀測誤差 ϵ_{jt} 本身的變異數不同，後者不隨樣本數縮小。兩者容易混淆，故此處明確標示實作用的是前者。預設開啟是因為乘法模型本身即指向它；設為可調參數，正是因為在此樣本規模下常態性無法檢定。

4 變異成分

4.1 期望均方

對主文的完全交叉設計 (n_t, n_d, n_s 個層級、 n_r 個 replicate)，動差法方程由期望均方導出。以 σ^2 表示對應效應的成分，

$$\mathbb{E}[\text{MS}_T] = \sigma_E^2 + n_r \sigma_{TDS}^2 + n_r n_s \sigma_{TD}^2 + n_r n_d \sigma_{TS}^2 + n_r n_d n_s \sigma_T^2, \quad (8)$$

$$\mathbb{E}[\text{MS}_{TD}] = \sigma_E^2 + n_r \sigma_{TDS}^2 + n_r n_s \sigma_{TD}^2, \quad (9)$$

$$\mathbb{E}[\text{MS}_{TDS}] = \sigma_E^2 + n_r \sigma_{TDS}^2, \quad (10)$$

$$\mathbb{E}[\text{MS}_E] = \sigma_E^2, \quad (11)$$

D 、 S 、 TS 、 DS 有對應方程。由最高階項往下逐一回代即得各成分。

說明 4.1 (差異之三：負的變異成分). 動差法估計可能為負，而變異數不可能為負。實作預設截斷於零。截斷是標準做法，但會使被截斷的成分產生小幅向上偏誤，並連帶扭曲任何用到它的比值。輸出保留未截斷的原始值，讓讀者看見截斷發生的頻率；頻繁截斷代表設計規模不足以支撐所嘗試的分解。

4.2 Generalizability 與 dependability 係數

相對決策（跨日期排序）：

$$E\rho^2 = \frac{\sigma_T^2}{\sigma_T^2 + \frac{\sigma_{TD}^2}{n_d} + \frac{\sigma_{TS}^2}{n_s} + \frac{\sigma_{TDS}^2}{n_d n_s} + \frac{\sigma_E^2}{n_d n_s n_r}}. \quad (12)$$

絕對決策的 dependability 係數 Φ 另計入 D 與 S 的主效應，因為當分數被單獨解讀（而非與其他日期相比）時，整體平移是有影響的：

$$\Phi = \frac{\sigma_T^2}{\sigma_T^2 + \frac{\sigma_D^2}{n_d} + \frac{\sigma_S^2}{n_s} + \frac{\sigma_{TD}^2}{n_d} + \frac{\sigma_{TS}^2}{n_s} + \frac{\sigma_{DS}^2}{n_d n_s} + \frac{\sigma_{TDS}^2}{n_d n_s} + \frac{\sigma_E^2}{n_d n_s n_r}}. \quad (13)$$

說明 4.2 (σ_{TDS}^2 與 σ_E^2 的除數不同). TDS 交互作用只在 *day* $\times$ *stream* 格上被平均，因此除以 $n_d n_s$ ；純 *replication* 誤差另外在格內被平均 n_r 次，因此除以 $n_d n_s n_r$ 。把兩者併為單一項 $(\sigma_{TDS}^2 + \sigma_E^2)/(n_d n_s n_r)$ 只在 $n_r = 1$ 時成立，在 $n_r > 1$ 時會低估相對誤差變異、從而高估 G 。本文建議的正式設計採 $n_r = 2$ ，正是差異存在的情形。式 (12) 與 `gstudy.py` 的 `generalizability_coefficients` 逐項對應，並由 `tests/test_gstudy.py` 的公式一致性測試持續驗證。

D-study 在 (n_d, n_s, n_r) 網格上評估兩者，把分解轉為可執行的設計建議：對 n_d 與對 n_s 的偏導數，直接回答下一單位投入該花在哪裡。

5 受限下的 consensus 權重

無限制解 $\mathbf{w}^* = \Sigma^{-1}\mathbf{1}/(\mathbf{1}^\top \Sigma^{-1}\mathbf{1})$ 已於主文推導。預設設定改解

$$\min_{\mathbf{w}} \mathbf{w}^\top \hat{\Sigma} \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \quad 0 \leq w_i \leq \bar{w}. \quad (14)$$

命題 5.1 (受限問題適定). 若 $\hat{\Sigma} \succeq 0$ 且 $\bar{w} \geq 1/N$ ，則 (14) 的可行集非空、緊緻且凸，故最小值存在；若 $\hat{\Sigma} \succ 0$ 則唯一。

證明. $\bar{w} \geq 1/N$ 時等權向量 $w_i = 1/N$ 可行，故非空；可行集是超平面與方盒的交集，故緊緻且凸。連續函數在非空緊集上取得最小值。 $\hat{\Sigma} \succ 0$ 時目標嚴格凸，故唯一。□

說明 5.1 (為何需要上界 $\bar{w}$). 若不設上界，當估計出的共變異數恰好讓某個 *pull* 看起來近乎無噪音時，權重會幾乎全部集中其上，*consensus* 退化為單一 *pull*——正是本框架要避免的失效模式。上界以少量理論效率換取「*consensus* 永遠是聚合結果」的保證。

5.1 Shrinkage 共變異數

Ledoit–Wolf 估計式為 $\hat{\Sigma} = (1 - \alpha)S + \alpha F$ ，其中 S 為樣本共變異數、 F 為良置條件的目標、 $\alpha \in [0, 1]$ 使期望 Frobenius 平方損失最小。採用它是因為 N 相對於日期數通常偏小， S^{-1} 相應不穩定。

5.2 多個 chunk 對捨入誤差究竟買到什麼

Trends 回傳整數，且每個 chunk 先除以自己視窗內的最大值再取整。這兩件事共同決定了「某日被多個 chunk 覆蓋」能降低多少量測誤差，而答案 ** 不是 chunk 的個數 **。

令 $v_{tc} = \text{round}(\theta_{tc})$ ， $\theta_{tc} = 100 q_t / M_c$ ，其中 q_t 為第 t 日被服務的相對量、 M_c 為 chunk c 視窗內的最大值。令 $\delta_{tc} = v_{tc} - \theta_{tc}$ 、 s_c 為估計尺度，則校準值為 $\hat{y}_{tc} = s_c v_{tc} = X_t + s_c \delta_{tc}$ 。

命題 5.2 (重疊 chunk 之間的捨入誤差). 令 $\alpha_c = 100/M_c$ ，則 $\delta_{tc} = \gamma(\alpha_c q_t \bmod 1)$ ，其中 $u < \frac{1}{2}$ 時 $\gamma(u) = -u$ 、否則 $\gamma(u) = 1 - u$ 。則

1. 若 q_t 為連續分布， δ_{tc} 漸近均勻於 $[-\frac{1}{2}, \frac{1}{2})$ 且 $\text{Var}(\delta_{tc}) = \frac{1}{12}$ ；

2. 若 $M_c = M_{c'}$ ，則 $\delta_{tc} = \delta_{tc'}$ ** 恆等 **，該對除其一之外不帶任何資訊；
3. 若 $\alpha_c/\alpha_{c'}$ 為無理數，由 Weyl 準則， $(\alpha_c q \bmod 1, \alpha_{c'} q \bmod 1)$ 漸近均勻於 $[0, 1)^2$ ，故 $\text{Cov}(\delta_{tc}, \delta_{tc'}) \rightarrow 0$ ；
4. 在等權且尺度相近、覆蓋該日的 *chunk* 構成 g_t 個相異 M_c 群且相異最大值處於一般位置時，

$$\text{Var}(\hat{X}_t) \approx \frac{\bar{s}^2}{12 g_t}. \quad (15)$$

證明. (i) 為 $\alpha q \bmod 1$ 的標準等分布結果。(ii) 直接可得： $M_c = M_{c'}$ 給出 $\theta_{tc} = \theta_{tc'}$ ，而 γ 是函數。(iii) 為 Weyl 準則用於該對。(iv) 由 $\hat{X}_t - X_t = \sum_c w_{tc} s_c \delta_{tc}$ 得：由 (ii)，共用最大值的 *chunk* 只貢獻同一項；由 (iii)，相異最大值貢獻漸近不相關的項，故實際上只有 g_t 個有效加總項。□

說明 5.2 (這與同日 *cache* 並不矛盾). 同日重複取得已被實測為同一份被服務樣本的重新縮放，故買不到抽樣資訊。命題 5.2 講的是 ** 另一種誤差 **：即使 q_t 固定不變，不同的正規化常數會把 ** 同一個實數 ** 映到 ** 不同的整數格點 **，其捨入誤差因而相異。****chunk** 重疊與重複取得降低的是不同的成分，兩者不可互相取代。 **

說明 5.3 (「一般位置」這個限定條件不是裝飾). (iv) 要求相異最大值處於一般位置，而模擬顯示這個限定條件確實在做事。最大值比為 3 時捨入誤差相關 +0.33；比為 5/3 與 7/3 時約 +0.06；比為 1.001 時 +0.71。其他有理比則為負相關（比為 2 時 -0.25、3/2 時 -0.08），那是有利而非有害。因此 g_t 是有效獨立捨入次數的 ** 代理量 **，僅在 (iii) 下精確，一般情形下既非上界亦非下界。實務上主要的失效模式仍是 $M_c = M_{c'}$ ，而該情形已由既有的 `n_scale_groups` 計數——真實資料上 8 個 *chunk* 只構成 4 群。

5.3 殘差共變異數的分辨力上界

$\hat{\Sigma}$ 由殘差估計，而殘差是各 *pull* 減去 ** 由 *pull* 自身構成 ** 的當日中心趨勢。被減數因而與被減的對象相關，這在看到任何資料之前就限制了估出的變異數彼此能相差多少。

命題 5.3 (殘差共變異數的分辨力上界). 設 $Z_{tj} = X_t + e_{tj}$ ， e_{tj} 跨 j 獨立且 $\text{Var}(e_{tj}) = \sigma_j^2$ ，殘差對跨 *pull* 均值取值， $r_{tj} = Z_{tj} - m^{-1} \sum_k Z_{tk}$ 。令 $S = \sum_k \sigma_k^2$ ，則

$$\text{Var}(r_{tj}) = \sigma_j^2 \left(1 - \frac{2}{m} \right) + \frac{S}{m^2}. \quad (16)$$

若 $\sigma_2 = \dots = \sigma_m = \sigma$ 且 $\sigma_1 \rightarrow 0$ ，則

$$\frac{\text{Var}(r_{t2})}{\text{Var}(r_{t1})} \rightarrow \frac{m^2 - m - 1}{m - 1} = m - \frac{1}{m - 1}, \quad (17)$$

此極限 ** 不依賴 σ **。當 $m = 2$ 時該比值對任意 σ_1, σ_2 恆等於 1。

證明. 令 $\bar{e}_t = m^{-1} \sum_k e_{tk}$, 則 $r_{tj} = e_{tj} - \bar{e}_t$. 由獨立性得 $\text{Cov}(e_{tj}, \bar{e}_t) = \sigma_j^2/m$ 與 $\text{Var}(\bar{e}_t) = S/m^2$, 故 $\text{Var}(r_{tj}) = \sigma_j^2 - 2\sigma_j^2/m + S/m^2$, 即 (16). 在所述設定下 $S \rightarrow (m-1)\sigma^2$, 因此 $\text{Var}(r_{t1}) \rightarrow (m-1)\sigma^2/m^2$, $\text{Var}(r_{t2}) \rightarrow \sigma^2[(m-2)/m + (m-1)/m^2] = \sigma^2(m^2 - m - 1)/m^2$, 兩者之比為 (17), σ^2 相消。當 $m = 2$ 時因子 $1 - 2/m$ 為零, 由 (16) 得 $\text{Var}(r_{t1}) = \text{Var}(r_{t2}) = S/4$, 與 σ_1, σ_2 無關; 更強的是 $r_{t1} = (e_{t1} - e_{t2})/2 = -r_{t2}$ 逐點成立。□

說明 5.4 (這個上界是關於什麼的). 命題 5.3 講的是「對樣本自身取中心趨勢」這件事, 不是 *Google Trends* 的性質。凡是由「對同一批觀測的某個統計量取殘差」所估的共變異數都適用, 且無論真實比值多大, 估出的比值上限大約就是被合併的觀測數。以真實變異數比 4×10^8 模擬, $m = 3, \dots, 10$ 皆與 (17) 相符至 0.6% 以內。

說明 5.5 (中位數被減數). 實作減的是當日中位數而非均值。中位數不是線性泛函, 無對應閉式; 數值上它在同一 m 範圍內優於均值 3 至 50%, 並隨 m 增大收斂到同一上界——它改變常數, 不改變結論。

5.4 有效 pull 數

輸出兩個摘要：

$$N_{\text{Kish}} = \frac{1}{\sum_i w_i^2}, \quad N_{\text{spec}} = \frac{(\sum_m \lambda_m)^2}{\sum_m \lambda_m^2}, \quad (18)$$

λ_m 為殘差相關矩陣的特徵值。前者衡量權重集中度, 後者衡量變異被共享的程度。兩者僅在權重相等且殘差不相關時等於 N , 在存在 **near-duplicate** 時都會明顯低於 N 。直接把 N 當樣本數會高估精度, 這正是 **acceptance rule** 以 N_{spec} 表述的原因。

5.5 每日標準誤

共識數列附有每日標準誤。它不是逐日的變異數估計, 而 節 7 的下游修正卻把它當作變異數使用, 因此在此給出完整構造。

令 $\hat{X}_t$ 為第 t 日的共識值、 y_{tj} 為 pull j 對齊後的值。以前述 $\hat{\Sigma}$ 與 $\mathbf{w}$ 定義

$$s_{\text{base}} = \sqrt{\mathbf{w}^\top \hat{\Sigma} \mathbf{w}}, \quad M_t = \text{med}_j |y_{tj} - \hat{X}_t|, \quad \bar{M} = \text{med}_t M_t. \quad (19)$$

實際輸出的量為

$$\text{se}_t = s_{\text{base}} \cdot \text{clip}\left(\frac{M_t}{\bar{M}}, c_{\text{lo}}, c_{\text{hi}}\right), \quad (c_{\text{lo}}, c_{\text{hi}}) = (0.25, 4), \quad (20)$$

關閉區域項時退化為 $\text{se}_t = s_{\text{base}}$ 。輸出的區間為 $\hat{X}_t \pm 1.96 \text{se}_t$ 。

說明 5.6 (三個低估來源，方向完全相同). 式 (20) 是跨 *pull* 離散度的條件式尺度，不是逐日的 $\text{Var}(\hat{X}_t)$ 估計。有三個彼此獨立的機制把它往下壓，且都不是捨入層級的小事：

1. 倍率上限。離散度真的達到典型日十倍的那一天，只會被報成四倍。上限恰好在不確定性最大的日子上綁住。
2. 局部重新加權未進入變異數。第 t 日若有 *pull* 缺失，共識以可用集合上重新正規化的權重形成，但 s_{base} 只由全域 w 算一次。權重集中於較少 *pull* 會提高真實變異數，而 (20) 除非 M_t 恰好同步上升，否則不會反應。
3. 殘差是對 *pull* 自身的逐日中位數取的。使 N_{spec} 向下偏誤的同一個運算，也壓縮了用以估計 $\hat{\Sigma}$ 的殘差離散度， s_{base} 因而繼承該壓縮。

方向值得與 N_{spec} 對照強調：後者的偏誤是保守的——低估資訊量因而傾向拒絕該批資料。這三者的方向相反。它們讓數列看起來比設計所能支撐的更精確，而那正是會讓任何由它得出的結論更好看的方向。

命題 5.4 (區域倍率估計的是什麼). 設殘差共變異數只在 ** 尺度 ** 上隨時間變動而形狀不變，即 $\Sigma_t = c_t^2 \Sigma$ ($c_t > 0$)。則

1. $\sqrt{w^\top \Sigma_t w} = c_t \sqrt{w^\top \Sigma w} = c_t \text{base_se}$ ，故「單一全域標準誤乘上逐日尺度」正是正確的形式；
2. $M_t/\bar{M}$ 對 c_t 一致，因為把中位絕對離差換算為標準差的一致性常數在分子與分母同時出現而相消。

證明. (i) 由雙線性直接可得。(ii) 在形狀不變的假設下， M_t 對每個 t 皆估計 $\kappa c_t \sigma$ (同一個 κ)，而 $\bar{M}$ 估計 $\kappa \sigma$ 。□

說明 5.7 (有限樣本行為，以及截斷的用途). 命題 5.4 是對 *pull* 數的漸近結果，而 M_t 只由 m 個 *pull* 算出。以 $c_t \equiv 1$ 模擬（此時倍率偏離 1 的部分全是估計噪音），倍率的標準差在 $m = 3$ 時為 0.61、 $m = 9$ 時 0.38、 $m = 30$ 時 0.21。截斷邊界 $[0.25, 4]$ 在 $m = 3$ 時綁住 4.75% 的日期、 $m = 9$ 時 0.40%、 $m = 30$ 時完全不綁。** 邊界本身沒有統計推導 **，它是數值防護；在本框架建議的設計規模下其代價很小。

說明 5.8 (檢定力，以及它在哪裡消失). 該倍率確實偵測得到真實的變動。當五分之一的日期真實 $c_t = 3$ 時，用倍率區分這些日期的 ROC 曲線下面積在 $m = 3$ 為 0.88、 $m = 9$ 為 0.98、 $m = 30$ 為 1.00。

但那是在命題的假設下——所有 *pull* 一起變吵。若某日只有 ** 部分 ** *pull* 變吵 (Σ_t 的 ** 形狀 ** 改變而非尺度)，中位數會吸收掉它，檢定力隨受影響 *pull* 的比例 ** 單調下降 **： $m = 9$ 時，全部受影響為 0.98、半數為 0.78、五分之一為 0.63。 ** 使 M_t 抗離群值的那個穩健性，正是使它在此失明的原因 **，且方向不利——未被偵測到的上升會讓 se_t 偏小。

說明 5.9 (對誤差修正估計量的後果). 節 7.1 的動差修正與誤差校正因素模型，都把 se_t^2 當作已知的 Ω 。一個一致偏小的 Ω 會造成校正不足，而所有輸出診斷仍彼此自治，因此結果讀起來仍像已校正。要偵測這個狀態需要真實的 Ω ，而那恰好是取不到的東西。在 (20) 被真正的逐日變異數取代之前，凡依賴 Ω 大小（而非其存在）的結果，都應理解為以一個下界為條件。

6 頻率 benchmark

6.1 解

$Q \succ 0$ 、 $W \succeq 0$ 、 A 為日對期的聚合矩陣時，

$$\mathbf{x}^* = (Q + A^\top W A)^{-1}(Q\mathbf{z} + A^\top W \mathbf{b}). \quad (21)$$

Q 建構為 $(\lambda_I + \lambda_R)I + \lambda_D D_1^\top D_1$ ，其中 D_1 為一階差分運算子（`benchmark.py` 的 `_difference_penalty` 建構 `shape (n-1, n)`、`offsets [0, 1]` 的差分矩陣後回傳 $D_1^\top D_1$ ）。第一項懲罰偏離日頻 consensus，其中 λ_R 是使 Q 在 $\lambda_I = 0$ 時仍正定的 ridge；第二項懲罰修正路徑的粗糙度。因此 movement preservation 是施加在「修正量」而非「水準」上。一階差分懲罰的是修正路徑的斜率；若改用二階差分則懲罰其曲率，屬於 benchmarking 文獻中另一族估計器，本實作並未採用。

6.2 Exact 模式

Exact 模式把聚合約束 $A\mathbf{x} = \mathbf{b}$ 由懲罰改為硬約束，得 KKT 系統

$$\begin{bmatrix} Q & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \boldsymbol{\lambda} \end{bmatrix} = \begin{bmatrix} Q\mathbf{z} \\ \mathbf{b} \end{bmatrix}, \quad (22)$$

在 A 為列滿秩時可解。預設為 soft 模式，因為低頻 GT 數列本身也帶測量誤差，硬性套用等於把該誤差原封不動轉嫁到日頻數列而不加聲明。

7 測量誤差修正

7.1 動差修正

令 $W_t = X_t + u_t$ 、 M 為控制變數的 residual maker、 Ω_u 為測量誤差共變異數。由 $\mathbb{E}[\mathbf{W}^\top M \mathbf{W}] = \mathbb{E}[\mathbf{X}^\top M \mathbf{X}] + \text{tr}(M \Omega_u)$ 與 $\mathbb{E}[\mathbf{W}^\top M \mathbf{Y}] = \beta \mathbb{E}[\mathbf{X}^\top M \mathbf{X}]$ ，

$$\hat{\beta} = \frac{\mathbf{W}^\top M \mathbf{Y}}{\mathbf{W}^\top M \mathbf{W} - \text{tr}(M \Omega_u)}. \quad (23)$$

說明 7.1 (分母本身就是診斷). 分母非正代表：在控制變數被 *partial out* 之後，估計的測量誤差已吃掉全部可觀察的解釋變數變異。實作在此拋出錯誤而非回傳數值。該情況下回傳一個符號翻轉或爆炸的係數，比直接失敗更糟——因為失敗本身帶有資訊：它說明這個建構出的指標在這條迴歸中已無可用訊號。

7.2 SIMEX

對網格 $\lambda \in \{0, \lambda_1, \dots, \lambda_K\}$ ，生成 $W_t(\lambda, b) = W_t + \sqrt{\lambda} \tilde{u}_{tb}$ ($\tilde{u}_{tb}$ 依 Ω_u 抽取)，對 $b = 1, \dots, B$ 估 $\hat{\beta}(\lambda, b)$ 後對 b 平均。以參數曲線 $g(\lambda; \theta)$ 配適 $\{(\lambda, \hat{\beta}(\lambda))\}$ ，回報 $g(-1; \hat{\theta})$ ，即外推至無測量誤差的假想情形。SIMEX 與動差修正並列回報而非擇一：兩者一致是古典誤差結構足夠的證據，兩者分歧則是不足的證據。

7.3 誤差校正因素分析

觀測 K 個 series 為 $\mathbf{y}_t = \Lambda \mathbf{f}_t + \mathbf{e}_t + \mathbf{u}_t$ ，其中 $\mathbf{f}_t$ 為潛在因素、 $\mathbf{e}_t$ 為 series 特有成分 ($\text{Var} = \Psi$ 對角)、 $\mathbf{u}_t$ 為量測誤差且 $\text{Var}(\mathbf{u}_t) = \Omega_t$ 由外部供給。估計量在特徵分解之前先扣除平均誤差共變異數： $\tilde{S} = S - \bar{\Omega}$ 。

命題 7.1 (誤差校正共變異數與衰減). 1. 若 $\mathbf{u}_t$ 與 $\mathbf{f}_t$ 、 $\mathbf{e}_t$ 不相關，則 $\mathbb{E}[\tilde{S}] = \Lambda \Lambda^\top + \Psi$ ：校正後共變異數是「若無量測誤差時該有的共變異數」的無偏估計。

2. 取單因素、loading 與誤差同質，並標準化使 $a + \psi + \omega = 1$ ($a = \lambda^2$ 為 *communality*、 ω 為量測誤差佔比)。在 ** 相關係數尺度 ** 上比較 loading，未校正對校正後的比值為

$$\frac{\lambda^{\text{raw}} / \sqrt{S_{kk}}}{\tilde{\lambda} / \sqrt{\tilde{S}_{kk}}} = \sqrt{\frac{B(1 - \omega)}{B - \omega}}, \quad B = 1 + (K - 1)a. \quad (24)$$

$\omega = 0$ 時恰為 1；因 $B > 1$ ， $\omega > 0$ 時嚴格小於 1 且對 ω 遞減。

3. 若模型成立且 $\bar{\Omega}$ 未超過真實的平均量測共變異數，則 $\tilde{S} \succeq 0$ 。

證明. (i) 在所述正交性下 $\mathbb{E}[S] = \Lambda\Lambda^\top + \Psi + \bar{\Omega}$ ，而 $\bar{\Omega}$ 已被扣除。(ii) 同質下 $S = \Lambda\Lambda^\top + \tau I$ ($\tau = \psi + \omega$)、 $\tilde{S} = \Lambda\Lambda^\top + \psi I$ ，兩矩陣共用首特徵向量 $\Lambda/\|\Lambda\|$ ，僅首特徵值相異 ($\|\Lambda\|^2 + \tau$ 對 $\|\Lambda\|^2 + \psi$)。代入 $\lambda_k = v_k\sqrt{\mu_1}$ 、各自除以自身矩陣所蘊含的標準差，並利用標準化後的 $a + \tau = 1$ ，即得 (24)。(iii) 由 (i)，期望值為 $\Lambda\Lambda^\top + \Psi$ ，因 Ψ 對角非負而半正定。□

說明 7.2 (校正後共變異數非正定究竟代表什麼). (iii) 修正了先前的解讀。**** 失去半正定性本身並不是「該組 series 撐不起一個因素」的證據 ****——在模型正確且 $\bar{\Omega}$ 正確時，它根本不會發生。它是 $\bar{\Omega}$ **** 相對於觀測共變異數過大 **** 的證據：量測誤差被高估、模型設定錯誤、或 S 的有限樣本變異。因此估計量選擇 **** 拋出例外而非修補 ****，並在診斷中報告最小特徵值，使違反的幅度可見。

說明 7.3 (數值檢驗). (24) 於模擬之前寫定，在 *communality* 0.3 至 0.6、誤差佔比 0 至 0.3、 K 由 4 至 12 的組合上吻合至 0.01% 以內； $\omega = 0$ 時回傳 1.00000。

8 數學與程式的對應

表 2: 各結果的實作位置。

結果	模組	進入點
Huber edge 估計	overlap.py	huber_location
圖形 WLS 與診斷	overlap.py	OverlapGraphCalibrator.fit
Exact/near duplicates	duplicates.py	diagnose_duplicates
變異成分與 D-study	gstudy.py	run_gstudy
設計式參考估計量	consensus.py	fit_design_weighted_consensus
受限 GLS consensus	consensus.py	fit_gls_consensus
Benchmark 解	benchmark.py	temporal_benchmark
Reliability 與收斂	reliability.py	assess_reliability
Acceptance decision tree	decision.py	evaluate_batch
動差修正與 SIMEX	eiv.py	reliability_corrected_ols、 simex_ols