

RACER-GT：在重複抽樣、分段正規化與相依量測 下 建構長期日頻 Google Trends 指標

實驗設計、全域重疊圖校準、廣義信度理論與共變異數調整估計

Yi-Hao Lai and RACER-GT contributors

方法論與軟體技術報告，版本 1.0.0

2026 年 7 月 27 日

摘要

Google Trends (GT) 已廣泛用作投資人注意力、資訊需求與情緒的高頻代理變數；然而，網站版 GT 的每次請求會重新縮放為 0–100，長期日頻資料往往必須切割為多個短視窗，且在相同查詢設定下重複下載仍可能出現不同數值。若研究者只下載一次、逐段接合後直接投入財金模型，分段尺度誤差、重複量測相依性、低搜尋量的零值與四捨五入，以及下游解釋變數的 measurement-error attenuation，均可能扭曲估計與預測結論。

本文提出 RACER-GT (Randomized Acquisition, Calibration, Error Decomposition, and Reliability for Google Trends)，其核心不是宣稱能恢復 Google 的絕對搜尋次數，而是先明確定義兩個可識別的統計目標：固定查詢與取得設計下的 GT 期望回傳值，以及共同尺度下的潛在相對搜尋訊號。方法依序結合：(一) 可預先註冊的平衡重複取得實驗與 protocol hash；(二) 使用所有重疊區間的全域圖形加權最小平方法，以避免 sequential stitching 的誤差累積；(三) 完整保留 exact duplicates，並以去除共同訊號後的殘差建立 near-duplicate dependence graph；(四) 將 historical date、collection day、collection stream 與 technical replicate 視為交叉 facets 的 Generalizability Theory；(五) 以誤差共變異數調整的 GLS / 穩定化最小變異凸組合重建日頻共識；(六) 以週頻與月頻資料進行二次規劃式 temporal benchmarking；(七) 分離 detection、level 與 daily-innovation reliability；以及(八) 將日頻 GT 的測量不確定性傳遞至下游 reliability-corrected OLS 與 SIMEX。

本文給出識別條件、無偏性與最小變異性之條件式證明、完整 decision tree，以及 Python 套件實作。20 次受控 Monte Carlo 在對齊資訊集後給出混合結果：跨

pull 聚合使平均 RMSE 由單一 pull 的 7.3519 降至 3.7421 (降低 49.1%，20 次重複全部改善)，相對跨 pull 中位數的 4.1710 亦降低 10.3%；temporal benchmarking 在估計量固定時另貢獻約 0.22 的 RMSE 降低 ($p \approx 3 \times 10^{-12}$)。但共變異數調整加權相對簡單平均 (3.7253) 並無可偵測的優勢 (-0.0167 ， $p = 0.152$)。對此最自然的解釋是依賴結構過於同質，因而 GLS 無可利用之處；本文進一步以四情境實驗直接檢驗該解釋，讓一部分 pull 額外共享一條跨設計因子的 cache 噪音，結果不支持它：GLS 在任一異質情境下均未顯著勝出，其中兩個情境顯著較差。診斷顯示約束並非原因（無約束解逐位相同），且機制運作正確（權重與殘差相關之相關係數 -0.562 ），剩下的解釋是以 9 個 pull 估計 Σ 所引入的誤差超過其效率增益。理論結果不受影響（ Σ 已知時 GLS 仍為 BLUE），受影響的是實務建議。校準階段亦得到同型結果：全域 overlap-graph 相對逐段 stitching 確實阻止了誤差沿接合鏈累積（成長比 1.12 對 4.75），但重建誤差差異在最有設定下仍為 $p = 0.098$ 。本文由此得到一個貫穿性的結論——各機制均按設計運作且可被量測證實，但其效果在點估計精度上是二階的；本框架的價值在於產生可被判斷的數列，而非更準的數列。這些結果不構成對所有關鍵字、地區與 GT 版本的普遍最優保證。

關鍵詞：Google Trends；投資人注意力；測量誤差；實驗設計；Generalizability Theory；圖形校準；GLS；temporal benchmarking；SIMEX

研究定位聲明。本文所稱「偏誤降低」與「無偏」均為相對於明確定義之 estimand，並建立在可檢驗或可敏感度分析的假設上。Google 未公開網站版 GT 的完整抽樣分配、random seed、sample ID 或伺服器配置，因此不可能僅由重複下載無條件證明其等於絕對搜尋量，也不能以不同 IP 位址直接推論樣本獨立。

目錄

1	研究問題與方法論動機	4
2	統計目標、不可識別性與可證明範圍	5
2.1	三個不同的研究目標	5
2.2	絕對搜尋量不可由網站版 GT 單獨識別	6
2.3	設計式無偏性	6
3	資料取得實驗與 protocol locking	8
3.1	交叉因素設計	8
3.2	固定歷史窗、chunk manifest 與 protocol hash	9
3.3	Pilot 與 confirmatory batch 的分離	9
4	第一階段：每一 complete pull 的全域重疊圖校準	10
4.1	分段正規化模型	10
4.2	Robust edge estimation	10
4.3	Graph WLS 識別與估計	11
4.4	同日多 chunk 聚合	13
4.5	與逐段 stitching 的直接比較	14
4.6	真實 Google Trends 資料上的校準檢驗	15
4.6.1	GT 的正規化會製造零資訊重疊	15
4.6.2	比例假設在真實資料上成立	16

4.6.3	模擬器的 chunk 噪音高估約 4.5 倍	17
4.6.4	一年的 chunk 為何看不到 F1，以及 F1 何時開始重要	17
5	第二階段：跨 pull 相依性、duplicates 與量測可靠度	18
5.1	Exact duplicate audit	18
5.2	Residual near-duplicate graph	19
5.3	三面向 Generalizability Theory	19
5.4	Balanced ANOVA 的 method-of-moments components	20
6	第三階段：共變異數調整的潛在共識數列	21
6.1	Measurement model	21
6.2	有效 pull 資訊量	23
7	第四階段：日、週、月頻率一致化	24
8	可靠度指標與預先鎖定的 decision tree	25
8.1	Detection、level 與 innovation	25
8.2	Acceptance rules	25
9	下游財金模型的 measurement-error correction	26
9.1	Attenuation bias	26
9.2	SIMEX	27
10	完整演算法	27
11	Python 套件實作	28
11.1	設計原則	28
11.2	最小使用範例	29
12	Monte Carlo 驗證	30
12.1	資料生成過程	30
12.2	比較設計：資訊集必須對齊	30
12.3	結果	31
12.4	依賴異質性的直接檢驗	32
13	建議的正式實驗規格	34
14	限制、敏感度分析與可延伸方向	35
14.1	無法由統計設計消除的限制	35
14.2	必要的穩健性檢驗	37
14.3	與既有方法的關係	38
15	結論	38
A	Decision tree 的預設欄位	39
B	輸入資料 schema	39
C	軟體測試與重現指令	40

1 研究問題與方法論動機

Google Trends 將搜尋活動轉化為相對搜尋興趣（relative search interest）指標，因其即時性與高頻特性，已被財金研究用來衡量投資人注意力、資訊需求與恐慌情緒，例如 Da, Engelberg, and Gao (2011, 2015) [10, 11] 以及後續的報酬、波動與交易量研究 [6, 25]。Ben-Rephael, Da, and Israelsen (2017) [1] 進一步指出，不同來源的注意力代理變數並不等價，這使 GT 本身的測量性質更值得單獨檢視。這類資料的經濟直覺很清楚：投資人未必進行交易，但通常會在形成交易意圖或受到市場事件刺激時先搜尋資訊。因此，搜尋活動可補足交易資料只記錄已實現行為的限制。

然而，GT 的便利性也容易掩蓋其測量結構。Google 官方說明指出，Trends 使用搜尋活動的樣本，將資料依時間與地區正規化，再縮放至 0–100；低搜尋量可能呈現為零。網站版每一次請求均在該次請求的範圍內重新縮放，而 2025 年公布的 API alpha 雖提供跨請求一致尺度，歷史範圍仍為滾動約 1,800 天，且數值仍不是絕對搜尋次數 [18, 17]。因此，若研究期橫跨 2010–2026 年，網站版資料通常仍需切成多個短視窗後重建。

既有研究已分別指出：GT 存在 sampling noise 與 frequency inconsistency [14]；不同時間下載相同查詢可能產生不一致結果 [5, 23]；低量關鍵字在 0–100 整數尺度下會遭受嚴重 rounding 與 censoring，因而需要 anchor calibration [29]；長期高頻資料可利用重疊視窗進行 knitting [2]。然而，若研究目的不只是在資料層面平滑一條曲線，而是要讓其進入財金計量模型，仍需同時回答下列問題：

1. 重複下載的 estimand 是什麼？「真實搜尋次數」是否可識別？
2. 如何以實驗設計控制 collection day、stream、request order 與 technical replicate？
3. 每一個 complete pull 內，各自被正規化的 chunks 如何放到共同尺度？
4. exact duplicates、near duplicates 與一般 sampling variation 應如何區分，而不進行 outcome-guided deletion？
5. 如何以 ANOVA / G-theory 分解誤差來源，並決定增加 days、streams 或 replicates 哪一項最有效？
6. 若 pulls 相互依賴，如何避免把 21 次下載錯當成 21 份獨立資訊？
7. 如何使日頻形狀與較可靠的週頻、月頻長期尺度一致？
8. GT 作為財金模型解釋變數時，如何修正 measurement-error attenuation？

RACER-GT 將上述問題整合為一條從資料取得到下游推論的可重現測量鏈。其流程如圖 1。




圖 1: RACER-GT 的完整估計鏈。每一層均保留輸入、輸出與稽核紀錄；非相同 pulls 不因偏離中位數而被刪除。

2 統計目標、不可識別性與可證明範圍

2.1 三個不同的研究目標

令 Q 表示已鎖定的 query specification，包括 term/topic、geo、category、search property、語言、固定歷史起訖日與 chunk manifest。令 R 表示 retrieval environment 與執行條件，例如 collection day、stream、time slot、request order、session state 以及網站端未被研究者觀察的抽樣狀態。網站版 GT 對歷史日 t 的回傳可抽象寫為

$$Y_t(Q, R) = \mathcal{N}_{Q,R}\{S_t(Q, R)\}, \quad (1)$$

其中 S_t 為 proprietary sampling 與 aggregation 後的搜尋訊號， $\mathcal{N}_{Q,R}$ 包含 window-specific normalization、0–100 scaling、rounding、thresholding 與可能的統計處理。

本文區分三個 estimands。

定義 2.1 (絕對搜尋量). $A_t(Q)$ 為符合查詢構念的 *Google* 絕對搜尋次數。網站版 *GT* 不直接觀察 $A_t(Q)$ 。

定義 2.2 (GT 設計期望). 在預先定義的 *retrieval distribution* $\mathcal{R}$ 下，

$$\theta_t(Q; \mathcal{R}) = \mathbb{E}_{R \sim \mathcal{R}} [Y_t(Q, R)]. \quad (2)$$

此 *estimand* 描述固定 *query protocol* 下 *GT* 系統的期望回傳值。

定義 2.3 (共同尺度潛在相對訊號). 令 X_t 為在明確基準期 $\mathcal{B}$ 下識別的相對搜尋指標，滿足

$$\frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} X_t = 100. \quad (3)$$

X_t 不代表絕對搜尋次數，而是不同 *chunks* 與 *pulls* 在校準後共享的相對尺度。

2.2 絕對搜尋量不可由網站版 GT 單獨識別

命題 2.1 (絕對尺度不可識別). 假設網站版 *GT* 僅觀察某一 *window* W 內經比例正規化的值

$$Y_t = 100 \frac{A_t}{\max_{\tau \in W} A_\tau}, \quad t \in W, \quad (4)$$

忽略 *rounding* 時，對任何常數 $c > 0$ ，序列 A_t 與 cA_t 產生完全相同的 Y_t 。因此，沒有外部 *anchor* 或絕對量資訊時， A_t 的絕對尺度不可識別。

證明. 將 A_t 替換為 cA_t ，則

$$100 \frac{cA_t}{\max_{\tau \in W} cA_\tau} = 100 \frac{cA_t}{c \max_{\tau \in W} A_\tau} = Y_t.$$

因此資料對所有 $c > 0$ 都具有相同 *likelihood* / *observation mapping*，絕對尺度無法由 Y_t 唯一決定。□

這項結果界定了研究主張的上限：我們可以改善相對訊號的尺度一致性、降低重建誤差並量化可靠度，但不能把統計校準誤稱為「恢復真實搜尋次數」。

2.3 設計式無偏性

令 $R_1, \dots, R_m$ 由預先鎖定的 $\mathcal{R}$ 產生，並考慮

$$\bar{Y}_t = \frac{1}{m} \sum_{i=1}^m Y_t(Q, R_i). \quad (5)$$

命題 2.2 (對 GT 設計期望的無偏性). 若 R_i 具有相同邊際分配 $\mathcal{R}$ ，則無論 *pulls* 之間是否

獨立，

$$\mathbb{E}(\bar{Y}_t) = \theta_t(Q; \mathcal{R}). \quad (6)$$

獨立性只影響 $\text{Var}(\bar{Y}_t)$ ，不影響此平均的期望。

證明. 利用期望的線性性：

$$\mathbb{E}(\bar{Y}_t) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}\{Y_t(Q, R_i)\} = \frac{1}{m} \sum_{i=1}^m \theta_t = \theta_t.$$

此推導不需 R_i 相互獨立。 $\square$

說明 2.1. 若取得設計不是由一個明確且固定的 $\mathcal{R}$ 產生，例如 *Day 30* 使用擴張到「當日」的歷史終點，則每一 *pull* 的 *estimand* 不同，平均值不再對單一 θ_t 無偏。這也是固定 *historical end date* 的理論理由。

實際的 RACER-GT 蒐集通常採分層且平衡的 **day $\times$ stream $\times$ replicate** 設計，而非假設所有 *pulls* 具有完全相同的條件分配。令 $h \in \mathcal{H}$ 表示預先鎖定的 **design cell**， π_h 為研究者事先指定的目標權重，且

$$\theta_{th} = \mathbb{E}(Y_{thi} \mid H = h), \quad \theta_t^\pi = \sum_{h \in \mathcal{H}} \pi_h \theta_{th}, \quad \sum_h \pi_h = 1. \quad (7)$$

若 **cell** h 完成 n_h 次有效重複量測，定義

$$\hat{\theta}_t^\pi = \sum_{h \in \mathcal{H}} \pi_h \bar{Y}_{th}, \quad \bar{Y}_{th} = \frac{1}{n_h} \sum_{i=1}^{n_h} Y_{thi}. \quad (8)$$

命題 2.3 (分層設計估計量的無偏性). 若每一 *design cell* 內的有效量測均以不依賴其未觀察回傳值的規則納入，且 $\mathbb{E}(Y_{thi} \mid H = h) = \theta_{th}$ ，則

$$\mathbb{E}(\hat{\theta}_t^\pi) = \theta_t^\pi, \quad (9)$$

即使同一 *cell* 內或不同 *cells* 之間的 *pulls* 相關，結論仍成立。相關性只改變變異數與有效資訊量。

證明. 由條件期望與線性性，

$$\mathbb{E}(\hat{\theta}_t^\pi) = \sum_h \pi_h \mathbb{E}(\bar{Y}_{th}) = \sum_h \pi_h \theta_{th} = \theta_t^\pi.$$

推導不需假設 $\text{Cov}(Y_{thi}, Y_{th'j}) = 0$ 。但若 **failed requests**、**partial responses** 或事後刪除與未觀察的 Y_{thi} 有關，則 **cell mean** 可能產生 **informative-missingness bias**，故 **raw audit** 與預先指定排除規則不可省略。 $\square$

平衡設計是 $\pi_h = 1/|\mathcal{H}|$ 的特例；若某些 collection days 或 streams 在目標 retrieval distribution 中應有不同權重，必須在看見資料前指定 π_h ，而不是依結果調整。

3 資料取得實驗與 protocol locking

3.1 交叉因素設計

RACER-GT 將取得程序視為 repeated-measurement experiment，而非將每次下載模糊地稱為「獨立樣本」。基本設計為

$$D \times S \times R, \quad (10)$$

其中 D 為 collection-day levels、 S 為 collection streams、 R 為每個 day $\times$ stream cell 內的 technical replicates。本文建議的起始設計為 Day 0、1、2、7、14、21、30，三個固定 streams；若資源允許， $R = 2$ 可將 pure technical error 與最高階交互作用分離。若僅 $R = 1$ ，仍可估計 day 與 stream facets，但 TDS 與純 replication error 無法分離。

說明 3.1 (為何 collection day 是承重的 facet). 本設計把 *collection day* 視為獨立 *facet*，理由是平台似乎以「日」為週期重新抽樣，而非每次請求重抽。Djorno et al. (2026) 報告重複的相同請求會在 24 小時內由 *cache* 提供，並於 UTC 午夜 *cache* 重置時抽取新樣本。

由此有兩個推論。第一，同一日內的重複取得無法買到關於抽樣誤差的獨立資訊，因此證據累積的有效速率上限是每日一筆新抽樣；任何以重複 *pulls* 平均來降低抽樣變異的程序——包括 Eichenauer et al. (2022) 所建議者——都是以日曆時間換取精度，這正是它在即時應用上尷尬之處。

第二，此機制給出一個可用以檢驗本框架的預測：若日 *cache* 嚴格成立，式 (26) 中的 *technical-replicate* 變異成分應與零無法區分，而第 6.1 節保留的 *exact duplicates* 就不是待清除的雜訊，而是 *cache* 的直接可觀察證據。反之，若該成分明顯大於零，則日 *cache* 的描述對所處理的 *query* 而言並不完整。此處陳述該預測是因為它的檢驗成本很低，且兩種結果都有資訊價值；本文不假設它成立，亦無任何結果依賴它。

Collection stream 應被定義為固定的複合環境：裝置、瀏覽器 profile、cookie、登入狀態、client 版本、網路與 IP 等條件在 stream 內保持不變。除非另行採用 crossover factorial design，估計出的 S effect 只能稱為 composite stream effect，不能拆解為 IP effect。

為避免 stream 與 request order 或 time slot 完全混淆，RACER-GT 以 cyclic / Latin-square-like rotation 平衡每一天的 stream order；chunk order 亦可輪替。若三個 streams 無法同時啟動，這種平衡至少能使系統狀態隨時間的變化不固定落在同一個 stream。

3.2 固定歷史窗、chunk manifest 與 protocol hash

所有正式 pulls 必須共用：

- 相同的 historical start 與 end；
- 相同的 chunk start/end、overlap 與 query parameters；
- 相同的資料清理、partial-period 排除與時區規則；
- 相同的 calibration、duplicate、G-study、consensus 與 decision thresholds；
- 相同版本的程式碼與設定檔。

設定物件以 canonical JSON 序列化並計算 SHA-256：

$$h = \text{SHA256}\{\text{canonical}(Q, \mathcal{D}, \mathcal{C}, \mathcal{T})\}, \quad (11)$$

其中 $\mathcal{D}$ 是蒐集設計， $\mathcal{C}$ 是校準設定， $\mathcal{T}$ 是 decision thresholds。每筆 raw row 可保存 h ，若任何設定被改動，protocol hash 即改變。

3.3 Pilot 與 confirmatory batch 的分離

Day 0–2 的 MONITOR 可用來檢查缺漏、query drift、exact duplicates、overlap graph 是否連通與程式執行錯誤；但若研究團隊因此修改 thresholds、stitching rule、query、code 或 decision tree，Day 0–2 必須被重新標記為 pilot，正式 confirmatory batch 由新的 Day 0 開始。否則同一資料同時被用來設計與驗證規則，形成 data-dependent acceptance bias。

同理，所有 GT 處理規則都必須在查看報酬、波動、價差、VaR 或其他財金結果之前鎖定。以「哪種 GT 建構最顯著」作為資料品質決策，會將 measurement validation 變成 outcome-guided model selection。

4 第一階段：每一 complete pull 的全域重疊圖校準

4.1 分段正規化模型

令一個 complete pull 包含 J 個重疊 chunks。對 chunk j 中歷史日 t 的正值觀察，考慮近似模型

$$Y_{jt} = a_j X_t \exp(\epsilon_{jt}), \quad a_j > 0, \quad (12)$$

其中 a_j 代表該次 chunk-specific normalization scale， X_t 是該 pull 內欲恢復的共同相對訊號。當 t 同時存在於 chunks j 與 k 時，

$$r_{jkt} = \log Y_{jt} - \log Y_{kt} = \ell_j - \ell_k + \nu_{jkt}, \quad \ell_j = \log a_j, \quad (13)$$

且 $\nu_{jkt} = \epsilon_{jt} - \epsilon_{kt}$ 。

由於零值不能取 $\log$ ，且接近零的整數 RSV 會放大 ratio noise，RACER-GT 僅使用兩邊皆高於預先指定門檻 $c_{\min}$ 的 overlap cells 估計 edge。零值本身不被插補為正值，但必須說明聚合階段的實際行為：當某一歷史日被多個 chunks 覆蓋、其中一部分回傳 0 而另一部分回傳正值時，下節的加權聚合結果為正值，因此該日在最終數列中不再是零。只有所有覆蓋該日的 chunks 都為 0 時，零值才會保留。這是聚合規則的推論，不是插補決策，但它改變了 detection reliability 所量測的對象，故 CalibrationResult.diagnostics 另行輸出 n_dates_with_zero_chunk 與 n_dates_zero_masked_by_aggregation 供稽核。對高 zero-share 的關鍵字，應同時檢視這兩個數字，或改採較廣的 Topic 與較低頻率。

4.2 Robust edge estimation

對每一可用的 chunk pair (j, k) ，令 $\mathcal{O}_{jk}$ 為重疊日期集合。edge location $\delta_{jk} = \ell_j - \ell_k$ 以 Huber M-estimator 估計：

$$\hat{\delta}_{jk} = \arg \min_{\delta} \sum_{t \in \mathcal{O}_{jk}} \rho_c(r_{jkt} - \delta), \quad (14)$$

其中

$$\rho_c(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq c, \\ c|u| - \frac{1}{2}c^2, & |u| > c. \end{cases} \quad (15)$$

這使極端 overlap cells 不至於完全決定尺度比。套件同時估計 robust scale 與 location variance $\hat{v}_{jk}$ ，形成 edge weight $w_{jk} = \min\{1/\max(\hat{v}_{jk}, v_{\min}), w_{\max}\}$ 。變異數下界 $v_{\min}$ 與權重上界 $w_{\max}$ 都是數值防護而非古典 M-estimation 理論的一部分：兩者共同限制任

一 edge 對全域解的影響力，因為恰好只有 $m_{\min}$ 天且數值幾乎相同的 edge 會產生假性偏小的變異數。實作採用的 $\hat{v}_{jk}$ 是 Huber 權重的有效樣本數版本，與教科書漸近式的差異詳見數學附錄。

4.3 Graph WLS 識別與估計

建立無向圖 $G = (V, E)$ ：每個 chunk 是 node，每個可估 edge 是一個 overlap relation。將所有 edge equations 堆疊為

$$\hat{\delta} = B\ell + \eta, \quad \mathbb{E}(\eta \mid B) = 0, \quad \text{Var}(\eta \mid B) = \Omega, \quad (16)$$

其中 B 是 oriented incidence matrix。由於只可識別相對尺度，固定一個 reference chunk r ，令 $\ell_r = 0$ ；刪除對應欄後得到 B_{-r} 。估計量為

$$\hat{\ell}_{-r} = (B_{-r}'WB_{-r})^{-1}B_{-r}'W\hat{\delta}. \quad (17)$$

命題 4.1 (相對尺度的識別). 固定一個 reference node 後， ℓ_{-r} 可識別若且唯若 overlap graph G 連通。此時 B_{-r} 具有滿 column rank， $B_{-r}'WB_{-r}$ 對任意正定 diagonal W 可逆。

證明. 圖論中，連通圖的 incidence matrix rank 為 $|V| - 1$ 。刪除任一 node 對應欄後， B_{-r} rank 為 $|V| - 1$ ，等於其欄數。反之，若圖有 $K > 1$ 個 components，incidence matrix rank 為 $|V| - K < |V| - 1$ ，即使固定單一 reference 仍存在至少 $K - 1$ 個未識別的 component-level shifts。□

命題 4.2 (Graph GLS 的條件式無偏性與效率). 在式 (16)、圖連通且 $W = \Omega^{-1}$ 下，式 (17) 滿足

$$\mathbb{E}(\hat{\ell}_{-r} \mid B) = \ell_{-r}, \quad (18)$$

且為所有線性無偏估計量中的最小變異估計量。

證明. 無偏性由

$$\mathbb{E}(\hat{\ell}_{-r} \mid B) = (B'WB)^{-1}B'W\mathbb{E}(\hat{\delta} \mid B) = \ell_{-r}$$

得之（為簡潔略去下標 $-r$ ）。效率為 Gauss–Markov theorem 的直接應用。□

上述命題只說 graph WLS 在給定 edge 估計下是 BLUE，並未回答本文最關心的問題：相對於逐段 stitching 究竟好多少。失效模式 F1 過去只是文字主張。下述命題把它化為一個等式，並且只依賴 chunk 設計、不依賴雜訊水準。

命題 4.3 (校準變異數即有效電阻). 將 *overlap graph* 視為電路，令 *edge* e 的電導為其精度 $w_e = 1/\text{Var}(\hat{\delta}_e)$ 。則對任意 *chunk* j 與 *reference* r ，

$$\text{Var}(\hat{\ell}_j - \hat{\ell}_r \mid B) = R_{\text{eff}}(j, r), \quad (19)$$

其中 R_{eff} 為加權圖 *Laplacian* $L = B'WB$ 意義下 j 與 r 之間的有效電阻。由此得兩個推論：

(i) 逐段 *stitching* 為同一估計量限制在一條 *spanning path* 上，其有效電阻是所經各 *edge* 電阻之和，因而隨接合數線性成長。這就是 *F1*，且為精確陳述而非比喻。

(ii) (*Rayleigh* 單調性) 在圖中增加任一 *edge* 不會提高任何一對節點間的有效電阻。因此

$$R_{\text{eff}}^{\text{graph}}(j, r) \leq R_{\text{eff}}^{\text{path}}(j, r) \quad \text{對所有 } j, \quad (20)$$

即全域圖校準在校準變異數上永不劣於任何逐段 *stitching*，且差距可在收集任何資料之前由設計本身算出。

證明. 以 r 為接地點，刪去對應列與欄後的 grounded Laplacian 恰為 $B'_{-r}WB_{-r}$ ，而式 (17) 的估計量共變異數為 $(B'_{-r}WB_{-r})^{-1}$ 。電網理論中，接地 Laplacian 逆矩陣的第 j 個對角元即為 j 至接地點的有效電阻，故得式 (19)。推論 (i) 因 *path* 為串聯電路，電阻相加。推論 (ii) 為 *Rayleigh* 單調性定理：增加 *edge* 等同增加並聯路徑，不會提高兩點間等效電阻。□

說明 4.1 (這使 *F1* 成為可在設計階段計算的量). 式 (19) 中 $\text{Var}(\hat{\delta}_e) \approx \sigma^2/n_e$ (n_e 為重疊天數， σ 為每日 *log-ratio* 離散度)，故 σ^2 在 *path* 與 *graph* 的比值中約掉：變異數降幅只是 *chunk* 設計的函數。以真實資料實測的 $\sigma = 0.0188$ 換算成終端 *chunk* 的尺度標準差：

表 1: *chunk* 設計經式 (19) 所隱含的校準誤差，採 $\text{Var}(\hat{\delta}_e) = \sigma^2/n_e$ ， σ 取自一年、單一關鍵字的中位離散度。只有第一列可與資料對照，其餘為外推——見 *remark 4.2*。

設計（歷史跨度、視窗／步進）	chunks	降幅	逐段	全域圖
實測，由估計出的 <i>edge</i> 變異數				
1 年，180 / 30	8	9.13×	—	—
外推，由理想化 <i>edge</i> 模型				
1 年，180 / 30	8	10.5×	0.40%	0.12%
5 年，180 / 30	56	18.2×	1.15%	0.27%
15 年，180 / 30	178	20.1×	2.06%	0.46%
15 年，180 / 15（表 10 建議）	355	140.5×	2.79%	0.23%

說明 4.2 (本表哪些是實測、哪些不是). 恆等式 (19) 與序關係式 (20) 是定理，不需要資料。但表中的數字是另一回事：其兩項假設被用來校準它的同一年資料所否證，且兩者都朝著對本文結論有利的方向偏，因此明列而非留給讀者自行發現。

理想化 edge 模型高估降幅約 15%。在唯一可雙向計算的設計上，由估計出的 *edge* 變異數得 $9.13\times$ ，理想化模型得 $10.5\times$ ：26 條重疊中有 5 條退化、取的是 *variance floor* 而非 σ^2/n_e ，且 *Huber* 權重使 $n_{\text{eff}} < n_e$ 。外推各列沒有這道檢查。

σ 不是常數。21 條有效重疊的 σ 在單一年度之內即相差 1.75 倍，且與該對的數值水準相關 -0.760 ($p = 0.0001$)，正是捨入下限 $1/(\sqrt{12}v)$ 所預測者。15 年序列涵蓋的搜尋量變化遠大於一年，低搜尋量時期的 σ 更大，故後三列的絕對百分比為低估。比值較穩健，因 σ 在 *path* 與 *graph* 之間大致約掉，但一旦 σ 跨 *edge* 變動便不會完全約掉。

射程也應直說：一年、一個關鍵字、一個 *pull*，外推十五倍。「F1 在長期設計下具實質意義」是命題 4.3 的預測，不是量測結果。要檢驗它需要長跨度的實際收集，表 10 已規定其規格，本文尚未執行。

1.4.0 起，`CalibrationResult.diagnostics` 直接輸出 `max_log_scale_variance`、`sequential_max_log_scale_variance` 與兩者之比 `calibration_variance_reduction`。

若 $\widehat{\ell}_j$ 近似常態且 $\text{Var}(\widehat{\ell}_j) = s_j^2$ ，直接使用 $\exp(-\widehat{\ell}_j)$ 會有 *lognormal transformation bias*。若校準目的為將 Y_{jt} 除以 a_j ，可採一階修正

$$\widehat{a_j^{-1}}_{bc} = \exp\left(-\widehat{\ell}_j - \frac{1}{2}s_j^2\right). \quad (21)$$

此修正依賴近似常態與 *variance estimate*，故程式允許關閉作為 *sensitivity analysis*。

4.4 同日多 chunk 聚合

校準後的 *chunk observation* 為

$$\widetilde{X}_{jt} = Y_{jt} \exp(-\widehat{\ell}_j). \quad (22)$$

同一歷史日通常被多個重疊 *chunks* 覆蓋。RACER-GT 預設依 *chunk-scale variance* 進行 *inverse-variance aggregation*：

$$\widehat{X}_t^{(i)} = \frac{\sum_{j \in \mathcal{J}_t} \omega_{jt} \widetilde{X}_{jt}}{\sum_{j \in \mathcal{J}_t} \omega_{jt}}, \quad \omega_{jt} = \frac{1}{\widehat{\text{Var}}(\widehat{\ell}_j) + \varepsilon}. \quad (23)$$

亦可使用 *median* 或 *Huber aggregation*。最後依式 (3) 將每個 *complete pull* 的基準期平均設為 100。這一步明確定義相對 *index*，而非宣稱恢復絕對量。

逐段 *stitching* 只使用相鄰 *chunks*，前段 *edge error* 會遞迴傳遞至後續所有尺度；全域圖法同時使用所有可估計的重疊關係，能以 *graph cycles* 觀察不一致，並

輸出 normal-matrix condition number、weighted edge RMSE 與 component diagnostics。

4.5 與逐段 stitching 的直接比較

上述論證過去只有理論陳述，未經量測。examples/run_calibration_comparison.py 直接量測它：src/racergt/baselines.py 實作了逐段 stitching (Bleher and Dimpfl 式的 knitting)，使用完全相同的 Huber edge 估計器、相同的 $c_{\min}$ 門檻與相同的基準期正規化，唯一差異是走一條 spanning path 而非解整張圖。因此任何精度差距都只能歸因於這個選擇。

表 2: 全域圖校準對逐段 stitching，每格 $20 \text{ seeds} \times 2 \text{ pulls}$ 。優勢欄為 sequential 減 graph 的 RMSE，正值表示全域圖較優。

設計	接合數	Graph	Sequential	優勢	MCSE	p	Graph 勝場
60 日 step	5	7.4827	7.4677	-0.0150	0.0053	0.008	13/40
30 日 step	9	7.3026	7.2967	-0.0059	0.0049	0.234	15/40
15 日 step	17	7.2085	7.2125	+0.0040	0.0072	0.576	15/40
15 日 step，低噪音	17	1.9245	1.9356	+0.0111	0.0066	0.098	21/40

機制成立，效果是二階的。F1 所描述的累積現象確實存在且量級明確：在 15 日 step 設計下，逐段 stitching 所回復的 log scale，其跨重複標準差由鏈前段的 0.0259 增至鏈末段的 0.1228，成長 4.75 倍；全域圖法的對應比值僅 1.12。誤差確實沿接合鏈累積，而全域求解確實阻止了它。

但這並未轉化為可偵測的重建誤差優勢。趨勢的方向與 F1 一致——接合數由 5 增至 17 時，優勢由 -0.0150 轉為 +0.0040；將 retrieval noise 由 0.06 降至 0.01、使校準誤差在總誤差中佔更大比重時，優勢再升至 +0.0111——但即使在這個為 F1 量身打造的最有利設定下， $p = 0.098$ 、勝場 21/40，仍未達顯著。在接合數最少的設計下，全域圖法反而顯著較差 ($p = 0.008$)，原因是其參考 chunk 由 highest-degree 規則選出而非固定為第一個 chunk，且它額外施加了式 (21) 的對數常態修正。

說明 4.3 (三個機制，同一個結論). 這是本文第三次得到同型結果。共變異數調整加權能正確辨識並降權相依 pulls (權重與殘差相關之相關係數 -0.562)，但不改善 RMSE；依賴異質性的預測被直接檢驗後失敗；全域圖校準確實阻止了誤差沿鏈累積 (1.12 對 4.75)，同樣不改善 RMSE。

三者的共同結構是：機制按設計運作，且可被量測證實，但其效果在點估計精度上是二階的，被 retrieval noise 掩蓋。對使用者而言，這個結論比任何單一數字都重要——它指出本框架的價值不在於產生更準的數列，而在於產生可被判斷的數列。有效 pull

數、依賴結構、*cycle* 不一致統計量、每日條件標準誤與可傳遞的測量不確定性，都是 *RMSE* 無法表達也無法取代的資訊。

4.6 真實 Google Trends 資料上的校準檢驗

上一小節的所有證據都出自本套件自己的模擬器，而模擬器是依估計量所假設的比例模型抽樣的。這是循環論證：它能顯示估計量解出了我們交給它的問題，卻不能顯示那個問題就是真實的問題。本節把校準階段套用在真實下載的資料上：關鍵字 `bitcoin`、地區美國、日頻、2024 全年，180 天視窗、30 天步進共 8 個 `chunk`，1,440 筆觀測。轉換器為 `examples/ingest_trends_csv.py`，分析為 `examples/run_real_data_calibration.py`。

先說這份資料不能檢驗什麼。這是單一 *pull*——一個蒐集日、一個 `stream`、一次重複。跨 *pull* 的所有機制因此完全無法在此檢驗：共變異數調整的共識加權、`exact` 與 `near-duplicate` 診斷、三面向 *G-theory* 的變異成分、有效 *pull* 數、節 4.5 的 *RMSE* 比較，全都需要跨日、跨環境的重複收集。本節不觸及它們，也不對它們作任何宣稱。真正要檢驗完整設計，需要表 10 所述規格下為期一個月的收集計畫。此外，真實資料沒有 *latent truth*，因此無法計算重建誤差，兩個方法都不能被稱為較準確。

4.6.1 GT 的正規化會製造零資訊重疊

第一個發現是模擬器結構上產生不了的。GT 以該次請求視窗內的最大值正規化每個 `chunk`。若兩個視窗都涵蓋同一個峰值日，兩者就被同一個數除，取整後在重疊區逐格完全相同。本資料中 `C0001–C0003` 的最大值同為 2024-03-05、`C0004–C0005` 同為 2024-08-05、`C0007–C0008` 同為 2024-12-05，於是 26 條重疊 *edge* 中有 5 條的 *log ratio* 恆等於零且無離散度：8 個 `chunk` 實際上只構成 4 個正規化群。

這樣的 *edge* 不帶任何尺度資訊，卻仍以 `edge_variance_floor` 與 `max_edge_weight` 所允許的權重進入加權最小平方——那是數值安全常數，不是統計論證。`simulate_racergt_data` 在取視窗最大值之前先對每個 `chunk` 乘上連續的對數常態噪音；在其預設參數下，兩個 `chunk` 取整後逐格相同的機率微乎其微，實測 520 條模擬 *edge* 中零筆退化，真實資料 26 條中 5 筆。（把 `chunk_noise_sd` 設為 0 則模擬器也會產生退化 *edge*，但那不是它的預設，也不是先前證據所使用的設定。）1.4.0 因此在 `CalibrationResult.diagnostics` 新增 `n_zero_dispersion_edges`、`n_informative_edges` 與 `n_scale_groups` 三個鍵。它們只作報告，不改變任何估計值；退化 *edge* 的處理是使用者的判斷，本套件不代為決定。

退化率取決於數列的峰值結構，不可由單一關鍵字外推。機制本身是演繹的（共用視窗最大值 $\Rightarrow$ 重疊區同一組整數），但比例是實證問題。

4.6.2 比例假設在真實資料上成立

校準階段整個建立在「重疊的 chunk 至多差一個常數比例」之上。重疊長達 150 天，此假設被高度過度識別，可直接檢驗。

表 3: 真實資料上的校準診斷。bitcoin、美國、日頻、2024 年，8 個 chunk，單一 pull。

診斷量	數值
重疊圖是否連通	是
Edge 數 (spanning path 僅用 7 條)	26
獨立 cycle 數	19
可檢驗的三角形數	45
Normal matrix condition number	10.82
Weighted edge RMSE	0.001379
零離散度 edge	5 / 26
正規化群數	4 (共 8 個 chunk)
三角形閉合誤差中位數	0.001783 log points
三角形閉合誤差最大值	0.011769 log points (尺度誤差 1.184%)
重疊內漂移 $p < 0.05$ 的比例	1 / 21 (隨機期望 1.05)
校準後殘餘錯尺度最大值	-0.032% (無檢定力，見remark 4.4)

三角形閉合檢定是本框架相對逐段 stitching 的核心優勢之一，且逐段 stitching 在結構上無法提供：模型要求任意三個互相重疊的 chunk 滿足 $d_{ij} + d_{jk} = d_{ik}$ ，而 stitching 只使用路徑上的 edge，既看不到也報告不了違反。45 個三角形的閉合誤差中位數為 0.0018 log points，最大 0.0118 (相當於 1.18% 的尺度誤差)。21 條有效重疊中僅 1 條的漂移檢定 $p < 0.05$ ，隨機期望為 1.05。

說明 4.4 (這些診斷抓得到什麼、抓不到什麼). 一個「通過」的診斷，在未證明它有能力失敗之前不值任何東西。對單一 chunk 注入已知擾動再重跑，即可得出各檢定的最小可偵測效果。

表 4: 各診斷對 chunk C0005 已知擾動的反應。基準最大閉合誤差 0.0118，基準漂移條數 1 / 21。

注入的擾動	最大閉合誤差	漂移 $p < 0.05$	每 chunk 偏離
整體縮放，任意大小	0.0118 (無反應)	1 (無反應)	無
趨勢，每 100 天 2%	0.0232	7 / 22	無
非線性，2%	0.0118 (無反應)	5 / 22	無
非線性，5%	0.0212	5 / 22	無

每 chunk 偏離檢定的檢定力恰好為零，此處報告它只是為了指出這一點。把一個 chunk 整體乘上常數，會被 $\hat{\ell}_j$ 完全吸收， $Y_{jt} \exp(-\hat{\ell}_j)$ 分毫不動，故注入 2% 與 20% 得到逐位相同的數字。這不是估計量的缺陷——整體縮放本來就是參數而非違反——但它意味著表 3 中的 -0.032% 不構成任何證據。

Cycle 閉合與漂移檢定則確實有檢定力，且針對的是尺度吸收不掉的違反。漂移檢定較敏感，能抓到閉合檢定漏掉的 2% 非線性扭曲。以基準對照本表：觀測到的最大閉合誤差只有「每 100 天 2% 趨勢」所產生量的一半，因此該量級以上的違反可被排除——這是本資料所能支持的最強陳述，與「模型正確」並不相同。

4.6.3 模擬器的 chunk 噪音高估約 4.5 倍

這份資料無法檢驗 F1，卻能決定性地檢驗另一件事：模擬器描述得對不對。SimulationSettings 的 chunk_noise_sd 預設 0.03，在取最大值前對每個 chunk 每一天乘上獨立的對數常態擾動。真實資料的重疊 log ratio 離散度中位數為 0.0188。

以封閉式的整數捨入下限相減會得到 0，但那個下限假設兩個 chunk 獨立捨入。實際上兩者捨入的是只差一個尺度因子的同一組數字，捨入誤差高度相關，封閉式因而高估下限，並使推得的噪音偏向零——正是對本結論有利的方向。本文因此不採用它，改以參數化 bootstrap 直接重現生成機制：取校準後的日頻數列，乘上指定強度的 chunk 噪音，除以視窗最大值，取整，再用與真實資料完全相同的方式計算離散度。

表 5: 掃描 chunk_noise_sd 並與觀測到的重疊離散度 0.018814 比對。每格 200 次重複。

σ_{chunk}	重疊離散度中位數	對觀測值之比
0 (僅整數捨入)	0.017757	0.94
0.005	0.017644	0.94
0.0066 (配適值)	0.018814	1.00
0.010	0.021892	1.16
0.020	0.033624	1.79
0.030 (模擬器預設)	0.046424	2.47

僅整數捨入就解釋了觀測離散度的 94%；配適值為 $\sigma_{\text{chunk}} \approx 0.0066$ ，約為模擬器預設的 1/4.5。低於約 0.005 時曲線在 Monte Carlo 誤差內持平，捨入主導，該區間不可識別；但 0.03 會產生 2.47 倍於觀測值的離散度，可被明確排除。

這對節 4.5 的解讀是加強而非否定：該比較是在校準噪音被高估數倍的情境下進行的，而即使在那個對 F1 有利的情境中，全域圖仍未取得可偵測的精度優勢。以真實噪音水準重跑只會讓差距更小。

4.6.4 一年的 chunk 為何看不到 F1，以及 F1 何時開始重要

兩個方法在真實資料上幾乎不可區分：相關係數 1.000000，逐日相對差中位數 0.00026、最大 0.00123，在 0–100 的指數尺度上最大絕對差僅 0.195 點。

說明 4.5 (一個必須指出的方法錯誤). 以「兩方法點估計之差是否隨鏈位置成長」來檢驗 $F1$ 是錯的估計量。 $F1$ 是關於變異數的主張，而單一 *pull* 只提供一個 *realization*；由 $n = 1$ 無從估計變異數，該檢定的檢定力在建構上即為零，與資料量無關。命題 4.3 使抽樣完全不必要：變異數比即有效電阻比，是設計的確定性函數。

依命題 4.3 計算本設計：全域圖的最大 $\text{Var}(\hat{\ell}_j) = 1.01 \times 10^{-6}$ ，spanning path 為 9.26×10^{-6} ，** 降幅 9.13 倍 **，且降幅沿鏈位置單調成長 ($2.1 \times \rightarrow 9.1 \times$)。** $F1$ 的機制確實在運作 **，且其大小可精確算出，不需任何檢定。

但換算成絕對尺度，本設計下逐段 stitching 的終端誤差僅 0.40%、全域圖 0.12%。** 比值大、絕對值小 **，兩者並不矛盾——這正是一年設計看不到差異的原因，也是先前三次模擬實驗得到 null 的原因。

說明 4.6 ($F1$ 在本文建議的 protocol 下被預測為實質). 表 1 將誤差沿歷史跨度外推：15 年、180 日視窗、15 日步進——即表 10 所建議的規格——逐段 stitching 的終端尺度誤差約為 2.79%，全域圖約為 0.23%。對一條橫跨 15 年的注意力指數而言，此量級的端點尺度偏誤是一個緩慢漂移，形態上與趨勢難以區分，正是 *GT* 文獻反覆警告的 *artificial low-frequency drift*。remark 4.2 說明這兩個數字所依賴的前提；它們是命題 4.3 的預測，不是量測結果。

因此本文對 $F1$ 的正確陳述是：機制為真、可被證明（命題 4.3）、且被預測在建議規模下具實質意義；本文一年份的實測之所以看不到它，是因為該設計的絕對誤差上限只有 0.40%。節 4.5 與節 12 的 *null results* 並非 $F1$ 的反證，而是命題 4.3 的直接預測：在短鏈上有效電阻差距的絕對值必然微小。

這也修正了 remark 4.3 的解讀。先前三次的共同結論是「機制成立但效果二階」；命題 4.3 說明其中至少校準這一項並非二階，而是規模相依——效果隨接合數成長，而先前所有實驗都在效果最小的一端進行。全域圖校準值得採用的理由，除了表 3 中逐段 stitching 結構上無法提供的診斷之外，還有式 (20) 給出的無條件保證：它永不更差。

5 第二階段：跨 pull 相依性、duplicates 與量測可靠度

5.1 Exact duplicate audit

對每一 complete pull 的 numeric vector 以固定 decimal rounding 後計算 SHA-256。完全相同的向量不應從 raw archive 消失，因其 multiplicity、collection days、streams 與 raw-response hashes 本身就是 cache / 共同版本 / 重複執行的證據。RACER-GT 採雙層資料：

- audit set：保留所有 nominal pulls 與 exact duplicates；

- analytic unique-vector set：在 consensus covariance estimation 中，每個完全相同向量保留一個 representative，並另存 multiplicity map。

Chunk-level duplicates 與 full-series duplicates 應分別檢查；僅看完整向量可能漏掉部分 chunks 被重複回傳的情況。

5.2 Residual near-duplicate graph

原始 GT pulls 都共享相同的歷史訊號，因此 raw-series correlation 本來就會非常高。若以 raw correlation 作為共同抽樣或 cache dependence 的唯一依據，容易將正常的共同訊號誤判為依賴。RACER-GT 先定義 preliminary common signal

$$m_t = \text{median}_i Z_{it}, \quad (24)$$

再移除 pull-specific mean bias

$$b_i = \frac{1}{T} \sum_t (Z_{it} - m_t), \quad e_{it} = Z_{it} - m_t - b_i. \quad (25)$$

Near-duplicate edge 必須同時通過預先指定的 value-anchored rule，例如 raw correlation、exact-cell agreement、MAE/100、positive-day Jaccard，以及 residual correlation。Connected component 只表示成員透過 edge chain 連接，不表示 component 中每一對都相似；因此報告 density、diameter、maximum clique、articulation points、minimum within-component correlations 與 maximum MAE。

Near-duplicate graph 只作依賴診斷與 covariance 建模；除 exact numeric duplicates 外，RACER-GT 不因某 pull 偏離中位數或降低 reliability 而刪除它。

5.3 三面向 Generalizability Theory

令 $t = 1, \dots, T$ 為 historical dates， $d = 1, \dots, D$ 為 collection-day levels， $s = 1, \dots, S$ 為 streams， $r = 1, \dots, R$ 為 technical replicates。完全交叉隨機效果模型為

$$Y_{tdsr} = \mu + T_t + D_d + S_s + (TD)_{td} + (TS)_{ts} + (DS)_{ds} + (TDS)_{tds} + E_{tdsr}. \quad (26)$$

各隨機成分期望為零、彼此不相關，variance components 記為

$$\sigma_T^2, \sigma_D^2, \sigma_S^2, \sigma_{TD}^2, \sigma_{TS}^2, \sigma_{DS}^2, \sigma_{TDS}^2, \sigma_E^2.$$

RACER-GT 對三種轉換分別執行 G-study :

$$\text{Level: } Y_{tdsr}, \quad (27)$$

$$\text{Detection: } I(Y_{tdsr} > 0), \quad (28)$$

$$\text{Innovation: } \Delta \log(1 + Y_{tdsr}). \quad (29)$$

這樣可避免一個單一 ICC 混合「是否被偵測到」、「數值水準是否一致」與「日變化是否一致」。

對平均 n_D 個 collection days、 n_S 個 streams 與 n_R 個 replicates 的相對決策，誤差 variance 為

$$\sigma_\delta^2 = \frac{\sigma_{TD}^2}{n_D} + \frac{\sigma_{TS}^2}{n_S} + \frac{\sigma_{TDS}^2}{n_D n_S} + \frac{\sigma_E^2}{n_D n_S n_R}. \quad (30)$$

Generalizability coefficient [27] 為

$$G(n_D, n_S, n_R) = \frac{\sigma_T^2}{\sigma_T^2 + \sigma_\delta^2}. \quad (31)$$

若研究關心相對排名之外的絕對水準，還要加入 day、stream 與 DS effects :

$$\sigma_\Delta^2 = \sigma_\delta^2 + \frac{\sigma_D^2}{n_D} + \frac{\sigma_S^2}{n_S} + \frac{\sigma_{DS}^2}{n_D n_S}, \quad (32)$$

$$\Phi(n_D, n_S, n_R) = \frac{\sigma_T^2}{\sigma_T^2 + \sigma_\Delta^2}. \quad (33)$$

5.4 Balanced ANOVA 的 method-of-moments components

令 $a = T, b = D, c = S$ ，先對 R replicates 取 cell mean。Balanced ANOVA 的 expected mean squares 可寫為

$$\mathbb{E}(MS_{TDS}) = \sigma_E^2/R + \sigma_{TDS}^2, \quad (34)$$

$$\mathbb{E}(MS_{TD}) = \sigma_E^2/R + \sigma_{TDS}^2 + c\sigma_{TD}^2, \quad (35)$$

$$\mathbb{E}(MS_{TS}) = \sigma_E^2/R + \sigma_{TDS}^2 + b\sigma_{TS}^2, \quad (36)$$

$$\mathbb{E}(MS_{DS}) = \sigma_E^2/R + \sigma_{TDS}^2 + a\sigma_{DS}^2, \quad (37)$$

$$\mathbb{E}(MS_T) = \sigma_E^2/R + \sigma_{TDS}^2 + c\sigma_{TD}^2 + b\sigma_{TS}^2 + bc\sigma_T^2, \quad (38)$$

並對 D, S 對稱。因此 method-of-moments estimator 例如

$$\hat{\sigma}_{TD}^2 = \frac{MS_{TD} - MS_{TDS}}{c}, \quad (39)$$

$$\hat{\sigma}_T^2 = \frac{MS_T - MS_{TD} - MS_{TS} + MS_{TDS}}{bc}. \quad (40)$$

若 $R > 1$ ， MS_E 由 cell 內殘差估計，且

$$\hat{\sigma}_{TDS}^2 = MS_{TDS} - MS_E/R. \quad (41)$$

若 $R = 1$ ， E 無法分離，實作將不可分部分歸入 TDS 。負的 method-of-moments components 可報告原值並依 protocol 選擇截為零 [26]；正式推論應另用 REML sensitivity analysis。由於 historical dates 具時間相依，係數信賴區間採 moving-block bootstrap，而非把 T 天當成獨立單位。

D-study 將式 (31) and (33) 代入不同的 (n_D, n_S, n_R) ，直接回答「下一筆資源應投入增加日期、streams 或 technical replicates」。因此 nominal pull count 不是充分的停止規則。

6 第三階段：共變異數調整的潛在共識數列

6.1 Measurement model

將每一個 calibrated unique pull 在相同基準期重新設為平均 100 後，對歷史日 t 寫成

$$\mathbf{Z}_t = \mathbf{1}X_t + \mathbf{e}_t, \quad \mathbb{E}(\mathbf{e}_t) = \mathbf{0}, \quad \text{Var}(\mathbf{e}_t) = \Sigma. \quad (42)$$

$\mathbf{Z}_t$ 為 $m \times 1$ vector。Near duplicates 對應 Σ 中較高的 off-diagonal covariance；因此它們不應被簡單計為多份獨立 evidence。

說明 6.1 (從 θ_t 到 X_t 的橋接假設). 命題 2.3 與 2.4 的 *estimand* 是 GT 設計期望 $\theta_t(Q; \mathcal{R})$ ，而式 (42) 的 *estimand* 是共同尺度潛在訊號 X_t 。兩者不是同一個量，其連結需要兩個必須明示的條件。

第一是**比例性**：存在與 t 無關的 $c > 0$ 使 $\theta_t = cX_t$ ，亦即在固定 *protocol* 下 GT 的期望回傳值與潛在相對訊號成比例。這排除了隨時間變動的系統性演算法偏誤，而該假設不可由重複量測本身檢驗（見第 14.1 節的 *common-mode bias*）。

第二是**校準誤差可忽略**： $Z_{it} = Y_{it} \exp(-\hat{\ell}_{j(i)})$ 涉及估計量的非線性變換，一般而言 $\mathbb{E}[Y \exp(-\hat{\ell})] \neq a^{-1}\mathbb{E}[Y]$ ，因為 $\exp(\cdot)$ 為凸函數且 $\hat{\ell}$ 帶估計誤差。式 (21) 的一階修正使 $\mathbb{E}[\exp(-\hat{\ell}_j)] = a_j^{-1}\{1 + O(n^{-1})\}$ ，其中 n 為該 *chunk* 可用的重疊日數。因此式 (42) 的

$\mathbb{E}(\mathbf{e}_t) = \mathbf{0}$ 是 $O(n^{-1})$ 意義下的近似，不是精確結果。

命題 7.1 的無偏性與最小變異性應在這兩個條件下閱讀。本文不宣稱它們可由資料驗證：前者需要外部效標，後者隨重疊設計加密而改善。

說明 6.2 (為何預設不移除 pull-specific additive bias). 1.0.0 版預設在此處對每個 *pull* 減去 $b_i = T^{-1} \sum_t (Z_{it} - m_t)$ ，其中 m_t 為逐日中位數。但基準期重設已使每個 *pull* 滿足 $T^{-1} \sum_t Z_{it} = 100$ ；當基準期等於歷史全區間 (QuerySpec 的預設回填) 時，

$$b_i = 100 - \frac{1}{T} \sum_t m_t \quad (43)$$

對所有 i 相同。該步驟因此不移除任何 *pull* 之間的相對差異，只是把整條共識序列平移「平均數與中位數之差」，並直接違反式 (42) 的 $\mathbb{E}(\mathbf{e}_t) = \mathbf{0}$ 。在受控模擬中它使 *mean bias* 由機器精度惡化為 -0.1464 ，且 20 次重複的 *RMSE* 全部劣化。

1.1.0 版將 `center_pull_bias` 預設改為關閉，並在 *diagnostics* 輸出 `pull_bias_cross_pull_sd`——該值接近零即表示 *centring* 項不帶任何 *pull-specific* 資訊——使此退化情形保持可稽核。僅在關閉 *baseline rescale* 且確實預期存在加法性 *pull offset* 時，才應啟用該選項。

考慮線性共識 $\hat{X}_t = \mathbf{w}' \mathbf{Z}_t$ 。若 $\mathbf{1}' \mathbf{w} = 1$ ，則

$$\mathbb{E}(\hat{X}_t) = X_t, \quad (44)$$

而 variance 為 $\mathbf{w}' \Sigma \mathbf{w}$ 。

命題 6.1 (GLS 共識). 若 Σ 正定且已知，所有滿足 $\mathbf{1}' \mathbf{w} = 1$ 的線性無偏估計量中，

$$\mathbf{w}^* = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}' \Sigma^{-1} \mathbf{1}} \quad (45)$$

使 $\text{Var}(\hat{X}_t)$ 最小，且

$$\text{Var}(\hat{X}_t) = \frac{1}{\mathbf{1}' \Sigma^{-1} \mathbf{1}}. \quad (46)$$

證明. 建立 Lagrangian

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}' \Sigma \mathbf{w} - 2\lambda(\mathbf{1}' \mathbf{w} - 1).$$

一階條件 $2\Sigma \mathbf{w} - 2\lambda \mathbf{1} = 0$ ，故 $\mathbf{w} = \lambda \Sigma^{-1} \mathbf{1}$ 。代入 $\mathbf{1}' \mathbf{w} = 1$ 得式 (45)。正定 Σ 使目標嚴格凸，因此解唯一且為全域最小值。□

實務上 Σ 必須由有限歷史日的 *residual matrix* 估計。RACER-GT 預設使用 Ledoit-Wolf shrinkage，使 *covariance* 在 m 相對不小或 *residuals* 高度共線時仍可逆。為避

免 sampling error 造成負權重與極端 extrapolation，預設解下列 convex quadratic program：

$$\min_{\mathbf{w}} \mathbf{w}' \hat{\Sigma} \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}' \mathbf{w} = 1, \quad 0 \leq w_i \leq \bar{w}. \quad (47)$$

受限解保持 sum-to-one，因此在式 (42) 下仍線性無偏；但嚴格的 unrestricted BLUE 結論只適用式 (45)。權重上限是穩定化選擇，必須在 protocol 中預先鎖定。

若某日缺少少數 pulls，實作對當日可用權重重新正規化。條件式基礎標準誤為

$$\hat{se}_0 = \sqrt{\hat{\mathbf{w}}' \hat{\Sigma} \hat{\mathbf{w}}}. \quad (48)$$

為反映事件日可能具有較大跨 pull dispersion，1.0.0 版再以當日 absolute deviation median 相對於全期間 median 進行 bounded local multiplier。這是 pragmatic heteroskedastic adjustment，而非完整 Bayesian posterior interval；正式研究可另以 block bootstrap 重新執行全 pipeline。

6.2 有效 pull 資訊量

Nominal m 無法反映相依性。對 residual correlation matrix R_e ，RACER-GT 報告 spectral participation ratio

$$m_{\text{eff}}^{\text{spectral}} = \frac{\text{tr}(R_e)^2}{\text{tr}(R_e^2)}. \quad (49)$$

當所有 residuals 完全共線，只有一個非零 eigenvalue， $m_{\text{eff}} = 1$ ；當 residuals 相互獨立， R_e 趨近 I_m 而 m_{eff} 趨近 m 。

此處須注意一個實作層面的偏誤：式 (25) 的殘差是各 pull 減去由它們自己構成的逐日中位數，此運算必然在殘差間引入負相關，因此即使原始 pulls 完全獨立， R_e 也不會恰好是單位矩陣。以構造上獨立的序列模擬， $m = 9$ 時 m_{eff} 平均約 8.57（低估 4.8%）， $m = 3$ 時約 2.59（低估 13.7%）。偏誤方向是保守的——傾向低估資訊量因而傾向拒絕，而非誤放行——但這表示 min_spectral_effective_pulls 門檻的實際嚴格度略高於其名目值，在小型設計上尤然。此量是資訊濃度診斷，不是對 proprietary sampling mechanism 的正式獨立樣本數證明。

另報告 Kish weight count [21]

$$m_{\text{eff}}^{\text{Kish}} = \frac{1}{\sum_i w_i^2}, \quad (50)$$

用以觀察共識是否被少數 pulls 支配。

7 第四階段：日、週、月頻率一致化

僅以短視窗日頻 `chunks` 接合，可能保留日際形狀卻失去長期尺度；Eichenauer et al. (2022) 稱此為 `frequency inconsistency`。令 `preliminary daily consensus` 為 $z \in \mathbb{R}^T$ ，`lower-frequency benchmark` 為 $b \in \mathbb{R}^K$ ，`aggregation matrix` A 的第 k 列對 `benchmark period` k 內日資料給予平均權重。

RACER-GT 的 `soft benchmarking estimator` 定義為

$$\hat{x} = \arg \min_x (x - z)'Q(x - z) + (Ax - b)'W(Ax - b), \quad (51)$$

其中

$$Q = (\lambda_I + \lambda_R)I + \lambda_D D_1' D_1, \quad (52)$$

D_1 是 `first-difference matrix`；此問題屬於 `benchmarking` 文獻中 `movement-preservation` 一族 [13, 7, 12]。 λ_I 控制對 `preliminary signal` 的忠實度； λ_R 是實作中獨立設定的 `ridge`，其唯一作用是在 $\lambda_I = 0$ 時仍保證 Q 正定，因此兩者在數學上合併為單一係數； λ_D 控制修正路徑的粗糙度， W 通常由 `benchmark standard errors` 的倒數平方組成。

一階差分懲罰的是修正路徑的斜率而非其曲率。預設的 $\lambda_D/\lambda_I = 10$ 是一個相當強的平滑先驗，會使修正趨向低頻調整，在事件日附近可能系統性削弱日頻形狀——而事件日正是注意力指標最有研究價值的部分。此比值應在 `pilot` 階段校準並鎖定，正式研究亦應報告 $\lambda_D/\lambda_I \in \{1, 10, 100\}$ 的敏感度。

命題 7.1 (`Soft benchmark` 的唯一解). 若 Q 正定且 W 半正定，式 (51) 嚴格凸，唯一解為

$$\hat{x} = z + (Q + A'WA)^{-1}A'W(b - Az). \quad (53)$$

證明. 對式 (51) 取 `gradient` 並令其為零：

$$Q(x - z) + A'W(Ax - b) = 0.$$

整理得 $(Q + A'WA)x = Qz + A'Wb$ ，等價於式 (53)。 Q 正定使 $Q + A'WA$ 正定，因此解唯一。 $\square$

若 `benchmark` 被視為無誤差硬約束，可解

$$\min_x (x - z)'Q(x - z) \quad \text{s.t.} \quad Ax = b, \quad (54)$$

其 KKT system 為

$$\begin{bmatrix} Q & A' \\ A & 0 \end{bmatrix} \begin{bmatrix} \delta \\ \lambda \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{b} - A\mathbf{z} \end{bmatrix}, \quad \hat{\mathbf{x}} = \mathbf{z} + \delta. \quad (55)$$

Soft mode 更適合 GT benchmark 本身也有 sampling variation 的情況；exact mode 可作 sensitivity analysis。若 nonnegative projection 被啟用，投影後聚合等式可能略受影響，故程式會報告 projection 是否發生。

8 可靠度指標與預先鎖定的 decision tree

8.1 Detection、level 與 innovation

RACER-GT 不以一個單一相關係數概括資料品質。Detection reliability 包括 zero/nonzero agreement、positive-day Jaccard 與 Fleiss' κ [15]；當所有觀察都屬同一類別時， κ 不可識別，此規則標記為 not applicable，而非錯誤判 FAIL。Level reliability 包括 Pearson、Spearman、MAE/100、G 與 Φ ；innovation reliability 則對 $\Delta \log(1 + Y)$ 計算 correlation、sign / peak overlap 與 G-study。

Exact-cell agreement 必須與 zero share 一起解讀。兩條低量序列若多數日都為零，可能得到很高 exact agreement，卻沒有足夠正值資訊；因此 decision tree 另設 maximum zero share，並檢查 positive Jaccard。

8.2 Acceptance rules

一個正式 batch 的 PASS 至少需滿足以下預先指定規則：

1. query、historical endpoints、chunks 與 protocol hash 完整一致；
2. 每個 complete pull 的 overlap graph 可識別且連通；
3. unique pulls 與 spectral effective pulls 達到門檻；
4. zero share 未超過門檻；
5. level 與 innovation G 達到門檻；
6. near-duplicate component 不支配全批資料；
7. 隨 pulls 增加的 consensus convergence MAE/100 低於門檻；
8. 若使用 benchmark，standardized benchmark RMSE 低於門檻。

若任一 mandatory rule 明確失敗，狀態為 FAIL；若沒有失敗但有不可判定 mandatory rule，狀態為 REVIEW；全部通過才是 PASS。PASS 的意義是「允許依鎖定 protocol 建構此相對指標」，不是 construct validity、外部效度或因果識別的證明。

關鍵詞／Topic 的 construct validity 必須另行檢查：語意與語言版本、可能的非財金用途、歷史首次合理出現時間、主要 peaks 的事件對應、搜尋量是否足夠，以及不同替代 terms 的結果是否一致。測量可靠而構念錯誤的指標仍然沒有研究效度 [19]。

9 下游財金模型的 measurement-error correction

9.1 Attenuation bias

令真正的注意力訊號 X_t 進入財金模型

$$Y_{t+h} = \alpha + \beta X_t + \gamma' C_t + \varepsilon_{t+h}, \quad (56)$$

但研究者觀察

$$W_t = X_t + u_t, \quad \mathbb{E}(u_t \mid X_t, C_t, \varepsilon_{t+h}) = 0. \quad (57)$$

在無 controls 的 classical homoskedastic case，naive OLS 滿足

$$\text{plim } \hat{\beta}_{\text{naive}} = \beta \frac{\sigma_X^2}{\sigma_X^2 + \sigma_u^2}, \quad (58)$$

故係數向零衰減。

令 $M_C = I - C(C'C)^{-1}C'$ 為 controls residual-maker。若 measurement-error covariance Ω_u 已知，則

$$\mathbb{E}(W' M_C W) = X' M_C X + \text{tr}(M_C \Omega_u). \quad (59)$$

因此 moment-corrected estimator 為

$$\hat{\beta}_{RC} = \frac{W' M_C Y}{W' M_C W - \text{tr}(M_C \hat{\Omega}_u)}. \quad (60)$$

RACER-GT 使用每日 consensus standard error 的平方形成 diagonal $\hat{\Omega}_u$ ，並以 Newey–West long-run variance [24] 對 scalar moment 提供 HAC standard error。若修正後分母非正，套件拒絕估計，因為在該假設下 latent predictor variation 不足以識別 β 。

9.2 SIMEX

當誤差標準差可估計但解析修正不穩定時，SIMEX [8, 28, 4] 對 $\lambda \geq 0$ 人工加入

$$W_t^{(b,\lambda)} = W_t + \sqrt{\lambda} \hat{\sigma}_{u,t} \xi_t^{(b)}, \quad \xi_t^{(b)} \sim N(0, 1), \quad (61)$$

估計 $\hat{\beta}(\lambda)$ 後，以二次曲線外推至 $\lambda = -1$ ，模擬移除 measurement error。SIMEX 對 extrapolation form 敏感，因此應與式 (60)、sample-specific pull regressions 與 full-pipeline bootstrap 並列報告，而非只選擇較顯著者。

10 完整演算法

Algorithm 1 RACER-GT 長期日頻指標建構

Require: Locked query Q ; balanced retrieval design ; fixed chunks ; raw responses ; optional lower-frequency benchmark

Ensure: Final daily index 、measurement uncertainty 、audit trail 、acceptance decision

- 1: Canonicalize protocol ; 計算 hash ; 產生 collection schedule 與 chunk manifest
 - 2: 蒐集並保存所有 raw responses ; 記錄 day 、stream 、replicate 、time 、order 、network events 與 hashes
 - 3: Audit historical endpoints 、query parameters 、chunk boundaries 、partial observations 與 missing chunks
 - 4: for each complete pull i do
 - 5: 由 usable overlaps 計算 robust log-ratio edges
 - 6: 建立 overlap graph ; 若不連通依 protocol FAIL / REVIEW
 - 7: 解 graph WLS 取得 chunk log scales 與 covariance
 - 8: 校準所有 chunks ; 以 inverse-variance / Huber / median 聚合同日值
 - 9: 依固定 baseline 將 pull index 平均設為 100
 - 10: end for
 - 11: 依預先指定 design-cell weights 計算 $\hat{\theta}_t^\pi$ 作為 design-based reference
 - 12: 保留 exact duplicate audit ; 建立 analytic unique-vector set
 - 13: 由共同中位數與 pull bias 形成 residuals ; 建立 near-duplicate graph
 - 14: 對 level 、detection 、innovation 執行 crossed-facet G-study 與 D-study
 - 15: 估計 residual covariance $\hat{\Sigma}$; 解受限或無限制 GLS latent consensus
 - 16: 計算 conditional standard errors 、spectral/Kish effective counts 與 convergence path
 - 17: if lower-frequency benchmark available then
 - 18: 解 soft / exact temporal benchmarking problem
 - 19: end if
 - 20: 執行 locked decision tree ; 輸出 PASS / REVIEW / FAIL
 - 21: 將 final index 與 uncertainty 輸入下游 EIV correction / SIMEX
-

11 Python 套件實作

11.1 設計原則

RACER-GT 1.0.0 採 ingestion-first architecture：統計套件不內建未經官方保證的網站 scraping。網站端點、rate limits、認證與服務條款可能變動，將 retrieval client 與估計器解耦，可使研究者在官方 API、手動 CSV export 或機構核准的 collector 間替換，而不改變統計 protocol。Collector 只需輸出固定 long-format schema。

核心模組如表 6。

表 6: RACER-GT 1.0.0 模組

模組	功能
config.py	Pydantic protocol schema、欄位驗證、canonical serialization 與 SHA-256 hash。
design.py	固定 overlap windows、balanced stream/time/chunk order 與 protocol bundle。
audit.py	Historical-window drift、query drift、partial data、missing chunks 與 metadata ambiguity。
overlap.py	Huber edge estimator、graph connectivity、WLS scale solution、condition diagnostics 與 calibrated pull aggregation。
duplicates.py	Exact vector hashes、value-anchored pair metrics、residual near-duplicate graph、components/cliques/articulation diagnostics。
gstudy.py	Balanced $T \times D \times S$ ANOVA、variance components、 G/Φ 、D-study 與 moving-block bootstrap。
consensus.py	Design-cell weighted reference、exact-collapse map、baseline rescale、Ledoit–Wolf covariance、GLS / constrained weights、effective pull counts 與 uncertainty。
benchmark.py	Sparse aggregation matrix、soft quadratic benchmark 與 exact KKT benchmark。
reliability.py	Pairwise level/innovation metrics、Fleiss kappa、day/stream dependence 與 sequential convergence。
decision.py	可稽核的 PASS/REVIEW/FAIL decision tree。

模組	功能
<code>eiv.py</code>	Reliability-corrected OLS、HAC inference 與 quadratic SIMEX。
<code>simulation.py</code>	含 latent dynamics、day/stream effects、correlated retrieval noise、chunk normalization、rounding 與 exact duplicates 的 DGP。
<code>validation.py</code>	Single pull、mean、median 與 RACER-GT 的 Monte Carlo 比較。
<code>pipeline.py</code>	End-to-end orchestrator 與完整輸出保存。
<code>cli.py</code>	design、audit、run、simulate、export-stata。

11.2 最小使用範例

```
import pandas as pd
from racergt import RacerGTConfig, RacerGTPipeline

config = RacerGTConfig.load_yaml("protocol.lock.yaml")
raw = pd.read_csv("raw_chunks.csv")
benchmark = pd.read_csv("benchmark.csv")

result = RacerGTPipeline(config).fit(raw, benchmark=benchmark)
result.save("results")

print(result.decision.status)
design_reference = result.design_consensus.consensus
final_gt = result.final_series
```

CLI：

```
racergt design examples/config_example.yaml --out protocol_bundle \
  --anchor-date 2026-08-01
racergt audit protocol_bundle/protocol.lock.yaml raw_chunks.csv
racergt run protocol_bundle/protocol.lock.yaml raw_chunks.csv \
  --benchmark benchmark.csv --out results
```

每一次 run 產生 design-weighted reference、final latent series、calibration scales、edge residuals、duplicate groups/components、pull covariance、weights、G-study tables、reliability/convergence、benchmark fit、decision tree 與 diagnostic report。所有中間結果可供 replication，而不是只輸出一條無法稽核的平滑序列。

12 Monte Carlo 驗證

12.1 資料生成過程

本文隨套件提供可重現 simulation。基礎 latent intensity 為

$$L_t = 30 + 0.004t + 2.5 \sin(2\pi t/7) + 4 \sin(2\pi t/365.25) + u_t + \sum_{q=1}^6 \text{Spike}_{qt}, \quad (62)$$

其中 $u_t = 0.92u_{t-1} + \eta_t$ 、 $\eta_t \sim N(0, 1.8^2)$ ，並加入六個非對稱衰減事件尖峰。真實 index 依研究期平均設為 100。

對 collection day d 與 stream s ，pull-level log error 為

$$\zeta_{it} = a_d + b_s + 0.5g_{dt} + 0.5h_{it}, \quad (63)$$

其中 $a_d \sim N(0, 0.025^2)$ 、 $b_s \sim N(0, 0.020^2)$ ， g_{dt} 與 h_{it} 分別是具持續性的 shared-day 與 idiosyncratic AR noise。每個 chunk 再加入 $N(0, 0.03^2)$ multiplicative noise，並依 chunk maximum 正規化為 0–100 後四捨五入。10% 的 nominal pulls 複製完整 latent realization 與 raw chunks，以模擬 exact cache/version duplicates。週、月 benchmark 由真實 index 的 period average 加入已知噪音產生。

Monte Carlo 使用 2024 年 366 個日資料、三個 collection days (0、1、7)、三 streams、120-day chunks、30-day steps，共 20 次 replications，seeds 1200–1219。這是程式驗證 DGP，不是對 Google proprietary mechanism 的宣稱。

12.2 比較設計：資訊集必須對齊

`PipelineResult.final_series` 在 benchmark 可用時回傳 benchmark 後的序列。若以該序列與「未接受 benchmark 的跨 pull 基準」相比，比較的就不是四個估計量，而是三個估計量與一個估計量加上一組額外的低頻資訊——尤其在模擬中，benchmark 由 latent truth 的期間平均加白噪音生成，資訊量極高。

因此每個估計量都在兩個資訊集下各評估一次：僅使用校準後的 complete pulls，以及套用完全相同的週頻與月頻 benchmark。single pull 一系列報告的是所有 pull 各自表現的平均，而非固定取某一個 pull，因為後者代表「恰好取到那一個 pull」而非「只下載一次的期望表現」。

12.3 結果

表 7: 20 次受控 Monte Carlo 結果 (seeds 1200–1219)。MCSE 為平均 RMSE 的 Monte Carlo 標準誤。

Estimator	Benchmark	RMSE	MCSE	MAE	Bias	Corr.	Innov. corr.
Single pull	無	7.3519	0.0573	5.6770	−0.0000	0.9688	0.8878
Cross-pull median	無	4.1710	0.0819	3.1973	−0.1464	0.9898	0.9556
Simple mean	無	3.7253	0.0877	2.8660	−0.0000	0.9919	0.9747
RACER-GT	無	3.7421	0.0894	2.8723	+0.0000	0.9918	0.9743
Single pull	有	6.9881	0.0491	5.3877	−0.0041	0.9717	0.8882
Cross-pull median	有	3.9584	0.0695	3.0283	−0.1311	0.9908	0.9558
Simple mean	有	3.5058	0.0754	2.6889	−0.0041	0.9928	0.9748
RACER-GT	有	3.5226	0.0770	2.6959	−0.0041	0.9927	0.9745

表 8: 配對比較。差值為估計量 B 減估計量 A 的 RMSE，正值表示 A 較優； $n = 20$ 配對。

估計量 A	估計量 B	差值	t	p	A 勝場
RACER-GT	Single pull	+3.6098	48.31	2.4×10^{-21}	20/20
RACER-GT	Cross-pull median	+0.4289	14.86	6.5×10^{-12}	20/20
RACER-GT	Simple mean	−0.0167	−1.49	0.152	7/20
RACER-GT (有 bm.)	Simple mean (有 bm.)	−0.0168	−1.65	0.116	7/20
RACER-GT (有 bm.)	RACER-GT (無 bm.)	+0.2194	15.49	3.1×10^{-12}	20/20
Simple mean (有 bm.)	Simple mean (無 bm.)	+0.2195	15.45	3.3×10^{-12}	20/20

由表 7 and 8 可得三項結論，其中兩項支持本框架，一項不支持。

第一，跨 pull 聚合的價值大且穩健。在同一資訊集下，RACER-GT 相對單一 pull 的 RMSE 降低

$$1 - \frac{3.7421}{7.3519} = 49.1\%, \quad (64)$$

20 次重複全部改善（配對 $t = 48.3$ ）。相對 cross-pull median 亦降低 10.3%，同樣 20 次全勝。這回答了本文的核心動機問題：只下載一次確實不夠。

第二，共變異數調整加權相對簡單平均，在本 DGP 下沒有可偵測的優勢。兩者相差 −0.0167 ($p = 0.152$ ，20 次中 RACER-GT 僅勝 7 次)，加入 benchmark 後結論不變 (−0.0168， $p = 0.116$)。本文不宣稱 GLS 權重在此情境下較優。

第三，temporal benchmarking 有獨立且顯著的貢獻。在估計量固定時，加入週／月頻 benchmark 使 RMSE 降低約 0.22 ($p \approx 3 \times 10^{-12}$ ，20 次全勝)，且對 RACER-GT 與 simple mean 的效果幾乎相同 (0.2194 對 0.2195)。頻率一致化的收益來自 benchmark 本身，而非它與哪一個日頻估計量搭配。

說明 12.1 (一個可檢驗的預測). 第二點是負面結果。它最自然的解釋是本模擬的跨 pull 依賴結構過於同質：所有 pull 以固定權重 0.5 共享同一 collection-day 噪音，因此殘差

共變異數矩陣近乎等相關，而等相關矩陣的最小變異權重本來就是等權，*GLS* 沒有可利用的結構，只能在估計噪音上吃虧。

若此解釋成立，則當依賴強度在 *pulls* 之間不同時——例如部分 *pull* 來自同一 *cache* 而其餘不是——*GLS* 應當勝出。這是一個可檢驗的預測，節 12.4 直接檢驗它。

12.4 依賴異質性的直接檢驗

`examples/run_dependence_experiment.py` 讓一部分 *pull* 額外共享一條 *cache* 噪音。成員身分跨越 *collection day* 與 *stream*，因此該依賴無法被設計因子吸收，只能由殘差共變異數發現——這正是 *GLS* 權重存在的理由。`cache_cluster_fraction` 為零時的資料與表 7 使用的完全相同（逐位元一致），因此兩節的數字可直接比較。

表 9: 依賴異質性四情境，各 20 次重複。優勢欄為 *simple mean* 減 *GLS* 的 RMSE，正值表示 *GLS* 較優。

情境	GLS	Simple mean	Median	優勢	MCSE	<i>p</i>	GLS 勝場
同質（基準）	3.7421	3.7253	4.1710	-0.0167	0.0112	0.152	7/20
1/3 pulls，中度	3.7658	3.6801	4.1133	-0.0857	0.0155	< 0.0001	2/20
1/3 pulls，強	4.1684	4.1980	4.6486	+0.0296	0.0439	0.508	10/20
1/2 pulls，強	5.1633	4.8802	5.5593	-0.2831	0.0591	0.0001	2/20

預測不成立。*GLS* 在四個情境中沒有任何一個顯著勝出：最接近的一個（1/3 pulls、強依賴）優勢為 +0.0296 但 $p = 0.51$ 、勝場恰為 10/20，等同平手；另外兩個情境 *GLS* 顯著較差。異質性增加並未使排序反轉。

兩項診斷排除了對此結果的兩種誤讀。

第一，約束不是原因。在 1/3 pulls、強依賴情境下解除約束後（10 次重複）：受限預設解、解除上限解與完全無約束解的平均 RMSE 都是 4.1752，三者逐位相同，因為無約束解本來就落在可行域內；改用 *empirical covariance* 為 4.1785，*diagonal* 為 4.2345，同期 *simple mean* 為 4.2415。理論上為 *BLUE* 的無約束 *GLS* 同樣沒有勝出。

第二，機制運作正確。每個 *pull* 的平均殘差相關與其獲得的 *GLS* 權重之相關係數為 -0.562（10 次重複全部為負）。*GLS* 確實找到了共享依賴的 *pulls* 並降低其權重，方向完全正確。表 9 的 *weight dispersion* 亦隨異質性單調上升（0.0220 → 0.0409），*spectral effective pull* 數則單調下降（4.93 → 2.95），兩者都正確反映了依賴的增加。

剩下的解釋是估計誤差： Σ 必須由 9 個 *pull* 與 366 個歷史日估計，其誤差對權重造成的擾動，大於利用真實依賴結構所能換得的效率增益。這與投資組合文獻長期以來的發現一致——樣本共變異數下的 *minimum-variance* 組合在小樣本時並不優於等權，*Ledoit-Wolf shrinkage* [22] 正是為緩解此問題而提出，本實作已預設採用而結論未變。

說明 12.2 (這個負面結果改變什麼、不改變什麼). 不改變的是理論： Σ 已知時 *GLS* 仍是最小變異線性無偏估計量（命題 7.1），該推導不依賴任何模擬。改變的是實務建議：在本文建議的設計規模下（21–42 *pulls*、單一年度），不應期待共變異數調整帶來可偵測的點估計改善，*simple mean* 是同樣合理的主結果選擇。

也不改變的是共變異數調整的診斷價值。上述 *spectral effective pull* 數由 4.93 降至 2.95，正確地告訴研究者「這 9 個 *pull* 現在只值約 3 個」——*simple mean* 無法提供這個判斷，也無法提供 *near-duplicate* 依賴結構、每日條件標準誤，以及可傳遞至下游 *EIV* 修正的測量不確定性。*RMSE* 無法回答「這批資料是否可用」，而那正是本框架的主要目的。

說明 12.3 (偏誤欄的解讀). *Single pull* 與 *simple mean* 的 *mean bias* 是 10^{-15} 量級，這是恆等式而非估計性質：每個 *complete pull* 都被正規化為基準期平均 100，而真值亦以同一基準期平均 100 定義，故其平均必然無偏。*RACER-GT* 的偏誤同樣落在機器精度內 ($+3.2 \times 10^{-17}$)。*Cross-pull median* 的 -0.1464 則是真實的：逐日中位數在右偏分布下系統性低於平均數，而本 *DGP* 含六個事件尖峰。




圖 2: 各估計量在兩個資訊集下的平均 RMSE，誤差棒為 Monte Carlo 標準誤。同一估計量兩根柱體的差距即 *temporal benchmarking* 的貢獻。




圖 3: Level correlation、innovation correlation 與 top-5% peak recall。三項指標上 RACER-GT 與 simple mean 實質相同，與表 8 的檢定結果一致。

這些模擬只驗證程式在一組已知 DGP 下的行為。節 12.4 已就 shared dependence 這一個維度做了 factorial 檢驗，其餘維度尚未涵蓋：正式論文應針對實際關鍵字的 zero share、波動性與 sample size 重新設計，至少改變 sampling noise、rounding/censoring、graph sparsity、structural breaks、benchmark noise、exact-duplicate fraction 與 covariance misspecification。

13 建議的正式實驗規格

若研究目標是 2010–2026 年單一主題的日頻 GT 指標，建議的 confirmatory protocol 如表 10。表中門檻是合理起點，不是跨研究普遍常數；應在不查看財金 outcome 的 pilot simulation 中校準，再鎖定。

表 10: 建議的正式 RACER-GT protocol

項目	建議設定與理由
Historical window	固定 2010-01-01 至明確 month-end；Day 0–30 不可使用 expanding end date。
Daily chunks	先以約 180 日 window、15–30 日 step 建立密集 overlap；實際回傳頻率需程式驗證。
Collection days	0、1、2、7、14、21、30，以同時觀察短期 cache/版本相似與較長期穩定度。
Streams	至少三個固定 composite environments；平衡 stream order 與 time slot。

項目	建議設定與理由
Replicates	最佳為每個 day $\times$ stream 兩次，產生 42 pulls；若資源限制為 21 pulls，明確承認 pure error 不可分離。
Raw archive	保存 response、numeric vectors、retrieval timestamp、query metadata、protocol hash、network events 與 client version。
Overlap calibration	Huber edges + global graph WLS；圖不連通原則上 FAIL，不以人工比例硬接。
Duplicates	Exact vectors 只在 analytic covariance 中 collapse；audit set 永久保留。Near duplicates 不刪除。
G-study	分別估 level、detection、innovation；以 28-day moving-block bootstrap 估 interval。
Consensus	Ledoit–Wolf covariance；非負 weights；weight cap 0.5 作預設，另報 unrestricted sensitivity。
Frequency benchmark	以多次擷取後的 weekly/monthly consensus 及其 SE 進行 soft benchmark；exact mode 作 robustness。
Stop rule	Unique count、spectral effective count、 G/Φ 、convergence 與 component concentration 共同決定，不以 nominal 21 為充分條件。
Downstream model	主結果使用 final consensus；另以 sample-specific pulls、RC-OLS、SIMEX 與 full-pipeline bootstrap 檢查。

14 限制、敏感度分析與可延伸方向

14.1 無法由統計設計消除的限制

第一，若 Google 對所有 pulls 施加相同且隨時間變動的系統性演算法偏誤，重複量測無法僅靠平均或 GLS 識別；這是 common-mode bias。可利用 API overlap period、外部搜尋資料、新聞／交易事件與不同 query formulations 進行 external validation，但仍不是絕對真值。

第二，零值可能混合真實零搜尋、privacy threshold、sampling 與 rounding。RACER-GT 1.0.0 將零值保留並分離 detection reliability，但尚未內建 interval-censored latent count likelihood。對高 zero-share term，降為週頻、改用較廣 Topic 或 anchor-bank calibration，通常比強制製造日頻值更合理。

第三，G-theory 的 balanced method-of-moments 易於解釋，卻在 unbalanced missingness、負 variance components 或非 Gaussian binary detection 下不如 generalized linear mixed models。正式論文可將本實作作 preregistered primary estimator，再以 REML / Bayesian hierarchical model 作 robustness。

第四，benchmark 後的 1.0.0 信賴區間主要保留 cross-pull measurement uncertainty，尚未完整傳播 benchmark noise、scale calibration uncertainty 與 tuning-parameter uncertainty。最嚴謹方式是 nested moving-block bootstrap：每次重抽 historical blocks、重新估 edges、scales、duplicates、covariance、weights 與 benchmark，最後再重估財金模型。

第五，取得端的 rate limit 是一個實質約束，且它會反噬設計本身。本文第 12 節建議的 protocol (2010 年起、180 日 window、15–30 日 step、21–42 pulls) 隱含的請求量並不小：以 15 日 step 計，單一 pull 需 393 個 chunks，而每個 chunk 需要兩次請求 (explore 取 token、widgetdata 取數值)，故一個 pull 即為 786 次請求，21 pulls 為 16,506 次、42 pulls 為 33,012 次。在 20 秒的保守請求間隔下，這分別是約 92 與 183 小時的連續取得時間；即使是單一 pull 也需約 4.4 小時。

而 Google Trends 對此有嚴格限流。作者在一次測試中，explore 端點回傳 200，但第二次 widgetdata 請求即回傳 HTTP 429，等待 30 秒後重試仍為 429。單一觀察不足以量化 Google 的限流政策——它可能隨 IP、時段、帳號狀態與請求模式而異——但已足以說明取得可行性不是可以略過的工程細節。

限流亦不限於程式化存取。同一時段以一般瀏覽器（已登入、人工導航）開啟 Trends 網頁時，網頁自身前端發出的 widgetdata 請求同樣回傳 429，而頁面圖表卻正常顯示——顯示的是快取內容。這對研究者有直接的操作意涵：Trends 前端會以快取遮蔽失敗的請求，使用者無法從畫面判斷所見數列是否為本次取得的結果。任何以手動匯出為取得途徑的協定，都必須獨立記錄 response 狀態與 raw_response_hash，而不能以「圖表有顯示」作為取得成功的判準；adapter contract 要求保存原始 response 的理由於此更為明確。

真正的問題不在等待時間，而在第 4 節對 collection_day 的定義：它是「一次完整歷史重建」所對應的序數層級，而 G-theory 的 D facet 與式 (30) 的 σ_{TD}^2 都建立在這個層級上。若一次完整重建需時 4.4 小時且會被限流反覆中斷，該 pull 究竟屬於哪一個 collection day 便不再明確；跨越午夜的 pull 更會同時觸及 Djorno et al. (2026) 所述的 cache 重置邊界 (remark 3.1)，使得同一個 pull 內部的 chunks 來自兩個不同的抽樣批次。這不是量測誤差，而是 facet 定義的失效。

本文因此建議：正式研究應先以 `examples/collect_google_trends.py --preview` 估算請求預算，再據以決定 `historical window` 與 `step`，使單一 `pull` 的取得時間短於 `cache` 週期。以單一年度、180 日 `window`、30 日 `step` 計，一個 `pull` 僅需 8 個 `chunks`、16 次請求，可在數分鐘內完成——這才是使 `collection day` 保持為良定義 `facet` 的設計。以 16.6 年的窗長搭配 15 日 `step`，在目前的限流下並不可行，本文先前未指出這一點。

第六，受限 `GLS weights` 的穩定性優於 `unrestricted inverse covariance`，但其最佳性取決於預先指定 `constraint set`。應報告 `diagonal covariance`、`empirical covariance`、`Ledoit-Wolf`、`unrestricted GLS`、`equal weights` 與 `median` 的 `sensitivity table`。

第七，真實資料的驗證目前只覆蓋校準階段。節 4.6 使用的是單一 `pull`，因此第二階段以後的每一個機制——共識加權、`duplicate` 診斷、`G-theory` 變異成分、可靠度指標、`benchmark`——在真實 `Google Trends` 資料上全部未經檢驗，其證據仍完全來自模擬。而表 5 已顯示模擬器在校準階段高估了 `chunk` 噪音約 4.5 倍，這使得「模擬器在其他階段的參數是否同樣失真」成為一個開放且重要的問題：若跨 `pull` 的 `retrieval noise`、`day effect` 或 `stream effect` 也被高估，則節 12 的相對表現數字同樣需要重新檢視。本文不宜稱模擬證據可外推至真實資料的跨 `pull` 行為。要填補這個缺口，需要跨蒐集日、跨環境的重複收集；表 10 的規格下，3 個 `stream` × 7 個蒐集日 = 21 個 `pull`、168 次下載，是一個月日曆時間可完成的設計。

14.2 必要的穩健性檢驗

1. 不同 `chunk lengths`、`steps`、`positive thresholds` 與 `reference strategies`；
2. `Huber`、`median` 與 `inverse-variance within-pull aggregation`；
3. `Exact duplicate collapse` 與 `multiplicity-weighted sensitivity`；
4. `Raw-rule`、`residual-rule thresholds` 與 `complete-linkage` / `maximal-clique diagnostics`；
5. `G-study negative-component truncation` versus `REML`；
6. `Consensus covariance estimators` 與 `weight caps`；
7. `Soft` versus `exact benchmark`，不同 `fidelity/smoothness weights`；
8. 最新 `vintage` 與多個 `historical vintages`；
9. `Topic` versus `search term`、語言變體與非投資搜尋意圖排除；
10. 財金模型中的 `lag structure`、`UTC` / 市場時區、週末聚合與 `publication delay`。

14.3 與既有方法的關係

RACER-GT 並非取代既有研究，而是把其可互補部分放入同一個測量框架。就實證比較而言，本文只直接比較了逐段 stitching（節 4.5），結果是機制成立但精度差異不顯著；West（2020）的 anchor bank 需要多組 query 才能運作，Djorno et al.（2026）的 preprocessing 以下游預測準確度為評估標準，兩者都無法在本文的單一 series、以 latent truth 為基準的模擬下直接比較。因此本文不宜稱相對這些方法具有精度優勢；已建立的是相對「只下載一次」的大幅改善，以及一組其他方法未提供的診斷輸出。

Eichenauer et al.（2022）提供 repeated draws 與 frequency consistency 的核心洞見；Bleher and Dimpfl（2022）說明高頻長期 knitting；West（2020）以 anchor bank 處理跨 query common scale 與 rounding；Cebrián and Domenech（2024）指出 repeated pulls 的誤差與熱門程度密切相關；Medeiros and Pires（2021）提醒單一 GT realization 可使 forecasting conclusion 偶然改變。RACER-GT 的新增層次在於：將 retrieval 本身明確設計為交叉測量實驗，以 graph GLS 解 within-pull scale，以 G-theory 決定蒐集資源，以 residual covariance 對相依 pulls 降權，再把 measurement uncertainty 傳至下游財金估計。

15 結論

長期日頻 GT 的核心問題不是「下載幾次才算獨立」，而是如何在無法觀察 proprietary sample assignment 的條件下，定義可識別 estimand、控制 retrieval design、估計分段尺度、分解誤差來源、處理相依量測，並將不確定性保留到財金模型。RACER-GT 的基本立場是：

不以 IP 取代獨立性證明；不以多數決刪除不一致 pulls；不以單一相關係數代表可靠度；不把通過資料品質決策誤稱為 construct validity；也不在下游模型中假裝建構後的 GT 沒有測量誤差。

在明列假設下，全域 overlap-graph WLS 可識別相對 chunk scales；G-theory 可量化 collection day、stream 與其交互作用；GLS 可依 residual covariance 將高度相依 pulls 自動降權；temporal benchmarking 可使日頻形狀與較低頻率尺度相容；EIV correction 則能處理 GT 作為解釋變數時的 attenuation。

受控模擬給出的是混合結果：在本文 DGP 中，跨 pull 聚合（相對單一 pull 降低 49.1%）與 temporal benchmarking（另降低約 0.22）都有大且穩健的貢獻，而共變異數調整加權相對簡單平均則沒有可偵測的優勢。本文選擇完整報告這個負面結果，而不是只呈現有利的比較——這正是全文立場的具體實踐：研究價值不在於某一個較小的誤差數字，而在於一套可以預先註冊、稽核、重現、否決自身資料，並誠實傳遞不確定性

(包含對自己不利的證據) 的測量制度。一個只會產出好看數字的測量流程，無法告訴研究者何時不該相信它。

A Decision tree 的預設欄位

Rule	1.0.0 example	解釋
Minimum unique pulls	12	Exact-collapse 後的不同 numeric vectors。
Spectral effective pulls	4	相依性調整的資訊濃度下限。
Maximum zero share	0.80	避免資料由 threshold zeros 支配。
Minimum level G	0.80	Historical-date level ranking 的重現性。
Minimum innovation G	0.70	$\Delta \log(1 + Y)$ 的重現性。
Detection κ	0.60	只有 zero/nonzero 類別有變異時適用。
Maximum component share	0.50	避免單一 dependence component 支配。
Final convergence MAE/100	0.02	最後新增 pull 對 consensus 的邊際改變。
Benchmark standard-ized RMSE	研究前校準	取決於 benchmark SE 與 soft constraints。

這些值是 protocol choices，不是由統計定理產生的 universal constants。正式研究需以 pilot DGP、construct importance 與可接受 decision risk 校準。

B 輸入資料 schema

Raw chunk table 的必要 keys 為

```
series_id, pull_id, chunk_id, historical_date, value,
collection_day, stream_id, replicate_id, window_start, window_end
```

強烈建議另存

```
retrieved_at, keyword, topic_or_term, geo, category,
search_property, language, is_partial, protocol_hash,
```

```
raw_response_hash, client_version, request_order, network_event
```

C 軟體測試與重現指令

本版本附九組單元／整合測試，涵蓋 design、overlap calibration、duplicates/consensus、G-study、benchmark、EIV 與 full pipeline。重現：

```
python -m pip install -e '.[dev]'  
pytest -q  
python examples/run_monte_carlo.py
```

套件亦提供 wheel、source archive、完整 README、資料字典、protocol template、Stata interoperability 與 Monte Carlo raw results。

參考文獻

- [1] Ben-Rephael, A., Da, Z., & Israelsen, R. D. (2017). It depends on where you search: Institutional investor attention and underreaction to news. *The Review of Financial Studies*, 30(9), 3009–3047. <https://doi.org/10.1093/rfs/hhx031>
- [2] Bleher, J., & Dimpfl, T. (2022). Knitting multi-annual high-frequency Google Trends to predict inflation and consumption. *Econometrics and Statistics*, 24, 1–26. <https://doi.org/10.1016/j.ecosta.2021.10.006>
- [3] Brennan, R. L. (2001). *Generalizability Theory*. Springer.
- [4] Carroll, R. J., Ruppert, D., Stefanski, L. A., & Crainiceanu, C. M. (2006). *Measurement Error in Nonlinear Models: A Modern Perspective* (2nd ed.). Chapman and Hall/CRC.
- [5] Cebrián, E., & Domenech, J. (2024). Addressing Google Trends inconsistencies. *Technological Forecasting and Social Change*, 202, 123318. <https://doi.org/10.1016/j.techfore.2024.123318>
- [6] Choi, H., & Varian, H. (2012). Predicting the present with Google Trends. *Economic Record*, 88(s1), 2–9. <https://doi.org/10.1111/j.1475-4932.2012.00809.x>

- [7] Chow, G. C., & Lin, A. (1971). Best linear unbiased interpolation, distribution, and extrapolation of time series by related series. *The Review of Economics and Statistics*, 53(4), 372–375. <https://doi.org/10.2307/1928739>
- [8] Cook, J. R., & Stefanski, L. A. (1994). Simulation-extrapolation estimation in parametric measurement error models. *Journal of the American Statistical Association*, 89(428), 1314–1328. <https://doi.org/10.1080/01621459.1994.10476871>
- [9] Cronbach, L. J., Gleser, G. C., Nanda, H., & Rajaratnam, N. (1972). *The Dependability of Behavioral Measurements: Theory of Generalizability for Scores and Profiles*. Wiley.
- [10] Da, Z., Engelberg, J., & Gao, P. (2011). In search of attention. *The Journal of Finance*, 66(5), 1461–1499. <https://doi.org/10.1111/j.1540-6261.2011.01679.x>
- [11] Da, Z., Engelberg, J., & Gao, P. (2015). The sum of all FEARS: Investor sentiment and asset prices. *The Review of Financial Studies*, 28(1), 1–32. <https://doi.org/10.1093/rfs/hhu072>
- [12] Dagum, E. B., & Cholette, P. A. (2006). *Benchmarking, Temporal Distribution, and Reconciliation Methods for Time Series*. Springer.
- [13] Denton, F. T. (1971). Adjustment of monthly or quarterly series to annual totals: An approach based on quadratic minimization. *Journal of the American Statistical Association*, 66(333), 99–102. <https://doi.org/10.1080/01621459.1971.10482227>
- [14] Eichenauer, V. Z., Indergand, R., Martínez, I. Z., & Sax, C. (2022). Obtaining consistent time series from Google Trends. *Economic Inquiry*, 60(2), 694–705. <https://doi.org/10.1111/ecin.13049>
- [15] Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5), 378–382. <https://doi.org/10.1037/h0031619>
- [16] Fuller, W. A. (1987). *Measurement Error Models*. Wiley.
- [17] Google Search Central. (2025, July 24). Introducing the Google Trends API (alpha): A new way to access Trends data. <https://developers.google.com/search/blog/2025/07/trends-api>

- [18] Google Trends Help. (n.d.). FAQ about Google Trends data. <https://support.google.com/trends/answer/4365533>
- [19] Hölzl, J., Keusch, F., & Sajons, C. (2025). The (mis)use of Google Trends data in the social sciences. *Social Science Research*, 126, 103099.
- [20] Huber, P. J. (1964). Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, 35(1), 73–101. <https://doi.org/10.1214/aoms/1177703732>
- [21] Kish, L. (1965). *Survey Sampling*. Wiley.
- [22] Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4)
- [23] Medeiros, M. C., & Pires, H. F. (2021). The proper use of Google Trends in forecasting models. *arXiv:2104.03065*. <https://doi.org/10.48550/arXiv.2104.03065>
- [24] Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. <https://doi.org/10.2307/1913610>
- [25] Preis, T., Moat, H. S., & Stanley, H. E. (2013). Quantifying trading behavior in financial markets using Google Trends. *Scientific Reports*, 3, 1684. <https://doi.org/10.1038/srep01684>
- [26] Searle, S. R., Casella, G., & McCulloch, C. E. (1992). *Variance Components*. Wiley.
- [27] Shavelson, R. J., & Webb, N. M. (1991). *Generalizability Theory: A Primer*. Sage.
- [28] Stefanski, L. A., & Cook, J. R. (1995). Simulation-extrapolation: The measurement error jackknife. *Journal of the American Statistical Association*, 90(432), 1247–1256. <https://doi.org/10.1080/01621459.1995.10476629>
- [29] West, R. (2020). Calibration of Google Trends time series. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management* (pp. 2257–2260). <https://doi.org/10.1145/3340531.3412075>