

RACER-GT：在重複抽樣、分段正規化與相依量測 下 建構長期日頻 Google Trends 指標

實驗設計、全域重疊圖校準、廣義信度理論與共變異數調整估計

Yi-Hao Lai and RACER-GT contributors

方法論與軟體技術報告，版本 1.0.0

2026 年 7 月 27 日

摘要

Google Trends (GT) 已廣泛用作投資人注意力、資訊需求與情緒的高頻代理變數；然而，網站版 GT 的每次請求會重新縮放為 0–100，長期日頻資料往往必須切割為多個短視窗，且在相同查詢設定下重複下載仍可能出現不同數值。若研究者只下載一次、逐段接合後直接投入財金模型，分段尺度誤差、重複量測相依性、低搜尋量的零值與四捨五入，以及下游解釋變數的 measurement-error attenuation，均可能扭曲估計與預測結論。

本文提出 RACER-GT (Randomized Acquisition, Calibration, Error Decomposition, and Reliability for Google Trends)，其核心不是宣稱能恢復 Google 的絕對搜尋次數，而是先明確定義兩個可識別的統計目標：固定查詢與取得設計下的 GT 期望回傳值，以及共同尺度下的潛在相對搜尋訊號。方法依序結合：(一) 可預先註冊的平衡重複取得實驗與 protocol hash；(二) 使用所有重疊區間的全域圖形加權最小平方法，以避免 sequential stitching 的誤差累積；(三) 完整保留 exact duplicates，並以去除共同訊號後的殘差建立 near-duplicate dependence graph；(四) 將 historical date、collection day、collection stream 與 technical replicate 視為交叉 facets 的 Generalizability Theory；(五) 以誤差共變異數調整的 GLS / 穩定化最小變異凸組合重建日頻共識；(六) 以週頻與月頻資料進行二次規劃式 temporal benchmarking；(七) 分離 detection、level 與 daily-innovation reliability；以及(八) 將日頻 GT 的測量不確定性傳遞至下游 reliability-corrected OLS 與 SIMEX。

本文給出識別條件、無偏性與最小變異性之條件式證明、完整 decision tree，以及 Python 套件實作。20 次受控 Monte Carlo 顯示，在本文設定的資料生成過程

中，RACER-GT 的平均 RMSE 為 3.5265，低於單一 pull 的 7.2305、跨 pull 中位數的 4.1710 與簡單平均的 3.7253。這些結果支持該框架能在特定條件下降低重建均方誤差，但不構成對所有關鍵字、地區與 GT 版本的普遍最優保證。

關鍵詞：Google Trends；投資人注意力；測量誤差；實驗設計；Generalizability Theory；圖形校準；GLS；temporal benchmarking；SIMEX

研究定位聲明。本文所稱「偏誤降低」與「無偏」均為相對於明確定義之 estimand，並建立在可檢驗或可敏感度分析的假設上。Google 未公開網站版 GT 的完整抽樣分配、random seed、sample ID 或伺服器配置，因此不可能僅由重複下載無條件證明其等於絕對搜尋量，也不能以不同 IP 位址直接推論樣本獨立。

目錄

1	研究問題與方法論動機	4
2	統計目標、不可識別性與可證明範圍	5
2.1	三個不同的研究目標	5
2.2	絕對搜尋量不可由網站版 GT 單獨識別	6
2.3	設計式無偏性	6
3	資料取得實驗與 protocol locking	8
3.1	交叉因素設計	8
3.2	固定歷史窗、chunk manifest 與 protocol hash	8
3.3	Pilot 與 confirmatory batch 的分離	9
4	第一階段：每一 complete pull 的全域重疊圖校準	9
4.1	分段正規化模型	9
4.2	Robust edge estimation	10
4.3	Graph WLS 識別與估計	10
4.4	同日多 chunk 聚合	11
5	第二階段：跨 pull 相依性、duplicates 與量測可靠度	11
5.1	Exact duplicate audit	11
5.2	Residual near-duplicate graph	12
5.3	三面向 Generalizability Theory	12
5.4	Balanced ANOVA 的 method-of-moments components	13
6	第三階段：共變異數調整的潛在共識數列	14
6.1	Measurement model	14
6.2	有效 pull 資訊量	15
7	第四階段：日、週、月頻率一致化	16
8	可靠度指標與預先鎖定的 decision tree	17
8.1	Detection、level 與 innovation	17
8.2	Acceptance rules	17
9	下游財金模型的 measurement-error correction	18
9.1	Attenuation bias	18
9.2	SIMEX	19

10 完整演算法	19
11 Python 套件實作	20
11.1 設計原則	20
11.2 最小使用範例	21
12 Monte Carlo 驗證	22
12.1 資料生成過程	22
12.2 結果	22
13 建議的正式實驗規格	24
14 限制、敏感度分析與可延伸方向	25
14.1 無法由統計設計消除的限制	25
14.2 必要的穩健性檢驗	26
14.3 與既有方法的關係	26
15 結論	26
A Decision tree 的預設欄位	27
B 輸入資料 schema	28
C 軟體測試與重現指令	28

1 研究問題與方法論動機

Google Trends 將搜尋活動轉化為相對搜尋興趣（relative search interest）指標，因其即時性與高頻特性，已被財金研究用來衡量投資人注意力、資訊需求與恐慌情緒，例如 Da, Engelberg, and Gao（2011, 2015）以及後續的報酬、波動與交易量研究。這類資料的經濟直覺很清楚：投資人未必進行交易，但通常會在形成交易意圖或受到市場事件刺激時先搜尋資訊。因此，搜尋活動可補足交易資料只記錄已實現行為的限制。

然而，GT 的便利性也容易掩蓋其測量結構。Google 官方說明指出，Trends 使用搜尋活動的樣本，將資料依時間與地區正規化，再縮放至 0–100；低搜尋量可能呈現為零。網站版每一次請求均在該次請求的範圍內重新縮放，而 2025 年公布的 API alpha 雖提供跨請求一致尺度，歷史範圍仍為滾動約 1,800 天，且數值仍不是絕對搜尋次數 [12, 11]。因此，若研究期橫跨 2010–2026 年，網站版資料通常仍需切成多個短視窗後重建。

既有研究已分別指出：GT 存在 sampling noise 與 frequency inconsistency [9]；不同時間下載相同查詢可能產生不一致結果 [3, 16]；低量關鍵字在 0–100 整數尺度下會遭受嚴重 rounding 與 censoring，因而需要 anchor calibration [17]；長期高頻資料可利用重疊視窗進行 knitting [1]。然而，若研究目的不只是在資料層面平滑一條曲線，而是要讓其進入財金計量模型，仍需同時回答下列問題：

1. 重複下載的 estimand 是什麼？「真實搜尋次數」是否可識別？
2. 如何以實驗設計控制 collection day、stream、request order 與 technical replicate？
3. 每一個 complete pull 內，各自被正規化的 chunks 如何放到共同尺度？
4. exact duplicates、near duplicates 與一般 sampling variation 應如何區分，而不進行 outcome-guided deletion？
5. 如何以 ANOVA / G-theory 分解誤差來源，並決定增加 days、streams 或 replicates 哪一項最有效？
6. 若 pulls 相互依賴，如何避免把 21 次下載錯當成 21 份獨立資訊？
7. 如何使日頻形狀與較可靠的週頻、月頻長期尺度一致？
8. GT 作為財金模型解釋變數時，如何修正 measurement-error attenuation？

RACER-GT 將上述問題整合為一條從資料取得到下游推論的可重現測量鏈。其流程如圖 1。




圖 1: RACER-GT 的完整估計鏈。每一層均保留輸入、輸出與稽核紀錄；非相同 pulls 不因偏離中位數而被刪除。

2 統計目標、不可識別性與可證明範圍

2.1 三個不同的研究目標

令 Q 表示已鎖定的 query specification，包括 term/topic、geo、category、search property、語言、固定歷史起訖日與 chunk manifest。令 R 表示 retrieval environment 與執行條件，例如 collection day、stream、time slot、request order、session state 以及網站端未被研究者觀察的抽樣狀態。網站版 GT 對歷史日 t 的回傳可抽象寫為

$$Y_t(Q, R) = \mathcal{N}_{Q,R}\{S_t(Q, R)\}, \quad (1)$$

其中 S_t 為 proprietary sampling 與 aggregation 後的搜尋訊號， $\mathcal{N}_{Q,R}$ 包含 window-specific normalization、0–100 scaling、rounding、thresholding 與可能的統計處理。

本文區分三個 estimands。

定義 2.1 (絕對搜尋量). $A_t(Q)$ 為符合查詢構念的 *Google* 絕對搜尋次數。網站版 GT 不直接觀察 $A_t(Q)$ 。

定義 2.2 (GT 設計期望). 在預先定義的 *retrieval distribution* $\mathcal{R}$ 下，

$$\theta_t(Q; \mathcal{R}) = \mathbb{E}_{R \sim \mathcal{R}} [Y_t(Q, R)]. \quad (2)$$

此 *estimand* 描述固定 *query protocol* 下 *GT* 系統的期望回傳值。

定義 2.3 (共同尺度潛在相對訊號). 令 X_t 為在明確基準期 $\mathcal{B}$ 下識別的相對搜尋指標，滿足

$$\frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} X_t = 100. \quad (3)$$

X_t 不代表絕對搜尋次數，而是不同 *chunks* 與 *pulls* 在校準後共享的相對尺度。

2.2 絕對搜尋量不可由網站版 GT 單獨識別

命題 2.1 (絕對尺度不可識別). 假設網站版 *GT* 僅觀察某一 *window* W 內經比例正規化的值

$$Y_t = 100 \frac{A_t}{\max_{\tau \in W} A_\tau}, \quad t \in W, \quad (4)$$

忽略 *rounding* 時，對任何常數 $c > 0$ ，序列 A_t 與 cA_t 產生完全相同的 Y_t 。因此，沒有外部 *anchor* 或絕對量資訊時， A_t 的絕對尺度不可識別。

證明. 將 A_t 替換為 cA_t ，則

$$100 \frac{cA_t}{\max_{\tau \in W} cA_\tau} = 100 \frac{cA_t}{c \max_{\tau \in W} A_\tau} = Y_t.$$

因此資料對所有 $c > 0$ 都具有相同 *likelihood* / *observation mapping*，絕對尺度無法由 Y_t 唯一決定。□

這項結果界定了研究主張的上限：我們可以改善相對訊號的尺度一致性、降低重建誤差並量化可靠度，但不能把統計校準誤稱為「恢復真實搜尋次數」。

2.3 設計式無偏性

令 $R_1, \dots, R_m$ 由預先鎖定的 $\mathcal{R}$ 產生，並考慮

$$\bar{Y}_t = \frac{1}{m} \sum_{i=1}^m Y_t(Q, R_i). \quad (5)$$

命題 2.2 (對 GT 設計期望的無偏性). 若 R_i 具有相同邊際分配 $\mathcal{R}$ ，則無論 *pulls* 之間是否

獨立，

$$\mathbb{E}(\bar{Y}_t) = \theta_t(Q; \mathcal{R}). \quad (6)$$

獨立性只影響 $\text{Var}(\bar{Y}_t)$ ，不影響此平均的期望。

證明. 利用期望的線性性：

$$\mathbb{E}(\bar{Y}_t) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}\{Y_t(Q, R_i)\} = \frac{1}{m} \sum_{i=1}^m \theta_t = \theta_t.$$

此推導不需 R_i 相互獨立。 $\square$

說明 2.1. 若取得設計不是由一個明確且固定的 $\mathcal{R}$ 產生，例如 *Day 30* 使用擴張到「當日」的歷史終點，則每一 *pull* 的 *estimand* 不同，平均值不再對單一 θ_t 無偏。這也是固定 *historical end date* 的理論理由。

實際的 RACER-GT 蒐集通常採分層且平衡的 **day** $\times$ **stream** $\times$ **replicate** 設計，而非假設所有 *pulls* 具有完全相同的條件分配。令 $h \in \mathcal{H}$ 表示預先鎖定的 **design cell**， π_h 為研究者事先指定的目標權重，且

$$\theta_{th} = \mathbb{E}(Y_{thi} \mid H = h), \quad \theta_t^\pi = \sum_{h \in \mathcal{H}} \pi_h \theta_{th}, \quad \sum_h \pi_h = 1. \quad (7)$$

若 **cell** h 完成 n_h 次有效重複量測，定義

$$\hat{\theta}_t^\pi = \sum_{h \in \mathcal{H}} \pi_h \bar{Y}_{th}, \quad \bar{Y}_{th} = \frac{1}{n_h} \sum_{i=1}^{n_h} Y_{thi}. \quad (8)$$

命題 2.3 (分層設計估計量的無偏性). 若每一 *design cell* 內的有效量測均以不依賴其未觀察回傳值的規則納入，且 $\mathbb{E}(Y_{thi} \mid H = h) = \theta_{th}$ ，則

$$\mathbb{E}(\hat{\theta}_t^\pi) = \theta_t^\pi, \quad (9)$$

即使同一 *cell* 內或不同 *cells* 之間的 *pulls* 相關，結論仍成立。相關性只改變變異數與有效資訊量。

證明. 由條件期望與線性性，

$$\mathbb{E}(\hat{\theta}_t^\pi) = \sum_h \pi_h \mathbb{E}(\bar{Y}_{th}) = \sum_h \pi_h \theta_{th} = \theta_t^\pi.$$

推導不需假設 $\text{Cov}(Y_{thi}, Y_{th'j}) = 0$ 。但若 **failed requests**、**partial responses** 或事後刪除與未觀察的 Y_{thi} 有關，則 **cell mean** 可能產生 **informative-missingness bias**，故 **raw audit** 與預先指定排除規則不可省略。 $\square$

平衡設計是 $\pi_h = 1/|\mathcal{H}|$ 的特例；若某些 collection days 或 streams 在目標 retrieval distribution 中應有不同權重，必須在看見資料前指定 π_h ，而不是依結果調整。

3 資料取得實驗與 protocol locking

3.1 交叉因素設計

RACER-GT 將取得程序視為 repeated-measurement experiment，而非將每次下載模糊地稱為「獨立樣本」。基本設計為

$$D \times S \times R, \quad (10)$$

其中 D 為 collection-day levels、 S 為 collection streams、 R 為每個 day $\times$ stream cell 內的 technical replicates。本文建議的起始設計為 Day 0、1、2、7、14、21、30，三個固定 streams；若資源允許， $R = 2$ 可將 pure technical error 與最高階交互作用分離。若僅 $R = 1$ ，仍可估計 day 與 stream facets，但 TDS 與純 replication error 無法分離。

Collection stream 應被定義為固定的複合環境：裝置、瀏覽器 profile、cookie、登入狀態、client 版本、網路與 IP 等條件在 stream 內保持不變。除非另行採用 crossover factorial design，估計出的 S effect 只能稱為 composite stream effect，不能拆解為 IP effect。

為避免 stream 與 request order 或 time slot 完全混淆，RACER-GT 以 cyclic / Latin-square-like rotation 平衡每一天的 stream order；chunk order 亦可輪替。若三個 streams 無法同時啟動，這種平衡至少能使系統狀態隨時間的變化不固定落在同一個 stream。

3.2 固定歷史窗、chunk manifest 與 protocol hash

所有正式 pulls 必須共用：

- 相同的 historical start 與 end；
- 相同的 chunk start/end、overlap 與 query parameters；
- 相同的資料清理、partial-period 排除與時區規則；
- 相同的 calibration、duplicate、G-study、consensus 與 decision thresholds；

- 相同版本的程式碼與設定檔。

設定物件以 canonical JSON 序列化並計算 SHA-256：

$$h = \text{SHA256}\{\text{canonical}(Q, \mathcal{D}, \mathcal{C}, \mathcal{T})\}, \quad (11)$$

其中 $\mathcal{D}$ 是蒐集設計， $\mathcal{C}$ 是校準設定， $\mathcal{T}$ 是 decision thresholds。每筆 raw row 可保存 h ，若任何設定被改動，protocol hash 即改變。

3.3 Pilot 與 confirmatory batch 的分離

Day 0–2 的 MONITOR 可用來檢查缺漏、query drift、exact duplicates、overlap graph 是否連通與程式執行錯誤；但若研究團隊因此修改 thresholds、stitching rule、query、code 或 decision tree，Day 0–2 必須被重新標記為 pilot，正式 confirmatory batch 由新的 Day 0 開始。否則同一資料同時被用來設計與驗證規則，形成 data-dependent acceptance bias。

同理，所有 GT 處理規則都必須在查看報酬、波動、價差、VaR 或其他財金結果之前鎖定。以「哪種 GT 建構最顯著」作為資料品質決策，會將 measurement validation 變成 outcome-guided model selection。

4 第一階段：每一 complete pull 的全域重疊圖校準

4.1 分段正規化模型

令一個 complete pull 包含 J 個重疊 chunks。對 chunk j 中歷史日 t 的正值觀察，考慮近似模型

$$Y_{jt} = a_j X_t \exp(\epsilon_{jt}), \quad a_j > 0, \quad (12)$$

其中 a_j 代表該次 chunk-specific normalization scale， X_t 是該 pull 內欲恢復的共同相對訊號。當 t 同時存在於 chunks j 與 k 時，

$$r_{jkt} = \log Y_{jt} - \log Y_{kt} = \ell_j - \ell_k + \nu_{jkt}, \quad \ell_j = \log a_j, \quad (13)$$

且 $\nu_{jkt} = \epsilon_{jt} - \epsilon_{kt}$ 。

由於零值不能取 log，且接近零的整數 RSV 會放大 ratio noise，RACER-GT 僅使用兩邊皆高於預先指定門檻 $c_{\min}$ 的 overlap cells 估計 edge；零值仍保留於最終數列與 detection reliability，不會被任意插補為正值。

4.2 Robust edge estimation

對每一可用的 chunk pair (j, k) ，令 $\mathcal{O}_{jk}$ 為重疊日期集合。edge location $\delta_{jk} = \ell_j - \ell_k$ 以 Huber M-estimator 估計：

$$\hat{\delta}_{jk} = \arg \min_{\delta} \sum_{t \in \mathcal{O}_{jk}} \rho_c(r_{jkt} - \delta), \quad (14)$$

其中

$$\rho_c(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq c, \\ c|u| - \frac{1}{2}c^2, & |u| > c. \end{cases} \quad (15)$$

這使極端 overlap cells 不至於完全決定尺度比。套件同時估計 robust scale 與 location variance $\hat{v}_{jk}$ ，形成 edge weight $w_{jk} = 1 / \max(\hat{v}_{jk}, v_{\min})$ 。

4.3 Graph WLS 識別與估計

建立無向圖 $G = (V, E)$ ：每個 chunk 是 node，每個可估 edge 是一個 overlap relation。將所有 edge equations 堆疊為

$$\hat{\delta} = B\ell + \eta, \quad \mathbb{E}(\eta \mid B) = \mathbf{0}, \quad \text{Var}(\eta \mid B) = \Omega, \quad (16)$$

其中 B 是 oriented incidence matrix。由於只可識別相對尺度，固定一個 reference chunk r ，令 $\ell_r = 0$ ；刪除對應欄後得到 B_{-r} 。估計量為

$$\hat{\ell}_{-r} = (B_{-r}'WB_{-r})^{-1}B_{-r}'W\hat{\delta}. \quad (17)$$

命題 4.1 (相對尺度的識別). 固定一個 *reference node* 後， ℓ_{-r} 可識別若且唯若 *overlap graph* G 連通。此時 B_{-r} 具有滿 *column rank*， $B_{-r}'WB_{-r}$ 對任意正定 *diagonal* W 可逆。

證明. 圖論中，連通圖的 incidence matrix rank 為 $|V| - 1$ 。刪除任一 node 對應欄後， B_{-r} rank 為 $|V| - 1$ ，等於其欄數。反之，若圖有 $K > 1$ 個 components，incidence matrix rank 為 $|V| - K < |V| - 1$ ，即使固定單一 reference 仍存在至少 $K - 1$ 個未識別的 component-level shifts。□

命題 4.2 (Graph GLS 的條件式無偏性與效率). 在式 (16)、圖連通且 $W = \Omega^{-1}$ 下，式 (17) 滿足

$$\mathbb{E}(\hat{\ell}_{-r} \mid B) = \ell_{-r}, \quad (18)$$

且為所有線性無偏估計量中的最小變異估計量。

證明。無偏性由

$$\mathbb{E}(\widehat{\ell}_{-r} \mid B) = (B'WB)^{-1}B'W\mathbb{E}(\widehat{\delta} \mid B) = \ell_{-r}$$

得之（為簡潔略去下標 $-r$ ）。效率為 Gauss–Markov theorem 的直接應用。□

若 $\widehat{\ell}_j$ 近似常態且 $\text{Var}(\widehat{\ell}_j) = s_j^2$ ，直接使用 $\exp(-\widehat{\ell}_j)$ 會有 lognormal transformation bias。若校準目的為將 Y_{jt} 除以 a_j ，可採一階修正

$$\widehat{a_j^{-1}}_{bc} = \exp\left(-\widehat{\ell}_j - \frac{1}{2}s_j^2\right). \quad (19)$$

此修正依賴近似常態與 variance estimate，故程式允許關閉作為 sensitivity analysis。

4.4 同日多 chunk 聚合

校準後的 chunk observation 為

$$\widetilde{X}_{jt} = Y_{jt} \exp(-\widehat{\ell}_j). \quad (20)$$

同一歷史日通常被多個重疊 chunks 覆蓋。RACER-GT 預設依 chunk-scale variance 進行 inverse-variance aggregation：

$$\widehat{X}_t^{(i)} = \frac{\sum_{j \in \mathcal{J}_t} \omega_{jt} \widetilde{X}_{jt}}{\sum_{j \in \mathcal{J}_t} \omega_{jt}}, \quad \omega_{jt} = \frac{1}{\widehat{\text{Var}}(\widehat{\ell}_j) + \varepsilon}. \quad (21)$$

亦可使用 median 或 Huber aggregation。最後依式 (3) 將每個 complete pull 的基準期平均設為 100。這一步明確定義相對 index，而非宣稱恢復絕對量。

逐段 stitching 只使用相鄰 chunks，前段 edge error 會遞迴傳遞至後續所有尺度；全域圖法同時使用遠近所有重疊 edges，能以 graph cycles 觀察不一致，並輸出 normal-matrix condition number、weighted edge RMSE 與 component diagnostics。

5 第二階段：跨 pull 相依性、duplicates 與量測可靠度

5.1 Exact duplicate audit

對每一 complete pull 的 numeric vector 以固定 decimal rounding 後計算 SHA-256。完全相同的向量不應從 raw archive 消失，因其 multiplicity、collection days、

streams 與 raw-response hashes 本身就是 cache / 共同版本 / 重複執行的證據。RACER-GT 採雙層資料：

- audit set：保留所有 nominal pulls 與 exact duplicates；
- analytic unique-vector set：在 consensus covariance estimation 中，每個完全相同向量保留一個 representative，並另存 multiplicity map。

Chunk-level duplicates 與 full-series duplicates 應分別檢查；僅看完整向量可能漏掉部分 chunks 被重複回傳的情況。

5.2 Residual near-duplicate graph

原始 GT pulls 都共享相同的歷史訊號，因此 raw-series correlation 本來就會非常高。若以 raw correlation 作為共同抽樣或 cache dependence 的唯一依據，容易將正常的共同訊號誤判為依賴。RACER-GT 先定義 preliminary common signal

$$m_t = \text{median}_i Z_{it}, \quad (22)$$

再移除 pull-specific mean bias

$$b_i = \frac{1}{T} \sum_t (Z_{it} - m_t), \quad e_{it} = Z_{it} - m_t - b_i. \quad (23)$$

Near-duplicate edge 必須同時通過預先指定的 value-anchored rule，例如 raw correlation、exact-cell agreement、MAE/100、positive-day Jaccard，以及 residual correlation。Connected component 只表示成員透過 edge chain 連接，不表示 component 中每一對都相似；因此報告 density、diameter、maximum clique、articulation points、minimum within-component correlations 與 maximum MAE。

Near-duplicate graph 只作依賴診斷與 covariance 建模；除 exact numeric duplicates 外，RACER-GT 不因某 pull 偏離中位數或降低 reliability 而刪除它。

5.3 三面向 Generalizability Theory

令 $t = 1, \dots, T$ 為 historical dates， $d = 1, \dots, D$ 為 collection-day levels， $s = 1, \dots, S$ 為 streams， $r = 1, \dots, R$ 為 technical replicates。完全交叉隨機效果模型為

$$Y_{tdsr} = \mu + T_t + D_d + S_s + (TD)_{td} + (TS)_{ts} + (DS)_{ds} + (TDS)_{tds} + E_{tdsr}. \quad (24)$$

各隨機成分期望為零、彼此不相關，variance components 記為

$$\sigma_T^2, \sigma_D^2, \sigma_S^2, \sigma_{TD}^2, \sigma_{TS}^2, \sigma_{DS}^2, \sigma_{TDS}^2, \sigma_E^2.$$

RACER-GT 對三種轉換分別執行 G-study：

$$\text{Level: } Y_{tdsr}, \quad (25)$$

$$\text{Detection: } I(Y_{tdsr} > 0), \quad (26)$$

$$\text{Innovation: } \Delta \log(1 + Y_{tdsr}). \quad (27)$$

這樣可避免一個單一 ICC 混合「是否被偵測到」、「數值水準是否一致」與「日變化是否一致」。

對平均 n_D 個 collection days、 n_S 個 streams 與 n_R 個 replicates 的相對決策，誤差 variance 為

$$\sigma_\delta^2 = \frac{\sigma_{TD}^2}{n_D} + \frac{\sigma_{TS}^2}{n_S} + \frac{\sigma_{TDS}^2}{n_D n_S} + \frac{\sigma_E^2}{n_D n_S n_R}. \quad (28)$$

Generalizability coefficient 為

$$G(n_D, n_S, n_R) = \frac{\sigma_T^2}{\sigma_T^2 + \sigma_\delta^2}. \quad (29)$$

若研究關心相對排名之外的絕對水準，還要加入 day、stream 與 DS effects：

$$\sigma_\Delta^2 = \sigma_\delta^2 + \frac{\sigma_D^2}{n_D} + \frac{\sigma_S^2}{n_S} + \frac{\sigma_{DS}^2}{n_D n_S}, \quad (30)$$

$$\Phi(n_D, n_S, n_R) = \frac{\sigma_T^2}{\sigma_T^2 + \sigma_\Delta^2}. \quad (31)$$

5.4 Balanced ANOVA 的 method-of-moments components

令 $a = T, b = D, c = S$ ，先對 R replicates 取 cell mean。Balanced ANOVA 的 expected mean squares 可寫為

$$\mathbb{E}(MS_{TDS}) = \sigma_E^2/R + \sigma_{TDS}^2, \quad (32)$$

$$\mathbb{E}(MS_{TD}) = \sigma_E^2/R + \sigma_{TDS}^2 + c\sigma_{TD}^2, \quad (33)$$

$$\mathbb{E}(MS_{TS}) = \sigma_E^2/R + \sigma_{TDS}^2 + b\sigma_{TS}^2, \quad (34)$$

$$\mathbb{E}(MS_{DS}) = \sigma_E^2/R + \sigma_{TDS}^2 + a\sigma_{DS}^2, \quad (35)$$

$$\mathbb{E}(MS_T) = \sigma_E^2/R + \sigma_{TDS}^2 + c\sigma_{TD}^2 + b\sigma_{TS}^2 + bc\sigma_T^2, \quad (36)$$

並對 D, S 對稱。因此 method-of-moments estimator 例如

$$\hat{\sigma}_{TD}^2 = \frac{MS_{TD} - MS_{TDS}}{c}, \quad (37)$$

$$\hat{\sigma}_T^2 = \frac{MS_T - MS_{TD} - MS_{TS} + MS_{TDS}}{bc}. \quad (38)$$

若 $R > 1$ ， MS_E 由 cell 內殘差估計，且

$$\hat{\sigma}_{TDS}^2 = MS_{TDS} - MS_E/R. \quad (39)$$

若 $R = 1$ ， E 無法分離，實作將不可分部分歸入 TDS 。負的 method-of-moments components 可報告原值並依 protocol 選擇截為零；正式推論應另用 REML sensitivity analysis。由於 historical dates 具時間相依，係數信賴區間採 moving-block bootstrap，而非把 T 天當成獨立單位。

D-study 將式 (29) and (31) 代入不同的 (n_D, n_S, n_R) ，直接回答「下一筆資源應投入增加日期、streams 或 technical replicates」。因此 nominal pull count 不是充分的停止規則。

6 第三階段：共變異數調整的潛在共識數列

6.1 Measurement model

將每一個 calibrated unique pull 在相同基準期重新設為平均 100，並移除 pull-specific additive bias 後，對歷史日 t 寫成

$$\mathbf{Z}_t = \mathbf{1}X_t + \mathbf{e}_t, \quad \mathbb{E}(\mathbf{e}_t) = \mathbf{0}, \quad \text{Var}(\mathbf{e}_t) = \Sigma. \quad (40)$$

$\mathbf{Z}_t$ 為 $m \times 1$ vector。Near duplicates 對應 Σ 中較高的 off-diagonal covariance；因此它們不應被簡單計為多份獨立 evidence。

考慮線性共識 $\hat{X}_t = \mathbf{w}'\mathbf{Z}_t$ 。若 $\mathbf{1}'\mathbf{w} = 1$ ，則

$$\mathbb{E}(\hat{X}_t) = X_t, \quad (41)$$

而 variance 為 $\mathbf{w}'\Sigma\mathbf{w}$ 。

命題 6.1 (GLS 共識). 若 Σ 正定且已知，所有滿足 $\mathbf{1}'\mathbf{w} = 1$ 的線性無偏估計量中，

$$\mathbf{w}^* = \frac{\Sigma^{-1}\mathbf{1}}{\mathbf{1}'\Sigma^{-1}\mathbf{1}} \quad (42)$$

使 $\text{Var}(\hat{X}_t)$ 最小，且

$$\text{Var}(\hat{X}_t) = \frac{1}{\mathbf{1}'\Sigma^{-1}\mathbf{1}}. \quad (43)$$

證明. 建立 Lagrangian

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}'\Sigma\mathbf{w} - 2\lambda(\mathbf{1}'\mathbf{w} - 1).$$

一階條件 $2\Sigma\mathbf{w} - 2\lambda\mathbf{1} = 0$ ，故 $\mathbf{w} = \lambda\Sigma^{-1}\mathbf{1}$ 。代入 $\mathbf{1}'\mathbf{w} = 1$ 得式 (42)。正定 Σ 使目標嚴格凸，因此解唯一且為全域最小值。□

實務上 Σ 必須由有限歷史日的 residual matrix 估計。RACER-GT 預設使用 Ledoit-Wolf shrinkage，使 covariance 在 m 相對不小或 residuals 高度共線時仍可逆。為避免 sampling error 造成負權重與極端 extrapolation，預設解下列 convex quadratic program：

$$\min_{\mathbf{w}} \mathbf{w}'\hat{\Sigma}\mathbf{w} \quad \text{s.t.} \quad \mathbf{1}'\mathbf{w} = 1, \quad 0 \leq w_i \leq \bar{w}. \quad (44)$$

受限解保持 sum-to-one，因此在式 (40) 下仍線性無偏；但嚴格的 unrestricted BLUE 結論只適用式 (42)。權重上限是穩定化選擇，必須在 protocol 中預先鎖定。

若某日缺少少數 pulls，實作對當日可用權重重新正規化。條件式基礎標準誤為

$$\widehat{se}_0 = \sqrt{\hat{\mathbf{w}}'\hat{\Sigma}\hat{\mathbf{w}}}. \quad (45)$$

為反映事件日可能具有較大跨 pull dispersion，1.0.0 版再以當日 absolute deviation median 相對於全期間 median 進行 bounded local multiplier。這是 pragmatic heteroskedastic adjustment，而非完整 Bayesian posterior interval；正式研究可另以 block bootstrap 重新執行全 pipeline。

6.2 有效 pull 資訊量

Nominal m 無法反映相依性。對 residual correlation matrix R_e ，RACER-GT 報告 spectral participation ratio

$$m_{\text{eff}}^{\text{spectral}} = \frac{\text{tr}(R_e)^2}{\text{tr}(R_e^2)}. \quad (46)$$

當 residuals 相互獨立， $R_e = I_m$ ，故 $m_{\text{eff}} = m$ ；當所有 residuals 完全共線，只有一個非零 eigenvalue， $m_{\text{eff}} = 1$ 。此量是資訊濃度診斷，不是對 proprietary sampling mechanism 的正式獨立樣本數證明。

另報告 Kish weight count

$$m_{\text{eff}}^{\text{Kish}} = \frac{1}{\sum_i w_i^2}, \quad (47)$$

用以觀察共識是否被少數 pulls 支配。

7 第四階段：日、週、月頻率一致化

僅以短視窗日頻 chunks 接合，可能保留日際形狀卻失去長期尺度；Eichenauer et al. (2022) 稱此為 frequency inconsistency。令 preliminary daily consensus 為 $z \in \mathbb{R}^T$ ，lower-frequency benchmark 為 $b \in \mathbb{R}^K$ ，aggregation matrix A 的第 k 列對 benchmark period k 內日資料給予平均權重。

RACER-GT 的 soft benchmarking estimator 定義為

$$\hat{x} = \arg \min_x (x - z)'Q(x - z) + (Ax - b)'W(Ax - b), \quad (48)$$

其中

$$Q = \lambda_I I + \lambda_D D_1' D_1 + \lambda_R I, \quad (49)$$

D_1 是 first-difference matrix； λ_I 控制對 preliminary signal 的忠實度， λ_D 控制修正路徑的粗糙度， W 通常由 benchmark standard errors 的倒數平方組成。

命題 7.1 (Soft benchmark 的唯一解). 若 Q 正定且 W 半正定，式 (48) 嚴格凸，唯一解為

$$\hat{x} = z + (Q + A'WA)^{-1}A'W(b - Az). \quad (50)$$

證明. 對式 (48) 取 gradient 並令其為零：

$$Q(x - z) + A'W(Ax - b) = 0.$$

整理得 $(Q + A'WA)x = Qz + A'Wb$ ，等價於式 (50)。 Q 正定使 $Q + A'WA$ 正定，因此解唯一。 $\square$

若 benchmark 被視為無誤差硬約束，可解

$$\min_x (x - z)'Q(x - z) \quad \text{s.t.} \quad Ax = b, \quad (51)$$

其 KKT system 為

$$\begin{bmatrix} Q & A' \\ A & 0 \end{bmatrix} \begin{bmatrix} \delta \\ \lambda \end{bmatrix} = \begin{bmatrix} 0 \\ b - Az \end{bmatrix}, \quad \hat{x} = z + \delta. \quad (52)$$

Soft mode 更適合 GT benchmark 本身也有 sampling variation 的情況；exact mode

可作 sensitivity analysis。若 nonnegative projection 被啟用，投影後聚合等式可能略受影響，故程式會報告 projection 是否發生。

8 可靠度指標與預先鎖定的 decision tree

8.1 Detection、level 與 innovation

RACER-GT 不以一個單一相關係數概括資料品質。Detection reliability 包括 zero/nonzero agreement、positive-day Jaccard 與 Fleiss' κ ；當所有觀察都屬同一類別時， κ 不可識別，此規則標記為 not applicable，而非錯誤判 FAIL。Level reliability 包括 Pearson、Spearman、MAE/100、G 與 Φ ；innovation reliability 則對 $\Delta \log(1 + Y)$ 計算 correlation、sign / peak overlap 與 G-study。

Exact-cell agreement 必須與 zero share 一起解讀。兩條低量序列若多數日都為零，可能得到很高 exact agreement，卻沒有足夠正值資訊；因此 decision tree 另設 maximum zero share，並檢查 positive Jaccard。

8.2 Acceptance rules

一個正式 batch 的 PASS 至少需滿足以下預先指定規則：

1. query、historical endpoints、chunks 與 protocol hash 完整一致；
2. 每個 complete pull 的 overlap graph 可識別且連通；
3. unique pulls 與 spectral effective pulls 達到門檻；
4. zero share 未超過門檻；
5. level 與 innovation G 達到門檻；
6. near-duplicate component 不支配全批資料；
7. 隨 pulls 增加的 consensus convergence MAE/100 低於門檻；
8. 若使用 benchmark，standardized benchmark RMSE 低於門檻。

若任一 mandatory rule 明確失敗，狀態為 FAIL；若沒有失敗但有不可判定 mandatory rule，狀態為 REVIEW；全部通過才是 PASS。PASS 的意義是「允許依鎖定 protocol 建構此相對指標」，不是 construct validity、外部效度或因果識別的證明。

關鍵詞／ Topic 的 **construct validity** 必須另行檢查：語意與語言版本、可能的非財金用途、歷史首次合理出現時間、主要 **peaks** 的事件對應、搜尋量是否足夠，以及不同替代 **terms** 的結果是否一致。測量可靠而構念錯誤的指標仍然沒有研究效度 [13]。

9 下游財金模型的 measurement-error correction

9.1 Attenuation bias

令真正的注意力訊號 X_t 進入財金模型

$$Y_{t+h} = \alpha + \beta X_t + \gamma' C_t + \varepsilon_{t+h}, \quad (53)$$

但研究者觀察

$$W_t = X_t + u_t, \quad \mathbb{E}(u_t \mid X_t, C_t, \varepsilon_{t+h}) = 0. \quad (54)$$

在無 controls 的 classical homoskedastic case，naive OLS 滿足

$$\text{plim } \hat{\beta}_{\text{naive}} = \beta \frac{\sigma_X^2}{\sigma_X^2 + \sigma_u^2}, \quad (55)$$

故係數向零衰減。

令 $M_C = I - C(C'C)^{-1}C'$ 為 controls residual-maker。若 measurement-error covariance Ω_u 已知，則

$$\mathbb{E}(W' M_C W) = X' M_C X + \text{tr}(M_C \Omega_u). \quad (56)$$

因此 moment-corrected estimator 為

$$\hat{\beta}_{RC} = \frac{W' M_C Y}{W' M_C W - \text{tr}(M_C \hat{\Omega}_u)}. \quad (57)$$

RACER-GT 使用每日 consensus standard error 的平形成 diagonal $\hat{\Omega}_u$ ，並以 Newey–West long-run variance 對 scalar moment 提供 HAC standard error。若修正後分母非正，套件拒絕估計，因為在該假設下 latent predictor variation 不足以識別 β 。

9.2 SIMEX

當誤差標準差可估計但解析修正不穩定時，SIMEX [4] 對 $\lambda \geq 0$ 人工加入

$$W_t^{(b,\lambda)} = W_t + \sqrt{\lambda} \hat{\sigma}_{u,t} \xi_t^{(b)}, \quad \xi_t^{(b)} \sim N(0, 1), \quad (58)$$

估計 $\hat{\beta}(\lambda)$ 後，以二次曲線外推至 $\lambda = -1$ ，模擬移除 measurement error。SIMEX 對 extrapolation form 敏感，因此應與式 (57)、sample-specific pull regressions 與 full-pipeline bootstrap 並列報告，而非只選擇較顯著者。

10 完整演算法

Algorithm 1 RACER-GT 長期日頻指標建構

Require: Locked query Q ; balanced retrieval design ; fixed chunks ; raw responses ; optional lower-frequency benchmark

Ensure: Final daily index 、measurement uncertainty 、audit trail 、acceptance decision

- 1: Canonicalize protocol ; 計算 hash ; 產生 collection schedule 與 chunk manifest
 - 2: 蒐集並保存所有 raw responses ; 記錄 day 、stream 、replicate 、time 、order 、network events 與 hashes
 - 3: Audit historical endpoints 、query parameters 、chunk boundaries 、partial observations 與 missing chunks
 - 4: for each complete pull i do
 - 5: 由 usable overlaps 計算 robust log-ratio edges
 - 6: 建立 overlap graph ; 若不連通依 protocol FAIL / REVIEW
 - 7: 解 graph WLS 取得 chunk log scales 與 covariance
 - 8: 校準所有 chunks ; 以 inverse-variance / Huber / median 聚合同日值
 - 9: 依固定 baseline 將 pull index 平均設為 100
 - 10: end for
 - 11: 依預先指定 design-cell weights 計算 $\hat{\theta}_t^\pi$ 作為 design-based reference
 - 12: 保留 exact duplicate audit ; 建立 analytic unique-vector set
 - 13: 由共同中位數與 pull bias 形成 residuals ; 建立 near-duplicate graph
 - 14: 對 level 、detection 、innovation 執行 crossed-facet G-study 與 D-study
 - 15: 估計 residual covariance $\hat{\Sigma}$; 解受限或無限制 GLS latent consensus
 - 16: 計算 conditional standard errors 、spectral/Kish effective counts 與 convergence path
 - 17: if lower-frequency benchmark available then
 - 18: 解 soft / exact temporal benchmarking problem
 - 19: end if
 - 20: 執行 locked decision tree ; 輸出 PASS / REVIEW / FAIL
 - 21: 將 final index 與 uncertainty 輸入下游 EIV correction / SIMEX
-

11 Python 套件實作

11.1 設計原則

RACER-GT 1.0.0 採 ingestion-first architecture：統計套件不內建未經官方保證的網站 scraping。網站端點、rate limits、認證與服務條款可能變動，將 retrieval client 與估計器解耦，可使研究者在官方 API、手動 CSV export 或機構核准的 collector 間替換，而不改變統計 protocol。Collector 只需輸出固定 long-format schema。

核心模組如表 1。

表 1: RACER-GT 1.0.0 模組

模組	功能
config.py	Pydantic protocol schema、欄位驗證、canonical serialization 與 SHA-256 hash。
design.py	固定 overlap windows、balanced stream/time/chunk order 與 protocol bundle。
audit.py	Historical-window drift、query drift、partial data、missing chunks 與 metadata ambiguity。
overlap.py	Huber edge estimator、graph connectivity、WLS scale solution、condition diagnostics 與 calibrated pull aggregation。
duplicates.py	Exact vector hashes、value-anchored pair metrics、residual near-duplicate graph、components/cliques/articulation diagnostics。
gstudy.py	Balanced $T \times D \times S$ ANOVA、variance components、 G/Φ 、D-study 與 moving-block bootstrap。
consensus.py	Design-cell weighted reference、exact-collapse map、baseline rescale、Ledoit–Wolf covariance、GLS / constrained weights、effective pull counts 與 uncertainty。
benchmark.py	Sparse aggregation matrix、soft quadratic benchmark 與 exact KKT benchmark。
reliability.py	Pairwise level/innovation metrics、Fleiss kappa、day/stream dependence 與 sequential convergence。
decision.py	可稽核的 PASS/REVIEW/FAIL decision tree。

模組	功能
eiv.py	Reliability-corrected OLS、HAC inference 與 quadratic SIMEX。
simulation.py	含 latent dynamics、day/stream effects、correlated retrieval noise、chunk normalization、rounding 與 exact duplicates 的 DGP。
validation.py	Single pull、mean、median 與 RACER-GT 的 Monte Carlo 比較。
pipeline.py	End-to-end orchestrator 與完整輸出保存。
cli.py	design、audit、run、simulate、export-stata。

11.2 最小使用範例

```
import pandas as pd
from racergt import RacerGTConfig, RacerGTPipeline

config = RacerGTConfig.load_yaml("protocol.lock.yaml")
raw = pd.read_csv("raw_chunks.csv")
benchmark = pd.read_csv("benchmark.csv")

result = RacerGTPipeline(config).fit(raw, benchmark=benchmark)
result.save("results")

print(result.decision.status)
design_reference = result.design_consensus.consensus
final_gt = result.final_series
```

CLI：

```
racergt design examples/config_example.yaml --out protocol_bundle \
  --anchor-date 2026-08-01
racergt audit protocol_bundle/protocol.lock.yaml raw_chunks.csv
racergt run protocol_bundle/protocol.lock.yaml raw_chunks.csv \
  --benchmark benchmark.csv --out results
```

每一次 run 產生 design-weighted reference、final latent series、calibration scales、edge residuals、duplicate groups/components、pull covariance、weights、G-study tables、reliability/convergence、benchmark fit、decision tree 與 diagnostic report。所有中間結果可供 replication，而不是只輸出一條無法稽核的平滑序列。

12 Monte Carlo 驗證

12.1 資料生成過程

本文隨套件提供可重現 simulation。基礎 latent intensity 為

$$L_t = 30 + 0.004t + 2.5 \sin(2\pi t/7) + 4 \sin(2\pi t/365.25) + u_t + \sum_{q=1}^6 \text{Spike}_{qt}, \quad (59)$$

其中 $u_t = 0.92u_{t-1} + \eta_t$ 、 $\eta_t \sim N(0, 1.8^2)$ ，並加入六個非對稱衰減事件尖峰。真實 index 依研究期平均設為 100。

對 collection day d 與 stream s ，pull-level log error 為

$$\zeta_{it} = a_d + b_s + 0.5g_{dt} + 0.5h_{it}, \quad (60)$$

其中 $a_d \sim N(0, 0.025^2)$ 、 $b_s \sim N(0, 0.020^2)$ ， g_{dt} 與 h_{it} 分別是具持續性的 shared-day 與 idiosyncratic AR noise。每個 chunk 再加入 $N(0, 0.03^2)$ multiplicative noise，並依 chunk maximum 正規化為 0–100 後四捨五入。10% 的 nominal pulls 複製完整 latent realization 與 raw chunks，以模擬 exact cache/version duplicates。週、月 benchmark 由真實 index 的 period average 加入已知噪音產生。

Monte Carlo 使用 2024 年 366 個日資料、三個 collection days (0、1、7)、三 streams、120-day chunks、30-day steps，共 20 次 replications，seeds 1200–1219。這是程式驗證 DGP，不是對 Google proprietary mechanism 的宣稱。

12.2 結果

表 2: 20 次受控 Monte Carlo 結果

Estimator	Mean bias	Mean MAE	Mean RMSE	Corr.	Innovation corr.
Single pull	0.0000	5.6452	7.2305	0.9695	0.8869
Cross-pull median	-0.1464	3.1973	4.1710	0.9898	0.9556
Simple mean	0.0000	2.8660	3.7253	0.9919	0.9747
RACER-GT	-0.1317	2.7017	3.5265	0.9927	0.9745

相較 single pull，RACER-GT 的 mean RMSE 降低

$$1 - \frac{3.5265}{7.2305} = 51.2\%. \quad (61)$$

相較 simple mean 降低約 5.3%。RACER-GT 的 level correlation 最高，但 innovation correlation 與 simple mean 幾乎相同，且 simple mean 的 mean bias 接近零，主要是所有方法都以全期平均 100 正規化。這說明 RACER-GT 的優勢主要表現在跨時間點的均方重建誤差與 level fidelity，不應誇大為每一指標均嚴格支配所有基準。




圖 2: 不同重建方法的平均 RMSE。




圖 3: Level correlation、innovation correlation 與 top-5% peak recall。

這些模擬只驗證程式在一組已知 DGP 下的行為。正式論文應針對實際關鍵字的 zero share、波動性與 sample size 重新設計 factorial Monte Carlo，至少改變：sampling noise、shared dependence、rounding/censoring、graph sparsity、structural breaks、benchmark noise、exact-duplicate fraction 與 covariance misspecification。

13 建議的正式實驗規格

若研究目標是 2010–2026 年單一主題的日頻 GT 指標，建議的 confirmatory protocol 如表 3。表中門檻是合理起點，不是跨研究普遍常數；應在不查看財金 outcome 的 pilot simulation 中校準，再鎖定。

表 3: 建議的正式 RACER-GT protocol

項目	建議設定與理由
Historical window	固定 2010-01-01 至明確 month-end；Day 0–30 不可使用 expanding end date。
Daily chunks	先以約 180 日 window、15–30 日 step 建立密集 overlap；實際回傳頻率需程式驗證。
Collection days	0、1、2、7、14、21、30，以同時觀察短期 cache/版本相似與較長期穩定度。
Streams	至少三個固定 composite environments；平衡 stream order 與 time slot。
Replicates	最佳為每個 day × stream 兩次，產生 42 pulls；若資源限制為 21 pulls，明確承認 pure error 不可分離。
Raw archive	保存 response、numeric vectors、retrieval timestamp、query metadata、protocol hash、network events 與 client version。
Overlap calibration	Huber edges + global graph WLS；圖不連通原則上 FAIL，不以人工比例硬接。
Duplicates	Exact vectors 只在 analytic covariance 中 collapse；audit set 永久保留。Near duplicates 不刪除。
G-study	分別估 level、detection、innovation；以 28-day moving-block bootstrap 估 interval。
Consensus	Ledoit–Wolf covariance；非負 weights；weight cap 0.5 作預設，另報 unrestricted sensitivity。
Frequency benchmark	以多次擷取後的 weekly/monthly consensus 及其 SE 進行 soft benchmark；exact mode 作 robustness。

項目	建議設定與理由
Stop rule	Unique count、spectral effective count、 G/Φ 、convergence 與 component concentration 共同決定，不以 nominal 21 為充分條件。
Downstream model	主結果使用 final consensus；另以 sample-specific pulls、RC-OLS、SIMEX 與 full-pipeline bootstrap 檢查。

14 限制、敏感度分析與可延伸方向

14.1 無法由統計設計消除的限制

第一，若 Google 對所有 pulls 施加相同且隨時間變動的系統性演算法偏誤，重複量測無法僅靠平均或 GLS 識別；這是 common-mode bias。可利用 API overlap period、外部搜尋資料、新聞／交易事件與不同 query formulations 進行 external validation，但仍不是絕對真值。

第二，零值可能混合真實零搜尋、privacy threshold、sampling 與 rounding。RACER-GT 1.0.0 將零值保留並分離 detection reliability，但尚未內建 interval-censored latent count likelihood。對高 zero-share term，降為週頻、改用較廣 Topic 或 anchor-bank calibration，通常比強制製造日頻值更合理。

第三，G-theory 的 balanced method-of-moments 易於解釋，卻在 unbalanced missingness、負 variance components 或非 Gaussian binary detection 下不如 generalized linear mixed models。正式論文可將本實作作 preregistered primary estimator，再以 REML／Bayesian hierarchical model 作 robustness。

第四，benchmark 後的 1.0.0 信賴區間主要保留 cross-pull measurement uncertainty，尚未完整傳播 benchmark noise、scale calibration uncertainty 與 tuning-parameter uncertainty。最嚴謹方式是 nested moving-block bootstrap：每次重抽 historical blocks、重新估 edges、scales、duplicates、covariance、weights 與 benchmark，最後再重估財金模型。

第五，受限 GLS weights 的穩定性優於 unrestricted inverse covariance，但其最佳性取決於預先指定 constraint set。應報告 diagonal covariance、empirical covariance、Ledoit-Wolf、unrestricted GLS、equal weights 與 median 的 sensitivity table。

14.2 必要的穩健性檢驗

1. 不同 chunk lengths、steps、positive thresholds 與 reference strategies；
2. Huber、median 與 inverse-variance within-pull aggregation；
3. Exact duplicate collapse 與 multiplicity-weighted sensitivity；
4. Raw-rule、residual-rule thresholds 與 complete-linkage / maximal-clique diagnostics；
5. G-study negative-component truncation versus REML；
6. Consensus covariance estimators 與 weight caps；
7. Soft versus exact benchmark，不同 fidelity/smoothness weights；
8. 最新 vintage 與多個 historical vintages；
9. Topic versus search term、語言變體與非投資搜尋意圖排除；
10. 財金模型中的 lag structure、UTC / 市場時區、週末聚合與 publication delay。

14.3 與既有方法的關係

RACER-GT 並非取代既有研究，而是把其可互補部分放入同一個測量框架。Eichenauer et al. (2022) 提供 repeated draws 與 frequency consistency 的核心洞見；Bleher and Dimpfl (2022) 說明高頻長期 knitting；West (2020) 以 anchor bank 處理跨 query common scale 與 rounding；Cebrián and Domenech (2024) 指出 repeated pulls 的誤差與熱門程度密切相關；Medeiros and Pires (2021) 提醒單一 GT realization 可使 forecasting conclusion 偶然改變。RACER-GT 的新增層次在於：將 retrieval 本身明確設計為交叉測量實驗，以 graph GLS 解 within-pull scale，以 G-theory 決定蒐集資源，以 residual covariance 對相依 pulls 降權，再把 measurement uncertainty 傳至下游財金估計。

15 結論

長期日頻 GT 的核心問題不是「下載幾次才算獨立」，而是如何在無法觀察 proprietary sample assignment 的條件下，定義可識別 estimand、控制 retrieval design、估計分段尺度、分解誤差來源、處理相依量測，並將不確定性保留到財金模型。RACER-GT 的基本立場是：

不以 IP 取代獨立性證明；不以多數決刪除不一致 pulls；不以單一相關係數代表可靠度；不把通過資料品質決策誤稱為 **construct validity**；也不在下游模型中假裝建構後的 GT 沒有測量誤差。

在明列假設下，全域 overlap-graph WLS 可識別相對 chunk scales；G-theory 可量化 collection day、stream 與其交互作用；GLS 可依 residual covariance 將高度相依 pulls 自動降權；temporal benchmarking 可使日頻形狀與較低頻率尺度相容；EIV correction 則能處理 GT 作為解釋變數時的 attenuation。受控模擬顯示完整方法在本文 DGP 中相較單一 pull 與簡單聚合降低 RMSE，但真正的研究價值不只是較小的某一個誤差數字，而是一套可以預先註冊、稽核、重現、否決自身資料，並誠實傳遞不確定性的測量制度。

A Decision tree 的預設欄位

Rule	1.0.0 example	解釋
Minimum unique pulls	12	Exact-collapse 後的不同 numeric vectors。
Spectral effective pulls	4	相依性調整的資訊濃度下限。
Maximum zero share	0.80	避免資料由 threshold zeros 支配。
Minimum level G	0.80	Historical-date level ranking 的重現性。
Minimum innovation G	0.70	$\Delta \log(1 + Y)$ 的重現性。
Detection κ	0.60	只有 zero/nonzero 類別有變異時適用。
Maximum component share	0.50	避免單一 dependence component 支配。
Final convergence MAE/100	0.02	最後新增 pull 對 consensus 的邊際改變。
Benchmark standard-ized RMSE	研究前校準	取決於 benchmark SE 與 soft constraints。

這些值是 protocol choices，不是由統計定理產生的 universal constants。正式研究需以 pilot DGP、construct importance 與可接受 decision risk 校準。

B 輸入資料 schema

Raw chunk table 的必要 keys 為

```
series_id, pull_id, chunk_id, historical_date, value,  
collection_day, stream_id, replicate_id, window_start, window_end
```

強烈建議另存

```
retrieved_at, keyword, topic_or_term, geo, category,  
search_property, language, is_partial, protocol_hash,  
raw_response_hash, client_version, request_order, network_event
```

C 軟體測試與重現指令

本版本附九組單元／整合測試，涵蓋 design、overlap calibration、duplicates/consensus、G-study、benchmark、EIV 與 full pipeline。重現：

```
python -m pip install -e '.[dev]'  
pytest -q  
python examples/run_monte_carlo.py
```

套件亦提供 wheel、source archive、完整 README、資料字典、protocol template、Stata interoperability 與 Monte Carlo raw results。

參考文獻

- [1] Bleher, J., & Dimpfl, T. (2022). Knitting multi-annual high-frequency Google Trends to predict inflation and consumption. *Econometrics and Statistics*, 24, 1–26. <https://doi.org/10.1016/j.ecosta.2021.10.006>
- [2] Brennan, R. L. (2001). *Generalizability Theory*. Springer.
- [3] Cebrián, E., & Domenech, J. (2024). Addressing Google Trends inconsistencies. *Technological Forecasting and Social Change*, 202, 123318. <https://doi.org/10.1016/j.techfore.2024.123318>
- [4] Cook, J. R., & Stefanski, L. A. (1994). Simulation-extrapolation estimation in parametric measurement error models. *Journal of the American Statistical Association*, 89(428), 1314–1328. <https://doi.org/10.1080/01621459.1994.10476871>

- [5] Cronbach, L. J., Gleser, G. C., Nanda, H., & Rajaratnam, N. (1972). *The Dependability of Behavioral Measurements: Theory of Generalizability for Scores and Profiles*. Wiley.
- [6] Da, Z., Engelberg, J., & Gao, P. (2011). In search of attention. *The Journal of Finance*, 66(5), 1461–1499. <https://doi.org/10.1111/j.1540-6261.2011.01679.x>
- [7] Da, Z., Engelberg, J., & Gao, P. (2015). The sum of all FEARS: Investor sentiment and asset prices. *The Review of Financial Studies*, 28(1), 1–32. <https://doi.org/10.1093/rfs/hhu072>
- [8] Denton, F. T. (1971). Adjustment of monthly or quarterly series to annual totals: An approach based on quadratic minimization. *Journal of the American Statistical Association*, 66(333), 99–102. <https://doi.org/10.1080/01621459.1971.10482227>
- [9] Eichenauer, V. Z., Indergand, R., Martínez, I. Z., & Sax, C. (2022). Obtaining consistent time series from Google Trends. *Economic Inquiry*, 60(2), 694–705. <https://doi.org/10.1111/ecin.13049>
- [10] Fuller, W. A. (1987). *Measurement Error Models*. Wiley.
- [11] Google Search Central. (2025, July 24). Introducing the Google Trends API (alpha): A new way to access Trends data. <https://developers.google.com/search/blog/2025/07/trends-api>
- [12] Google Trends Help. (n.d.). FAQ about Google Trends data. <https://support.google.com/trends/answer/4365533>
- [13] Hölzl, J., Keusch, F., & Sajons, C. (2025). The (mis)use of Google Trends data in the social sciences. *Social Science Research*, 126, 103099.
- [14] Huber, P. J. (1964). Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, 35(1), 73–101. <https://doi.org/10.1214/aoms/1177703732>
- [15] Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4)

- [16] Medeiros, M. C., & Pires, H. F. (2021). The proper use of Google Trends in forecasting models. *arXiv:2104.03065*. <https://doi.org/10.48550/arXiv.2104.03065>
- [17] West, R. (2020). Calibration of Google Trends time series. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management* (pp. 2257–2260). <https://doi.org/10.1145/3340531.3412075>