

# RACER-GT：在重複抽樣、分段正規化與相依量測 下 建構長期日頻 Google Trends 指標

實驗設計、全域重疊圖校準、廣義信度理論與共變異數調整估計

Yi-Hao Lai and RACER-GT contributors

方法論與軟體技術報告，版本 1.0.0

2026 年 7 月 27 日

## 摘要

Google Trends (GT) 已廣泛用作投資人注意力、資訊需求與情緒的高頻代理變數；然而，網站版 GT 的每次請求會重新縮放為 0–100，長期日頻資料往往必須切割為多個短視窗，且在相同查詢設定下重複下載仍可能出現不同數值。若研究者只下載一次、逐段接合後直接投入財金模型，分段尺度誤差、重複量測相依性、低搜尋量的零值與四捨五入，以及下游解釋變數的 measurement-error attenuation，均可能扭曲估計與預測結論。

本文提出 RACER-GT (Randomized Acquisition, Calibration, Error Decomposition, and Reliability for Google Trends)，其核心不是宣稱能恢復 Google 的絕對搜尋次數，而是先明確定義兩個可識別的統計目標：固定查詢與取得設計下的 GT 期望回傳值，以及共同尺度下的潛在相對搜尋訊號。方法依序結合：(一) 可預先註冊的平衡重複取得實驗與 protocol hash；(二) 使用所有重疊區間的全域圖形加權最小平方法，以避免 sequential stitching 的誤差累積；(三) 完整保留 exact duplicates，並以去除共同訊號後的殘差建立 near-duplicate dependence graph；(四) 將 historical date、collection day、collection stream 與 technical replicate 視為交叉 facets 的 Generalizability Theory；(五) 以誤差共變異數調整的 GLS / 穩定化最小變異凸組合重建日頻共識；(六) 以週頻與月頻資料進行二次規劃式 temporal benchmarking；(七) 分離 detection、level 與 daily-innovation reliability；以及(八) 將日頻 GT 的測量不確定性傳遞至下游 reliability-corrected OLS 與 SIMEX。

本文給出識別條件、無偏性與最小變異性之條件式證明、完整 decision tree，以及 Python 套件實作。20 次受控 Monte Carlo 在對齊資訊集後給出混合結果：跨

pull 聚合使平均 RMSE 由單一 pull 的 7.3519 降至 3.7421 (降低 49.1%，20 次重複全部改善)，相對跨 pull 中位數的 4.1710 亦降低 10.3%；temporal benchmarking 在估計量固定時另貢獻約 0.22 的 RMSE 降低 ( $p \approx 3 \times 10^{-12}$ )。但共變異數調整加權相對簡單平均 (3.7253) 並無可偵測的優勢 ( $-0.0167$ ， $p = 0.152$ )。對此最自然的解釋是依賴結構過於同質，因而 GLS 無可利用之處；本文進一步以四情境實驗直接檢驗該解釋，讓一部分 pull 額外共享一條跨設計因子的 cache 噪音，結果不支持它：GLS 在任一異質情境下均未顯著勝出，其中兩個情境顯著較差。診斷顯示約束並非原因（無約束解逐位相同），且機制運作正確（權重與殘差相關之相關係數  $-0.562$ ），剩下的解釋是以 9 個 pull 估計  $\Sigma$  所引入的誤差超過其效率增益。理論結果不受影響 ( $\Sigma$  已知時 GLS 仍為 BLUE)，受影響的是實務建議。校準階段亦得到同型結果：全域 overlap-graph 相對逐段 stitching 確實阻止了誤差沿接合鏈累積（成長比 1.12 對 4.75），但重建誤差差異在最有設定下仍為  $p = 0.098$ 。本文由此得到一個貫穿性的結論——各機制均按設計運作且可被量測證實，但其效果在點估計精度上是二階的；本框架的價值在於產生可被判斷的數列，而非更準的數列。這些結果不構成對所有關鍵字、地區與 GT 版本的普遍最優保證。

**關鍵詞：**Google Trends；投資人注意力；測量誤差；實驗設計；Generalizability Theory；圖形校準；GLS；temporal benchmarking；SIMEX

**研究定位聲明。**本文所稱「偏誤降低」與「無偏」均為相對於明確定義之 estimand，並建立在可檢驗或可敏感度分析的假設上。Google 未公開網站版 GT 的完整抽樣分配、random seed、sample ID 或伺服器配置，因此不可能僅由重複下載無條件證明其等於絕對搜尋量，也不能以不同 IP 位址直接推論樣本獨立。

## 目錄

|       |                                      |    |
|-------|--------------------------------------|----|
| 1     | 研究問題與方法論動機                           | 4  |
| 2     | 統計目標、不可識別性與可證明範圍                     | 5  |
| 2.1   | 三個不同的研究目標                            | 5  |
| 2.2   | 絕對搜尋量不可由網站版 GT 單獨識別                  | 6  |
| 2.3   | 設計式無偏性                               | 6  |
| 3     | 資料取得實驗與 protocol locking             | 8  |
| 3.1   | 交叉因素設計                               | 8  |
| 3.2   | 固定歷史窗、chunk manifest 與 protocol hash | 9  |
| 3.3   | Pilot 與 confirmatory batch 的分離       | 9  |
| 4     | 第一階段：每一 complete pull 的全域重疊圖校準       | 10 |
| 4.1   | 分段正規化模型                              | 10 |
| 4.2   | Robust edge estimation               | 10 |
| 4.3   | Graph WLS 識別與估計                      | 11 |
| 4.4   | 同日多 chunk 聚合                         | 13 |
| 4.5   | 與逐段 stitching 的直接比較                  | 14 |
| 4.6   | 真實 Google Trends 資料上的校準檢驗            | 15 |
| 4.6.1 | GT 的正規化會製造零資訊重疊                      | 15 |
| 4.6.2 | 比例假設在真實資料上成立                         | 16 |

|       |                                                         |    |
|-------|---------------------------------------------------------|----|
| 4.6.3 | 模擬器的 chunk 噪音高估約 4.5 倍 . . . . .                        | 16 |
| 4.6.4 | 一年的 chunk 為何看不到 F1，以及 F1 何時開始重要 . . . . .               | 17 |
| 5     | 第二階段：跨 pull 相依性、duplicates 與量測可靠度 . . . . .             | 18 |
| 5.1   | Exact duplicate audit . . . . .                         | 18 |
| 5.2   | Residual near-duplicate graph . . . . .                 | 18 |
| 5.3   | 三面向 Generalizability Theory . . . . .                   | 19 |
| 5.4   | Balanced ANOVA 的 method-of-moments components . . . . . | 20 |
| 6     | 第三階段：共變異數調整的潛在共識數列 . . . . .                            | 21 |
| 6.1   | Measurement model . . . . .                             | 21 |
| 6.2   | 有效 pull 資訊量 . . . . .                                   | 23 |
| 7     | 第四階段：日、週、月頻率一致化 . . . . .                               | 23 |
| 8     | 可靠度指標與預先鎖定的 decision tree . . . . .                     | 24 |
| 8.1   | Detection、level 與 innovation . . . . .                  | 24 |
| 8.2   | Acceptance rules . . . . .                              | 25 |
| 9     | 下游財金模型的 measurement-error correction . . . . .          | 25 |
| 9.1   | Attenuation bias . . . . .                              | 25 |
| 9.2   | SIMEX . . . . .                                         | 26 |
| 10    | 完整演算法 . . . . .                                         | 27 |
| 11    | Python 套件實作 . . . . .                                   | 27 |
| 11.1  | 設計原則 . . . . .                                          | 27 |
| 11.2  | 最小使用範例 . . . . .                                        | 29 |
| 12    | Monte Carlo 驗證 . . . . .                                | 29 |
| 12.1  | 資料生成過程 . . . . .                                        | 29 |
| 12.2  | 比較設計：資訊集必須對齊 . . . . .                                  | 30 |
| 12.3  | 結果 . . . . .                                            | 31 |
| 12.4  | 依賴異質性的直接檢驗 . . . . .                                    | 32 |
| 13    | 建議的正式實驗規格 . . . . .                                     | 34 |
| 14    | 限制、敏感度分析與可延伸方向 . . . . .                                | 35 |
| 14.1  | 無法由統計設計消除的限制 . . . . .                                  | 35 |
| 14.2  | 必要的穩健性檢驗 . . . . .                                      | 37 |
| 14.3  | 與既有方法的關係 . . . . .                                      | 38 |
| 15    | 結論 . . . . .                                            | 38 |
| A     | Decision tree 的預設欄位 . . . . .                           | 39 |
| B     | 輸入資料 schema . . . . .                                   | 39 |
| C     | 軟體測試與重現指令 . . . . .                                     | 40 |

# 1 研究問題與方法論動機

Google Trends 將搜尋活動轉化為相對搜尋興趣（relative search interest）指標，因其即時性與高頻特性，已被財金研究用來衡量投資人注意力、資訊需求與恐慌情緒，例如 Da, Engelberg, and Gao (2011, 2015) [10, 11] 以及後續的報酬、波動與交易量研究 [6, 25]。Ben-Rephael, Da, and Israelsen (2017) [1] 進一步指出，不同來源的注意力代理變數並不等價，這使 GT 本身的測量性質更值得單獨檢視。這類資料的經濟直覺很清楚：投資人未必進行交易，但通常會在形成交易意圖或受到市場事件刺激時先搜尋資訊。因此，搜尋活動可補足交易資料只記錄已實現行為的限制。

然而，GT 的便利性也容易掩蓋其測量結構。Google 官方說明指出，Trends 使用搜尋活動的樣本，將資料依時間與地區正規化，再縮放至 0–100；低搜尋量可能呈現為零。網站版每一次請求均在該次請求的範圍內重新縮放，而 2025 年公布的 API alpha 雖提供跨請求一致尺度，歷史範圍仍為滾動約 1,800 天，且數值仍不是絕對搜尋次數 [18, 17]。因此，若研究期橫跨 2010–2026 年，網站版資料通常仍需切成多個短視窗後重建。

既有研究已分別指出：GT 存在 sampling noise 與 frequency inconsistency [14]；不同時間下載相同查詢可能產生不一致結果 [5, 23]；低量關鍵字在 0–100 整數尺度下會遭受嚴重 rounding 與 censoring，因而需要 anchor calibration [29]；長期高頻資料可利用重疊視窗進行 knitting [2]。然而，若研究目的不只是在資料層面平滑一條曲線，而是要讓其進入財金計量模型，仍需同時回答下列問題：

1. 重複下載的 estimand 是什麼？「真實搜尋次數」是否可識別？
2. 如何以實驗設計控制 collection day、stream、request order 與 technical replicate？
3. 每一個 complete pull 內，各自被正規化的 chunks 如何放到共同尺度？
4. exact duplicates、near duplicates 與一般 sampling variation 應如何區分，而不進行 outcome-guided deletion？
5. 如何以 ANOVA / G-theory 分解誤差來源，並決定增加 days、streams 或 replicates 哪一項最有效？
6. 若 pulls 相互依賴，如何避免把 21 次下載錯當成 21 份獨立資訊？
7. 如何使日頻形狀與較可靠的週頻、月頻長期尺度一致？
8. GT 作為財金模型解釋變數時，如何修正 measurement-error attenuation？

RACER-GT 將上述問題整合為一條從資料取得到下游推論的可重現測量鏈。其流程如圖 1。




圖 1: RACER-GT 的完整估計鏈。每一層均保留輸入、輸出與稽核紀錄；非相同 pulls 不因偏離中位數而被刪除。

## 2 統計目標、不可識別性與可證明範圍

### 2.1 三個不同的研究目標

令  $Q$  表示已鎖定的 query specification，包括 term/topic、geo、category、search property、語言、固定歷史起訖日與 chunk manifest。令  $R$  表示 retrieval environment 與執行條件，例如 collection day、stream、time slot、request order、session state 以及網站端未被研究者觀察的抽樣狀態。網站版 GT 對歷史日  $t$  的回傳可抽象寫為

$$Y_t(Q, R) = \mathcal{N}_{Q,R}\{S_t(Q, R)\}, \quad (1)$$

其中  $S_t$  為 proprietary sampling 與 aggregation 後的搜尋訊號， $\mathcal{N}_{Q,R}$  包含 window-specific normalization、0–100 scaling、rounding、thresholding 與可能的統計處理。

本文區分三個 estimands。

**定義 2.1 (絕對搜尋量).**  $A_t(Q)$  為符合查詢構念的 *Google* 絕對搜尋次數。網站版 *GT* 不直接觀察  $A_t(Q)$ 。

**定義 2.2** (GT 設計期望). 在預先定義的 *retrieval distribution*  $\mathcal{R}$  下，

$$\theta_t(Q; \mathcal{R}) = \mathbb{E}_{R \sim \mathcal{R}} [Y_t(Q, R)]. \quad (2)$$

此 *estimand* 描述固定 *query protocol* 下 *GT* 系統的期望回傳值。

**定義 2.3** (共同尺度潛在相對訊號). 令  $X_t$  為在明確基準期  $\mathcal{B}$  下識別的相對搜尋指標，滿足

$$\frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} X_t = 100. \quad (3)$$

$X_t$  不代表絕對搜尋次數，而是不同 *chunks* 與 *pulls* 在校準後共享的相對尺度。

## 2.2 絕對搜尋量不可由網站版 GT 單獨識別

**命題 2.1** (絕對尺度不可識別). 假設網站版 *GT* 僅觀察某一 *window*  $W$  內經比例正規化的值

$$Y_t = 100 \frac{A_t}{\max_{\tau \in W} A_\tau}, \quad t \in W, \quad (4)$$

忽略 *rounding* 時，對任何常數  $c > 0$ ，序列  $A_t$  與  $cA_t$  產生完全相同的  $Y_t$ 。因此，沒有外部 *anchor* 或絕對量資訊時， $A_t$  的絕對尺度不可識別。

證明. 將  $A_t$  替換為  $cA_t$ ，則

$$100 \frac{cA_t}{\max_{\tau \in W} cA_\tau} = 100 \frac{cA_t}{c \max_{\tau \in W} A_\tau} = Y_t.$$

因此資料對所有  $c > 0$  都具有相同 *likelihood* / *observation mapping*，絕對尺度無法由  $Y_t$  唯一決定。□

這項結果界定了研究主張的上限：我們可以改善相對訊號的尺度一致性、降低重建誤差並量化可靠度，但不能把統計校準誤稱為「恢復真實搜尋次數」。

## 2.3 設計式無偏性

令  $R_1, \dots, R_m$  由預先鎖定的  $\mathcal{R}$  產生，並考慮

$$\bar{Y}_t = \frac{1}{m} \sum_{i=1}^m Y_t(Q, R_i). \quad (5)$$

**命題 2.2** (對 GT 設計期望的無偏性). 若  $R_i$  具有相同邊際分配  $\mathcal{R}$ ，則無論 *pulls* 之間是否

獨立，

$$\mathbb{E}(\bar{Y}_t) = \theta_t(Q; \mathcal{R}). \quad (6)$$

獨立性只影響  $\text{Var}(\bar{Y}_t)$ ，不影響此平均的期望。

證明. 利用期望的線性性：

$$\mathbb{E}(\bar{Y}_t) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}\{Y_t(Q, R_i)\} = \frac{1}{m} \sum_{i=1}^m \theta_t = \theta_t.$$

此推導不需  $R_i$  相互獨立。  $\square$

**說明 2.1.** 若取得設計不是由一個明確且固定的  $\mathcal{R}$  產生，例如 *Day 30* 使用擴張到「當日」的歷史終點，則每一 *pull* 的 *estimand* 不同，平均值不再對單一  $\theta_t$  無偏。這也是固定 *historical end date* 的理論理由。

實際的 RACER-GT 蒐集通常採分層且平衡的 **day  $\times$  stream  $\times$  replicate** 設計，而非假設所有 *pulls* 具有完全相同的條件分配。令  $h \in \mathcal{H}$  表示預先鎖定的 **design cell**， $\pi_h$  為研究者事先指定的目標權重，且

$$\theta_{th} = \mathbb{E}(Y_{thi} \mid H = h), \quad \theta_t^\pi = \sum_{h \in \mathcal{H}} \pi_h \theta_{th}, \quad \sum_h \pi_h = 1. \quad (7)$$

若 **cell**  $h$  完成  $n_h$  次有效重複量測，定義

$$\hat{\theta}_t^\pi = \sum_{h \in \mathcal{H}} \pi_h \bar{Y}_{th}, \quad \bar{Y}_{th} = \frac{1}{n_h} \sum_{i=1}^{n_h} Y_{thi}. \quad (8)$$

**命題 2.3 (分層設計估計量的無偏性).** 若每一 *design cell* 內的有效量測均以不依賴其未觀察回傳值的規則納入，且  $\mathbb{E}(Y_{thi} \mid H = h) = \theta_{th}$ ，則

$$\mathbb{E}(\hat{\theta}_t^\pi) = \theta_t^\pi, \quad (9)$$

即使同一 *cell* 內或不同 *cells* 之間的 *pulls* 相關，結論仍成立。相關性只改變變異數與有效資訊量。

證明. 由條件期望與線性性，

$$\mathbb{E}(\hat{\theta}_t^\pi) = \sum_h \pi_h \mathbb{E}(\bar{Y}_{th}) = \sum_h \pi_h \theta_{th} = \theta_t^\pi.$$

推導不需假設  $\text{Cov}(Y_{thi}, Y_{th'j}) = 0$ 。但若 **failed requests**、**partial responses** 或事後刪除與未觀察的  $Y_{thi}$  有關，則 **cell mean** 可能產生 **informative-missingness bias**，故 **raw audit** 與預先指定排除規則不可省略。  $\square$

平衡設計是  $\pi_h = 1/|\mathcal{H}|$  的特例；若某些 collection days 或 streams 在目標 retrieval distribution 中應有不同權重，必須在看見資料前指定  $\pi_h$ ，而不是依結果調整。

### 3 資料取得實驗與 protocol locking

#### 3.1 交叉因素設計

RACER-GT 將取得程序視為 repeated-measurement experiment，而非將每次下載模糊地稱為「獨立樣本」。基本設計為

$$D \times S \times R, \quad (10)$$

其中  $D$  為 collection-day levels、 $S$  為 collection streams、 $R$  為每個 day  $\times$  stream cell 內的 technical replicates。本文建議的起始設計為 Day 0、1、2、7、14、21、30，三個固定 streams；若資源允許， $R = 2$  可將 pure technical error 與最高階交互作用分離。若僅  $R = 1$ ，仍可估計 day 與 stream facets，但  $TDS$  與純 replication error 無法分離。

**說明 3.1** (為何 collection day 是承重的 facet). 本設計把 *collection day* 視為獨立 *facet*，理由是平台似乎以「日」為週期重新抽樣，而非每次請求重抽。Djorno et al. (2026) 報告重複的相同請求會在 24 小時內由 *cache* 提供，並於 UTC 午夜 *cache* 重置時抽取新樣本。

由此有兩個推論。第一，同一日內的重複取得無法買到關於抽樣誤差的獨立資訊，因此證據累積的有效速率上限是每日一筆新抽樣；任何以重複 *pulls* 平均來降低抽樣變異的程序——包括 Eichenauer et al. (2022) 所建議者——都是以日曆時間換取精度，這正是它在即時應用上尷尬之處。

第二，此機制給出一個可用以檢驗本框架的預測：若日 *cache* 嚴格成立，式 (26) 中的 *technical-replicate* 變異成分應與零無法區分，而第 6.1 節保留的 *exact duplicates* 就不是待清除的雜訊，而是 *cache* 的直接可觀察證據。反之，若該成分明顯大於零，則日 *cache* 的描述對所處理的 *query* 而言並不完整。此處陳述該預測是因為它的檢驗成本很低，且兩種結果都有資訊價值；本文不假設它成立，亦無任何結果依賴它。

Collection stream 應被定義為固定的複合環境：裝置、瀏覽器 profile、cookie、登入狀態、client 版本、網路與 IP 等條件在 stream 內保持不變。除非另行採用 crossover factorial design，估計出的  $S$  effect 只能稱為 composite stream effect，不能拆解為 IP effect。



為避免 stream 與 request order 或 time slot 完全混淆，RACER-GT 以 cyclic / Latin-square-like rotation 平衡每一天的 stream order；chunk order 亦可輪替。若三個 streams 無法同時啟動，這種平衡至少能使系統狀態隨時間的變化不固定落在同一個 stream。

### 3.2 固定歷史窗、chunk manifest 與 protocol hash

所有正式 pulls 必須共用：

- 相同的 historical start 與 end；
- 相同的 chunk start/end、overlap 與 query parameters；
- 相同的資料清理、partial-period 排除與時區規則；
- 相同的 calibration、duplicate、G-study、consensus 與 decision thresholds；
- 相同版本的程式碼與設定檔。

設定物件以 canonical JSON 序列化並計算 SHA-256：

$$h = \text{SHA256}\{\text{canonical}(Q, \mathcal{D}, \mathcal{C}, \mathcal{T})\}, \quad (11)$$

其中  $\mathcal{D}$  是蒐集設計， $\mathcal{C}$  是校準設定， $\mathcal{T}$  是 decision thresholds。每筆 raw row 可保存  $h$ ，若任何設定被改動，protocol hash 即改變。

### 3.3 Pilot 與 confirmatory batch 的分離

Day 0–2 的 MONITOR 可用來檢查缺漏、query drift、exact duplicates、overlap graph 是否連通與程式執行錯誤；但若研究團隊因此修改 thresholds、stitching rule、query、code 或 decision tree，Day 0–2 必須被重新標記為 pilot，正式 confirmatory batch 由新的 Day 0 開始。否則同一資料同時被用來設計與驗證規則，形成 data-dependent acceptance bias。

同理，所有 GT 處理規則都必須在查看報酬、波動、價差、VaR 或其他財金結果之前鎖定。以「哪種 GT 建構最顯著」作為資料品質決策，會將 measurement validation 變成 outcome-guided model selection。

## 4 第一階段：每一 complete pull 的全域重疊圖校準

### 4.1 分段正規化模型

令一個 complete pull 包含  $J$  個重疊 chunks。對 chunk  $j$  中歷史日  $t$  的正值觀察，考慮近似模型

$$Y_{jt} = a_j X_t \exp(\epsilon_{jt}), \quad a_j > 0, \quad (12)$$

其中  $a_j$  代表該次 chunk-specific normalization scale， $X_t$  是該 pull 內欲恢復的共同相對訊號。當  $t$  同時存在於 chunks  $j$  與  $k$  時，

$$r_{jkt} = \log Y_{jt} - \log Y_{kt} = \ell_j - \ell_k + \nu_{jkt}, \quad \ell_j = \log a_j, \quad (13)$$

且  $\nu_{jkt} = \epsilon_{jt} - \epsilon_{kt}$ 。

由於零值不能取  $\log$ ，且接近零的整數 RSV 會放大 ratio noise，RACER-GT 僅使用兩邊皆高於預先指定門檻  $c_{\min}$  的 overlap cells 估計 edge。零值本身不被插補為正值，但必須說明聚合階段的實際行為：當某一歷史日被多個 chunks 覆蓋、其中一部分回傳 0 而另一部分回傳正值時，下節的加權聚合結果為正值，因此該日在最終數列中不再是零。只有所有覆蓋該日的 chunks 都為 0 時，零值才會保留。這是聚合規則的推論，不是插補決策，但它改變了 detection reliability 所量測的對象，故 CalibrationResult.diagnostics 另行輸出 n\_dates\_with\_zero\_chunk 與 n\_dates\_zero\_masked\_by\_aggregation 供稽核。對高 zero-share 的關鍵字，應同時檢視這兩個數字，或改採較廣的 Topic 與較低頻率。

### 4.2 Robust edge estimation

對每一可用的 chunk pair  $(j, k)$ ，令  $\mathcal{O}_{jk}$  為重疊日期集合。edge location  $\delta_{jk} = \ell_j - \ell_k$  以 Huber M-estimator 估計：

$$\hat{\delta}_{jk} = \arg \min_{\delta} \sum_{t \in \mathcal{O}_{jk}} \rho_c(r_{jkt} - \delta), \quad (14)$$

其中

$$\rho_c(u) = \begin{cases} \frac{1}{2}u^2, & |u| \leq c, \\ c|u| - \frac{1}{2}c^2, & |u| > c. \end{cases} \quad (15)$$

這使極端 overlap cells 不至於完全決定尺度比。套件同時估計 robust scale 與 location variance  $\hat{v}_{jk}$ ，形成 edge weight  $w_{jk} = \min\{1/\max(\hat{v}_{jk}, v_{\min}), w_{\max}\}$ 。變異數下界  $v_{\min}$  與權重上界  $w_{\max}$  都是數值防護而非古典 M-estimation 理論的一部分：兩者共同限制任

一 edge 對全域解的影響力，因為恰好只有  $m_{\min}$  天且數值幾乎相同的 edge 會產生假性偏小的變異數。實作採用的  $\hat{v}_{jk}$  是 Huber 權重的有效樣本數版本，與教科書漸近式的差異詳見數學附錄。

### 4.3 Graph WLS 識別與估計

建立無向圖  $G = (V, E)$ ：每個 chunk 是 node，每個可估 edge 是一個 overlap relation。將所有 edge equations 堆疊為

$$\hat{\delta} = B\ell + \eta, \quad \mathbb{E}(\eta \mid B) = 0, \quad \text{Var}(\eta \mid B) = \Omega, \quad (16)$$

其中  $B$  是 oriented incidence matrix。由於只可識別相對尺度，固定一個 reference chunk  $r$ ，令  $\ell_r = 0$ ；刪除對應欄後得到  $B_{-r}$ 。估計量為

$$\hat{\ell}_{-r} = (B_{-r}'WB_{-r})^{-1}B_{-r}'W\hat{\delta}. \quad (17)$$

**命題 4.1** (相對尺度的識別). 固定一個 reference node 後， $\ell_{-r}$  可識別若且唯若 overlap graph  $G$  連通。此時  $B_{-r}$  具有滿 column rank， $B_{-r}'WB_{-r}$  對任意正定 diagonal  $W$  可逆。

證明. 圖論中，連通圖的 incidence matrix rank 為  $|V| - 1$ 。刪除任一 node 對應欄後， $B_{-r}$  rank 為  $|V| - 1$ ，等於其欄數。反之，若圖有  $K > 1$  個 components，incidence matrix rank 為  $|V| - K < |V| - 1$ ，即使固定單一 reference 仍存在至少  $K - 1$  個未識別的 component-level shifts。□

**命題 4.2** (Graph GLS 的條件式無偏性與效率). 在式 (16)、圖連通且  $W = \Omega^{-1}$  下，式 (17) 滿足

$$\mathbb{E}(\hat{\ell}_{-r} \mid B) = \ell_{-r}, \quad (18)$$

且為所有線性無偏估計量中的最小變異估計量。

證明. 無偏性由

$$\mathbb{E}(\hat{\ell}_{-r} \mid B) = (B'WB)^{-1}B'W\mathbb{E}(\hat{\delta} \mid B) = \ell_{-r}$$

得之（為簡潔略去下標  $-r$ ）。效率為 Gauss–Markov theorem 的直接應用。□

上述命題只說 graph WLS 在給定 edge 估計下是 BLUE，並未回答本文最關心的問題：相對於逐段 stitching 究竟好多少。失效模式 F1 過去只是文字主張。下述命題把它化為一個等式，並且只依賴 chunk 設計、不依賴雜訊水準。

**命題 4.3** (校準變異數即有效電阻). 將 *overlap graph* 視為電路，令 *edge*  $e$  的電導為其精度  $w_e = 1/\text{Var}(\hat{\delta}_e)$ 。則對任意 *chunk*  $j$  與 *reference*  $r$ ，

$$\text{Var}(\hat{\ell}_j - \hat{\ell}_r \mid B) = R_{\text{eff}}(j, r), \quad (19)$$

其中  $R_{\text{eff}}$  為加權圖 *Laplacian*  $L = B'WB$  意義下  $j$  與  $r$  之間的有效電阻。由此得兩個推論：

(i) 逐段 *stitching* 為同一估計量限制在一條 *spanning path* 上，其有效電阻是所經各 *edge* 電阻之和，因而隨接合數線性成長。這就是 *F1*，且為精確陳述而非比喻。

(ii) (*Rayleigh* 單調性) 在圖中增加任一 *edge* 不會提高任何一對節點間的有效電阻。因此

$$R_{\text{eff}}^{\text{graph}}(j, r) \leq R_{\text{eff}}^{\text{path}}(j, r) \quad \text{對所有 } j, \quad (20)$$

即全域圖校準在校準變異數上永不劣於任何逐段 *stitching*，且差距可在收集任何資料之前由設計本身算出。

證明. 以  $r$  為接地點，刪去對應列與欄後的 grounded Laplacian 恰為  $B'_{-r}WB_{-r}$ ，而式 (17) 的估計量共變異數為  $(B'_{-r}WB_{-r})^{-1}$ 。電網理論中，接地 Laplacian 逆矩陣的第  $j$  個對角元即為  $j$  至接地點的有效電阻，故得式 (19)。推論 (i) 因 *path* 為串聯電路，電阻相加。推論 (ii) 為 *Rayleigh* 單調性定理：增加 *edge* 等同增加並聯路徑，不會提高兩點間等效電阻。□

**說明 4.1** (這使 *F1* 成為可在設計階段計算的量). 式 (19) 中  $\text{Var}(\hat{\delta}_e) \approx \sigma^2/n_e$  ( $n_e$  為重疊天數， $\sigma$  為每日 *log-ratio* 離散度)，故  $\sigma^2$  在 *path* 與 *graph* 的比值中約掉：變異數降幅只是 *chunk* 設計的函數。以真實資料實測的  $\sigma = 0.0188$  換算成終端 *chunk* 的尺度標準差：

表 1: *chunk* 設計經式 (19) 所隱含的校準誤差，採  $\text{Var}(\hat{\delta}_e) = \sigma^2/n_e$ ， $\sigma$  取自一年、單一關鍵字的中位離散度。只有第一列可與資料對照，其餘為外推——見 *remark 4.2*。

| 設計（歷史跨度、視窗／步進）           | chunks | 降幅     | 逐段    | 全域圖   |
|--------------------------|--------|--------|-------|-------|
| 實測，由估計出的 <i>edge</i> 變異數 |        |        |       |       |
| 1 年，180 / 30             | 8      | 9.13×  | —     | —     |
| 外推，由理想化 <i>edge</i> 模型   |        |        |       |       |
| 1 年，180 / 30             | 8      | 10.5×  | 0.40% | 0.12% |
| 5 年，180 / 30             | 56     | 18.2×  | 1.15% | 0.27% |
| 15 年，180 / 30            | 178    | 20.1×  | 2.06% | 0.46% |
| 15 年，180 / 15（表 9 建議）    | 355    | 140.5× | 2.79% | 0.23% |

**說明 4.2** (本表哪些是實測、哪些不是). 恆等式 (19) 與序關係式 (20) 是定理，不需要資料。但表中的數字是另一回事：其兩項假設被用來校準它的同一年資料所否認，且兩者都朝著對本文結論有利的方向偏，因此明列而非留給讀者自行發現。

**理想化 edge 模型高估降幅約 15%。**在唯一可雙向計算的設計上，由估計出的 *edge* 變異數得  $9.13\times$ ，理想化模型得  $10.5\times$ ：26 條重疊中有 5 條退化、取的是 *variance floor* 而非  $\sigma^2/n_e$ ，且 *Huber* 權重使  $n_{\text{eff}} < n_e$ 。外推各列沒有這道檢查。

**$\sigma$  不是常數。**21 條有效重疊的  $\sigma$  在單一年度之內即相差 1.75 倍，且與該對的數值水準相關  $-0.760$  ( $p = 0.0001$ )，正是捨入下限  $1/(\sqrt{12}v)$  所預測者。15 年序列涵蓋的搜尋量變化遠大於一年，低搜尋量時期的  $\sigma$  更大，故後三列的絕對百分比為低估。比值較穩健，因  $\sigma$  在 *path* 與 *graph* 之間大致約掉，但一旦  $\sigma$  跨 *edge* 變動便不會完全約掉。

射程也應直說：一年、一個關鍵字、一個 *pull*，外推十五倍。「F1 在長期設計下具實質意義」是命題 4.3 的預測，不是量測結果。要檢驗它需要長跨度的實際收集，表 9 已規定其規格，本文尚未執行。

1.4.0 起，`CalibrationResult.diagnostics` 直接輸出 `max_log_scale_variance`、`sequential_max_log_scale_variance` 與兩者之比 `calibration_variance_reduction`。

若  $\widehat{\ell}_j$  近似常態且  $\text{Var}(\widehat{\ell}_j) = s_j^2$ ，直接使用  $\exp(-\widehat{\ell}_j)$  會有 *lognormal transformation bias*。若校準目的為將  $Y_{jt}$  除以  $a_j$ ，可採一階修正

$$\widehat{a_j^{-1}}_{bc} = \exp\left(-\widehat{\ell}_j - \frac{1}{2}s_j^2\right). \quad (21)$$

此修正依賴近似常態與 *variance estimate*，故程式允許關閉作為 *sensitivity analysis*。

## 4.4 同日多 chunk 聚合

校準後的 *chunk observation* 為

$$\widetilde{X}_{jt} = Y_{jt} \exp(-\widehat{\ell}_j). \quad (22)$$

同一歷史日通常被多個重疊 *chunks* 覆蓋。RACER-GT 預設依 *chunk-scale variance* 進行 *inverse-variance aggregation*：

$$\widehat{X}_t^{(i)} = \frac{\sum_{j \in \mathcal{J}_t} \omega_{jt} \widetilde{X}_{jt}}{\sum_{j \in \mathcal{J}_t} \omega_{jt}}, \quad \omega_{jt} = \frac{1}{\widehat{\text{Var}}(\widehat{\ell}_j) + \varepsilon}. \quad (23)$$

亦可使用 *median* 或 *Huber aggregation*。最後依式 (3) 將每個 *complete pull* 的基準期平均設為 100。這一步明確定義相對 *index*，而非宣稱恢復絕對量。

逐段 *stitching* 只使用相鄰 *chunks*，前段 *edge error* 會遞迴傳遞至後續所有尺度；全域圖法同時使用所有可估計的重疊關係，能以 *graph cycles* 觀察不一致，並

輸出 normal-matrix condition number、weighted edge RMSE 與 component diagnostics。

## 4.5 與逐段 stitching 的直接比較

上述論證過去只有理論陳述，未經量測。examples/run\_calibration\_comparison.py 直接量測它：src/racergt/baselines.py 實作了逐段 stitching (Bleher and Dimpfl 式的 knitting)，使用完全相同的 Huber edge 估計器、相同的  $c_{\min}$  門檻與相同的基準期正規化，唯一差異是走一條 spanning path 而非解整張圖。因此任何精度差距都只能歸因於這個選擇。

表 2: 全域圖校準對逐段 stitching，每格  $20 \text{ seeds} \times 2 \text{ pulls}$ 。優勢欄為 sequential 減 graph 的 RMSE，正值表示全域圖較優。

| 設計            | 接合數 | Graph  | Sequential | 優勢      | MCSE   | $p$   | Graph 勝場 |
|---------------|-----|--------|------------|---------|--------|-------|----------|
| 60 日 step     | 5   | 7.4827 | 7.4677     | -0.0150 | 0.0053 | 0.008 | 13/40    |
| 30 日 step     | 9   | 7.3026 | 7.2967     | -0.0059 | 0.0049 | 0.234 | 15/40    |
| 15 日 step     | 17  | 7.2085 | 7.2125     | +0.0040 | 0.0072 | 0.576 | 15/40    |
| 15 日 step，低噪音 | 17  | 1.9245 | 1.9356     | +0.0111 | 0.0066 | 0.098 | 21/40    |

**機制成立，效果是二階的。**F1 所描述的累積現象確實存在且量級明確：在 15 日 step 設計下，逐段 stitching 所回復的 log scale，其跨重複標準差由鏈前段的 0.0259 增至鏈末段的 0.1228，成長 4.75 倍；全域圖法的對應比值僅 1.12。誤差確實沿接合鏈累積，而全域求解確實阻止了它。

但這並未轉化為可偵測的重建誤差優勢。趨勢的方向與 F1 一致——接合數由 5 增至 17 時，優勢由 -0.0150 轉為 +0.0040；將 retrieval noise 由 0.06 降至 0.01、使校準誤差在總誤差中佔更大比重時，優勢再升至 +0.0111——但即使在這個為 F1 量身打造的最有利設定下， $p = 0.098$ 、勝場 21/40，仍未達顯著。在接合數最少的設計下，全域圖法反而顯著較差 ( $p = 0.008$ )，原因是其參考 chunk 由 highest-degree 規則選出而非固定為第一個 chunk，且它額外施加了式 (21) 的對數常態修正。

**說明 4.3 (三個機制，同一個結論).** 這是本文第三次得到同型結果。共變異數調整加權能正確辨識並降權相依 pulls (權重與殘差相關之相關係數 -0.562)，但不改善 RMSE；依賴異質性的預測被直接檢驗後失敗；全域圖校準確實阻止了誤差沿鏈累積 (1.12 對 4.75)，同樣不改善 RMSE。

三者的共同結構是：機制按設計運作，且可被量測證實，但其效果在點估計精度上是二階的，被 retrieval noise 掩蓋。對使用者而言，這個結論比任何單一數字都重要——它指出本框架的價值不在於產生更準的數列，而在於產生可被判斷的數列。有效 pull

數、依賴結構、*cycle* 不一致統計量、每日條件標準誤與可傳遞的測量不確定性，都是 *RMSE* 無法表達也無法取代的資訊。

## 4.6 真實 Google Trends 資料上的校準檢驗

上一小節的所有證據都出自本套件自己的模擬器，而模擬器是依估計量所假設的比例模型抽樣的。這是循環論證：它能顯示估計量解出了我們交給它的問題，卻不能顯示那個問題就是真實的問題。本節把校準階段套用在真實下載的資料上：關鍵字 `bitcoin`、地區美國、日頻、2024 全年，180 天視窗、30 天步進共 8 個 `chunk`，1,440 筆觀測。轉換器為 `examples/ingest_trends_csv.py`，分析為 `examples/run_real_data_calibration.py`。

先說這份資料不能檢驗什麼。這是單一 *pull*——一個蒐集日、一個 `stream`、一次重複。跨 *pull* 的所有機制因此完全無法在此檢驗：共變異數調整的共識加權、`exact` 與 `near-duplicate` 診斷、三面向 *G-theory* 的變異成分、有效 *pull* 數、節 4.5 的 *RMSE* 比較，全都需要跨日、跨環境的重複收集。本節不觸及它們，也不對它們作任何宣稱。真正要檢驗完整設計，需要表 9 所述規格下為期一個月的收集計畫。此外，真實資料沒有 *latent truth*，因此無法計算重建誤差，兩個方法都不能被稱為較準確。

### 4.6.1 GT 的正規化會製造零資訊重疊

第一個發現是模擬器結構上產生不了的。GT 以該次請求視窗內的最大值正規化每個 `chunk`。若兩個視窗都涵蓋同一個峰值日，兩者就被同一個數除，取整後在重疊區逐格完全相同。本資料中 `C0001–C0003` 的最大值同為 2024-03-05、`C0004–C0005` 同為 2024-08-05、`C0007–C0008` 同為 2024-12-05，於是 26 條重疊 *edge* 中有 5 條的 *log ratio* 恆等於零且無離散度：8 個 `chunk` 實際上只構成 4 個正規化群。

這樣的 *edge* 不帶任何尺度資訊，卻仍以 `edge_variance_floor` 與 `max_edge_weight` 所允許的權重進入加權最小平方——那是數值安全常數，不是統計論證。`simulate_racergt_data` 在取視窗最大值之前先對每個 `chunk` 乘上連續的對數常態噪音；在其預設參數下，兩個 `chunk` 取整後逐格相同的機率微乎其微，實測 520 條模擬 *edge* 中零筆退化，真實資料 26 條中 5 筆。（把 `chunk_noise_sd` 設為 0 則模擬器也會產生退化 *edge*，但那不是它的預設，也不是先前證據所使用的設定。）1.4.0 因此在 `CalibrationResult.diagnostics` 新增 `n_zero_dispersion_edges`、`n_informative_edges` 與 `n_scale_groups` 三個鍵。它們只作報告，不改變任何估計值；退化 *edge* 的處理是使用者的判斷，本套件不代為決定。

退化率取決於數列的峰值結構，不可由單一關鍵字外推。機制本身是演繹的（共用視窗最大值  $\Rightarrow$  重疊區同一組整數），但比例是實證問題。

#### 4.6.2 比例假設在真實資料上成立

校準階段整個建立在「重疊的 chunk 至多差一個常數比例」之上。重疊長達 150 天，此假設被高度過度識別，可直接檢驗。

表 3: 真實資料上的校準診斷。bitcoin、美國、日頻、2024 年，8 個 chunk，單一 pull。

| 診斷量                            | 數值                                |
|--------------------------------|-----------------------------------|
| 重疊圖是否連通                        | 是                                 |
| Edge 數 (spanning path 僅用 7 條)  | 26                                |
| 獨立 cycle 數                     | 19                                |
| 可檢驗的三角形數                       | 45                                |
| Normal matrix condition number | 10.82                             |
| Weighted edge RMSE             | 0.001379                          |
| 零離散度 edge                      | 5 / 26                            |
| 正規化群數                          | 4 (共 8 個 chunk)                   |
| 三角形閉合誤差中位數                     | 0.001783 log points               |
| 三角形閉合誤差最大值                     | 0.011769 log points (尺度誤差 1.184%) |
| 重疊內漂移 $p < 0.05$ 的比例           | 1 / 21 (隨機期望 1.05)                |
| 校準後殘餘錯尺度最大值                    | -0.032% (全部 $ t  < 0.6$ )         |

三角形閉合檢定是本框架相對逐段 stitching 的核心優勢之一，且逐段 stitching 在結構上無法提供：模型要求任意三個互相重疊的 chunk 滿足  $d_{ij} + d_{jk} = d_{ik}$ ，而 stitching 只使用路徑上的 edge，既看不到也報告不了違反。45 個三角形的閉合誤差中位數為 0.0018 log points，最大 0.0118 (相當於 1.18% 的尺度誤差)。21 條有效重疊中僅 1 條的漂移檢定  $p < 0.05$ ，隨機期望為 1.05。校準後每個 chunk 對重建數列的平均對數偏離全部不顯著，最大者僅 -0.032%。比例假設沒有被真實資料推翻。

#### 4.6.3 模擬器的 chunk 噪音高估約 4.5 倍

這份資料無法檢驗 F1，卻能決定性地檢驗另一件事：模擬器描述得對不對。SimulationSettings 的 chunk\_noise\_sd 預設 0.03，在取最大值前對每個 chunk 每一天乘上獨立的對數常態擾動。真實資料的重疊 log ratio 離散度中位數為 0.0188。

以封閉式的整數捨入下限相減會得到 0，但那個下限假設兩個 chunk 獨立捨入。實際上兩者捨入的是只差一個尺度因子的同一組數字，捨入誤差高度相關，封閉式因而高估下限，並使推得的噪音偏向零——正是對本結論有利的方向。本文因此不採用它，改以參數化 bootstrap 直接重現生成機制：取校準後的日頻數列，乘上指定強度的 chunk 噪音，除以視窗最大值，取整，再用與真實資料完全相同的方式計算離散度。



表 4: 掃描 `chunk_noise_sd` 並與觀測到的重疊離散度 0.018814 比對。每格 200 次重複。

| $\sigma_{\text{chunk}}$ | 重疊離散度中位數 | 對觀測值之比 |
|-------------------------|----------|--------|
| 0 (僅整數捨入)               | 0.017757 | 0.94   |
| 0.005                   | 0.017644 | 0.94   |
| 0.0066 (配適值)            | 0.018814 | 1.00   |
| 0.010                   | 0.021892 | 1.16   |
| 0.020                   | 0.033624 | 1.79   |
| 0.030 (模擬器預設)           | 0.046424 | 2.47   |

僅整數捨入就解釋了觀測離散度的 94%；配適值為  $\sigma_{\text{chunk}} \approx 0.0066$ ，約為模擬器預設的  $1/4.5$ 。低於約 0.005 時曲線在 Monte Carlo 誤差內持平，捨入主導，該區間不可識別；但 0.03 會產生 2.47 倍於觀測值的離散度，可被明確排除。

這對節 4.5 的解讀是加強而非否定：該比較是在校準噪音被高估數倍的情境下進行的，而即使在那個對 F1 有利的情境中，全域圖仍未取得可偵測的精度優勢。以真實噪音水準重跑只會讓差距更小。

#### 4.6.4 一年的 chunk 為何看不到 F1，以及 F1 何時開始重要

兩個方法在真實資料上幾乎不可區分：相關係數 1.000000，逐日相對差中位數 0.00026、最大 0.00123，在 0–100 的指數尺度上最大絕對差僅 0.195 點。

**說明 4.4** (一個必須指出的方法錯誤). 以「兩方法點估計之差是否隨鏈位置成長」來檢驗 *F1* 是錯的估計量。*F1* 是關於變異數的主張，而單一 *pull* 只提供一個 *realization*；由  $n = 1$  無從估計變異數，該檢定的檢定力在建構上即為零，與資料量無關。命題 4.3 使抽樣完全不必要：變異數比即有效電阻比，是設計的確定性函數。

依命題 4.3 計算本設計：全域圖的最大  $\text{Var}(\hat{\ell}_j) = 1.01 \times 10^{-6}$ ，spanning path 為  $9.26 \times 10^{-6}$ ，\*\* 降幅 9.13 倍 \*\*，且降幅沿鏈位置單調成長 ( $2.1 \times \rightarrow 9.1 \times$ )。\*\*F1 的機制確實在運作\*\*，且其大小可精確算出，不需任何檢定。

但換算成絕對尺度，本設計下逐段 stitching 的終端誤差僅 0.40%、全域圖 0.12%。\*\* 比值大、絕對值小 \*\*，兩者並不矛盾——這正是一年設計看不到差異的原因，也是先前三次模擬實驗得到 null 的原因。

**說明 4.5** (F1 在本文建議的 protocol 下被預測為實質). 表 1 將誤差沿歷史跨度外推：15 年、180 日視窗、15 日步進——即表 9 所建議的規格——逐段 stitching 的終端尺度誤差約為 2.79%，全域圖約為 0.23%。對一條橫跨 15 年的注意力指數而言，此量級的端點尺度偏誤是一個緩慢漂移，形態上與趨勢難以區分，正是 GT 文獻反覆警告的 *artificial low-frequency drift*。remark 4.2 說明這兩個數字所依賴的前提；它們是命題 4.3 的預測，不是量測結果。

因此本文對  $F1$  的正確陳述是：機制為真、可被證明（命題 4.3）、且被預測在建議規模下具實質意義；本文一年份的實測之所以看不到它，是因為該設計的絕對誤差上限只有 0.40%。節 4.5 與節 12 的 *null results* 並非  $F1$  的反證，而是命題 4.3 的直接預測：在短鏈上有效電阻差距的絕對值必然微小。

這也修正了 *remark 4.3* 的解讀。先前三次的共同結論是「機制成立但效果二階」；命題 4.3 說明其中至少校準這一項並非二階，而是規模相依——效果隨接合數成長，而先前所有實驗都在效果最小的一端進行。全域圖校準值得採用的理由，除了表 3 中逐段 *stitching* 結構上無法提供的診斷之外，還有式 (20) 給出的無條件保證：它永不更差。

## 5 第二階段：跨 pull 相依性、duplicates 與量測可靠度

### 5.1 Exact duplicate audit

對每一 complete pull 的 numeric vector 以固定 decimal rounding 後計算 SHA-256。完全相同的向量不應從 raw archive 消失，因其 multiplicity、collection days、streams 與 raw-response hashes 本身就是 cache / 共同版本 / 重複執行的證據。RACER-GT 採雙層資料：

- audit set：保留所有 nominal pulls 與 exact duplicates；
- analytic unique-vector set：在 consensus covariance estimation 中，每個完全相同向量保留一個 representative，並另存 multiplicity map。

Chunk-level duplicates 與 full-series duplicates 應分別檢查；僅看完整向量可能漏掉部分 chunks 被重複回傳的情況。

### 5.2 Residual near-duplicate graph

原始 GT pulls 都共享相同的歷史訊號，因此 raw-series correlation 本來就會非常高。若以 raw correlation 作為共同抽樣或 cache dependence 的唯一依據，容易將正常的共同訊號誤判為依賴。RACER-GT 先定義 preliminary common signal

$$m_t = \text{median}_i Z_{it}, \quad (24)$$

再移除 pull-specific mean bias

$$b_i = \frac{1}{T} \sum_t (Z_{it} - m_t), \quad e_{it} = Z_{it} - m_t - b_i. \quad (25)$$

Near-duplicate edge 必須同時通過預先指定的 value-anchored rule，例如 raw correlation、exact-cell agreement、MAE/100、positive-day Jaccard，以及 residual correlation。Connected component 只表示成員透過 edge chain 連接，不表示 component 中每一對都相似；因此報告 density、diameter、maximum clique、articulation points、minimum within-component correlations 與 maximum MAE。

Near-duplicate graph 只作依賴診斷與 covariance 建模；除 exact numeric duplicates 外，RACER-GT 不因某 pull 偏離中位數或降低 reliability 而刪除它。

### 5.3 三面向 Generalizability Theory

令  $t = 1, \dots, T$  為 historical dates， $d = 1, \dots, D$  為 collection-day levels， $s = 1, \dots, S$  為 streams， $r = 1, \dots, R$  為 technical replicates。完全交叉隨機效果模型為

$$Y_{tdsr} = \mu + T_t + D_d + S_s + (TD)_{td} + (TS)_{ts} + (DS)_{ds} + (TDS)_{tds} + E_{tdsr}. \quad (26)$$

各隨機成分期望為零、彼此不相關，variance components 記為

$$\sigma_T^2, \sigma_D^2, \sigma_S^2, \sigma_{TD}^2, \sigma_{TS}^2, \sigma_{DS}^2, \sigma_{TDS}^2, \sigma_E^2.$$

RACER-GT 對三種轉換分別執行 G-study：

$$\text{Level: } Y_{tdsr}, \quad (27)$$

$$\text{Detection: } I(Y_{tdsr} > 0), \quad (28)$$

$$\text{Innovation: } \Delta \log(1 + Y_{tdsr}). \quad (29)$$

這樣可避免一個單一 ICC 混合「是否被偵測到」、「數值水準是否一致」與「日變化是否一致」。

對平均  $n_D$  個 collection days、 $n_S$  個 streams 與  $n_R$  個 replicates 的相對決策，誤差 variance 為

$$\sigma_\delta^2 = \frac{\sigma_{TD}^2}{n_D} + \frac{\sigma_{TS}^2}{n_S} + \frac{\sigma_{TDS}^2}{n_D n_S} + \frac{\sigma_E^2}{n_D n_S n_R}. \quad (30)$$

Generalizability coefficient [27] 為

$$G(n_D, n_S, n_R) = \frac{\sigma_T^2}{\sigma_T^2 + \sigma_\delta^2}. \quad (31)$$

若研究關心相對排名之外的絕對水準，還要加入 day、stream 與  $DS$  effects：

$$\sigma_{\Delta}^2 = \sigma_{\delta}^2 + \frac{\sigma_D^2}{n_D} + \frac{\sigma_S^2}{n_S} + \frac{\sigma_{DS}^2}{n_D n_S}, \quad (32)$$

$$\Phi(n_D, n_S, n_R) = \frac{\sigma_T^2}{\sigma_T^2 + \sigma_{\Delta}^2}. \quad (33)$$

## 5.4 Balanced ANOVA 的 method-of-moments components

令  $a = T, b = D, c = S$ ，先對  $R$  replicates 取 cell mean。Balanced ANOVA 的 expected mean squares 可寫為

$$\mathbb{E}(MS_{TDS}) = \sigma_E^2/R + \sigma_{TDS}^2, \quad (34)$$

$$\mathbb{E}(MS_{TD}) = \sigma_E^2/R + \sigma_{TDS}^2 + c\sigma_{TD}^2, \quad (35)$$

$$\mathbb{E}(MS_{TS}) = \sigma_E^2/R + \sigma_{TDS}^2 + b\sigma_{TS}^2, \quad (36)$$

$$\mathbb{E}(MS_{DS}) = \sigma_E^2/R + \sigma_{TDS}^2 + a\sigma_{DS}^2, \quad (37)$$

$$\mathbb{E}(MS_T) = \sigma_E^2/R + \sigma_{TDS}^2 + c\sigma_{TD}^2 + b\sigma_{TS}^2 + bc\sigma_T^2, \quad (38)$$

並對  $D, S$  對稱。因此 method-of-moments estimator 例如

$$\hat{\sigma}_{TD}^2 = \frac{MS_{TD} - MS_{TDS}}{c}, \quad (39)$$

$$\hat{\sigma}_T^2 = \frac{MS_T - MS_{TD} - MS_{TS} + MS_{TDS}}{bc}. \quad (40)$$

若  $R > 1$ ， $MS_E$  由 cell 內殘差估計，且

$$\hat{\sigma}_{TDS}^2 = MS_{TDS} - MS_E/R. \quad (41)$$

若  $R = 1$ ， $E$  無法分離，實作將不可分部分歸入  $TDS$ 。負的 method-of-moments components 可報告原值並依 protocol 選擇截為零 [26]；正式推論應另用 REML sensitivity analysis。由於 historical dates 具時間相依，係數信賴區間採 moving-block bootstrap，而非把  $T$  天當成獨立單位。

D-study 將式 (31) and (33) 代入不同的  $(n_D, n_S, n_R)$ ，直接回答「下一筆資源應投入增加日期、streams 或 technical replicates」。因此 nominal pull count 不是充分的停止規則。

## 6 第三階段：共變異數調整的潛在共識數列

### 6.1 Measurement model

將每一個 calibrated unique pull 在相同基準期重新設為平均 100 後，對歷史日  $t$  寫成

$$\mathbf{Z}_t = \mathbf{1}X_t + \mathbf{e}_t, \quad \mathbb{E}(\mathbf{e}_t) = \mathbf{0}, \quad \text{Var}(\mathbf{e}_t) = \Sigma. \quad (42)$$

$\mathbf{Z}_t$  為  $m \times 1$  vector。Near duplicates 對應  $\Sigma$  中較高的 off-diagonal covariance；因此它們不應被簡單計為多份獨立 evidence。

**說明 6.1** (從  $\theta_t$  到  $X_t$  的橋接假設). 命題 2.3 與 2.4 的 *estimand* 是  $GT$  設計期望  $\theta_t(Q; \mathcal{R})$ ，而式 (42) 的 *estimand* 是共同尺度潛在訊號  $X_t$ 。兩者不是同一個量，其連結需要兩個必須明示的條件。

第一是**比例性**：存在與  $t$  無關的  $c > 0$  使  $\theta_t = cX_t$ ，亦即在固定 *protocol* 下  $GT$  的期望回傳值與潛在相對訊號成比例。這排除了隨時間變動的系統性演算法偏誤，而該假設不可由重複量測本身檢驗（見第 14.1 節的 *common-mode bias*）。

第二是**校準誤差可忽略**： $Z_{it} = Y_{it} \exp(-\hat{\ell}_{j(i)})$  涉及估計量的非線性變換，一般而言  $\mathbb{E}[Y \exp(-\hat{\ell})] \neq a^{-1}\mathbb{E}[Y]$ ，因為  $\exp(\cdot)$  為凸函數且  $\hat{\ell}$  帶估計誤差。式 (21) 的一階修正使  $\mathbb{E}[\exp(-\hat{\ell}_j)] = a_j^{-1}\{1 + O(n^{-1})\}$ ，其中  $n$  為該 *chunk* 可用的重疊日數。因此式 (42) 的  $\mathbb{E}(\mathbf{e}_t) = \mathbf{0}$  是  $O(n^{-1})$  意義下的近似，不是精確結果。

命題 7.1 的無偏性與最小變異性應在這兩個條件下閱讀。本文不宣稱它們可由資料驗證：前者需要外部效標，後者隨重疊設計加密而改善。

**說明 6.2** (為何預設不移除 pull-specific additive bias). 1.0.0 版預設在此處對每個 *pull* 減去  $b_i = T^{-1} \sum_t (Z_{it} - m_t)$ ，其中  $m_t$  為逐日中位數。但基準期重設已使每個 *pull* 滿足  $T^{-1} \sum_t Z_{it} = 100$ ；當基準期等於歷史全區間 (QuerySpec 的預設回填) 時，

$$b_i = 100 - \frac{1}{T} \sum_t m_t \quad (43)$$

對所有  $i$  相同。該步驟因此不移除任何 *pull* 之間的相對差異，只是把整條共識序列平移「平均數與中位數之差」，並直接違反式 (42) 的  $\mathbb{E}(\mathbf{e}_t) = \mathbf{0}$ 。在受控模擬中它使 *mean bias* 由機器精度惡化為  $-0.1464$ ，且 20 次重複的 *RMSE* 全部劣化。

1.1.0 版將 `center_pull_bias` 預設改為關閉，並在 *diagnostics* 輸出 `pull_bias_cross_pull_sd`——該值接近零即表示 *centring* 項不帶任何 *pull-specific* 資訊——使此退化情形保持可稽核。僅在關閉 *baseline rescale* 且確實預期存在加法性 *pull offset* 時，才應啟用該選項。

考慮線性共識  $\hat{X}_t = \mathbf{w}'\mathbf{Z}_t$ 。若  $\mathbf{1}'\mathbf{w} = 1$ ，則

$$\mathbb{E}(\hat{X}_t) = X_t, \quad (44)$$

而 variance 為  $\mathbf{w}'\Sigma\mathbf{w}$ 。

**命題 6.1 (GLS 共識).** 若  $\Sigma$  正定且已知，所有滿足  $\mathbf{1}'\mathbf{w} = 1$  的線性無偏估計量中，

$$\mathbf{w}^* = \frac{\Sigma^{-1}\mathbf{1}}{\mathbf{1}'\Sigma^{-1}\mathbf{1}} \quad (45)$$

使  $\text{Var}(\hat{X}_t)$  最小，且

$$\text{Var}(\hat{X}_t) = \frac{1}{\mathbf{1}'\Sigma^{-1}\mathbf{1}}. \quad (46)$$

證明. 建立 Lagrangian

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}'\Sigma\mathbf{w} - 2\lambda(\mathbf{1}'\mathbf{w} - 1).$$

一階條件  $2\Sigma\mathbf{w} - 2\lambda\mathbf{1} = 0$ ，故  $\mathbf{w} = \lambda\Sigma^{-1}\mathbf{1}$ 。代入  $\mathbf{1}'\mathbf{w} = 1$  得式 (45)。正定  $\Sigma$  使目標嚴格凸，因此解唯一且為全域最小值。□

實務上  $\Sigma$  必須由有限歷史日的 residual matrix 估計。RACER-GT 預設使用 Ledoit-Wolf shrinkage，使 covariance 在  $m$  相對不小或 residuals 高度共線時仍可逆。為避免 sampling error 造成負權重與極端 extrapolation，預設解下列 convex quadratic program：

$$\min_{\mathbf{w}} \mathbf{w}'\hat{\Sigma}\mathbf{w} \quad \text{s.t.} \quad \mathbf{1}'\mathbf{w} = 1, \quad 0 \leq w_i \leq \bar{w}. \quad (47)$$

受限解保持 sum-to-one，因此在式 (42) 下仍線性無偏；但嚴格的 unrestricted BLUE 結論只適用式 (45)。權重上限是穩定化選擇，必須在 protocol 中預先鎖定。

若某日缺少少數 pulls，實作對當日可用權重重新正規化。條件式基礎標準誤為

$$\hat{se}_0 = \sqrt{\hat{\mathbf{w}}'\hat{\Sigma}\hat{\mathbf{w}}}. \quad (48)$$

為反映事件日可能具有較大跨 pull dispersion，1.0.0 版再以當日 absolute deviation median 相對於全期間 median 進行 bounded local multiplier。這是 pragmatic heteroskedastic adjustment，而非完整 Bayesian posterior interval；正式研究可另以 block bootstrap 重新執行全 pipeline。

## 6.2 有效 pull 資訊量

Nominal  $m$  無法反映相依性。對 residual correlation matrix  $R_e$ ，RACER-GT 報告 spectral participation ratio

$$m_{\text{eff}}^{\text{spectral}} = \frac{\text{tr}(R_e)^2}{\text{tr}(R_e^2)}. \quad (49)$$

當所有 residuals 完全共線，只有一個非零 eigenvalue， $m_{\text{eff}} = 1$ ；當 residuals 相互獨立， $R_e$  趨近  $I_m$  而  $m_{\text{eff}}$  趨近  $m$ 。

此處須注意一個實作層面的偏誤：式 (25) 的殘差是各 pull 減去由它們自己構成的逐日中位數，此運算必然在殘差間引入負相關，因此即使原始 pulls 完全獨立， $R_e$  也不會恰好是單位矩陣。以構造上獨立的序列模擬， $m = 9$  時  $m_{\text{eff}}$  平均約 8.57（低估 4.8%）， $m = 3$  時約 2.59（低估 13.7%）。偏誤方向是保守的——傾向低估資訊量因而傾向拒絕，而非誤放行——但這表示 min\_spectral\_effective\_pulls 門檻的實際嚴格度略高於其名目值，在小型設計上尤然。此量是資訊濃度診斷，不是對 proprietary sampling mechanism 的正式獨立樣本數證明。

另報告 Kish weight count [21]

$$m_{\text{eff}}^{\text{Kish}} = \frac{1}{\sum_i w_i^2}, \quad (50)$$

用以觀察共識是否被少數 pulls 支配。

## 7 第四階段：日、週、月頻率一致化

僅以短視窗日頻 chunks 接合，可能保留日際形狀卻失去長期尺度；Eichenauer et al. (2022) 稱此為 frequency inconsistency。令 preliminary daily consensus 為  $z \in \mathbb{R}^T$ ，lower-frequency benchmark 為  $b \in \mathbb{R}^K$ ，aggregation matrix  $A$  的第  $k$  列對 benchmark period  $k$  內日資料給予平均權重。

RACER-GT 的 soft benchmarking estimator 定義為

$$\hat{x} = \arg \min_x (x - z)'Q(x - z) + (Ax - b)'W(Ax - b), \quad (51)$$

其中

$$Q = (\lambda_I + \lambda_R)I + \lambda_D D_1' D_1, \quad (52)$$

$D_1$  是 first-difference matrix；此問題屬於 benchmarking 文獻中 movement-preservation 一族 [13, 7, 12]。 $\lambda_I$  控制對 preliminary signal 的忠實度； $\lambda_R$  是實作中獨立設定的 ridge，其唯一作用是在  $\lambda_I = 0$  時仍保證  $Q$  正定，因此兩者在數學上合併為

單一係數； $\lambda_D$  控制修正路徑的粗糙度， $W$  通常由 benchmark standard errors 的倒數平方組成。

一階差分懲罰的是修正路徑的斜率而非其曲率。預設的  $\lambda_D/\lambda_I = 10$  是一個相當強的平滑先驗，會使修正趨向低頻調整，在事件日附近可能系統性削弱日頻形狀——而事件日正是注意力指標最有研究價值的部分。此比值應在 pilot 階段校準並鎖定，正式研究亦應報告  $\lambda_D/\lambda_I \in \{1, 10, 100\}$  的敏感度。

**命題 7.1** (Soft benchmark 的唯一解). 若  $Q$  正定且  $W$  半正定，式 (51) 嚴格凸，唯一解為

$$\hat{\mathbf{x}} = \mathbf{z} + (Q + A'WA)^{-1}A'W(\mathbf{b} - A\mathbf{z}). \quad (53)$$

證明. 對式 (51) 取 gradient 並令其為零：

$$Q(\mathbf{x} - \mathbf{z}) + A'W(A\mathbf{x} - \mathbf{b}) = 0.$$

整理得  $(Q + A'WA)\mathbf{x} = Q\mathbf{z} + A'W\mathbf{b}$ ，等價於式 (53)。  $Q$  正定使  $Q + A'WA$  正定，因此解唯一。  $\square$

若 benchmark 被視為無誤差硬約束，可解

$$\min_{\mathbf{x}} (\mathbf{x} - \mathbf{z})'Q(\mathbf{x} - \mathbf{z}) \quad \text{s.t.} \quad A\mathbf{x} = \mathbf{b}, \quad (54)$$

其 KKT system 為

$$\begin{bmatrix} Q & A' \\ A & 0 \end{bmatrix} \begin{bmatrix} \boldsymbol{\delta} \\ \boldsymbol{\lambda} \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{b} - A\mathbf{z} \end{bmatrix}, \quad \hat{\mathbf{x}} = \mathbf{z} + \boldsymbol{\delta}. \quad (55)$$

Soft mode 更適合 GT benchmark 本身也有 sampling variation 的情況；exact mode 可作 sensitivity analysis。若 nonnegative projection 被啟用，投影後聚合等式可能略受影響，故程式會報告 projection 是否發生。

## 8 可靠度指標與預先鎖定的 decision tree

### 8.1 Detection、level 與 innovation

RACER-GT 不以一個單一相關係數概括資料品質。Detection reliability 包括 zero/nonzero agreement、positive-day Jaccard 與 Fleiss'  $\kappa$  [15]；當所有觀察都屬同一類別時， $\kappa$  不可識別，此規則標記為 not applicable，而非錯誤判 FAIL。Level reliability



包括 Pearson、Spearman、MAE/100、G 與  $\Phi$ ；innovation reliability 則對  $\Delta \log(1 + Y)$  計算 correlation、sign / peak overlap 與 G-study。

Exact-cell agreement 必須與 zero share 一起解讀。兩條低量序列若多數日都為零，可能得到很高 exact agreement，卻沒有足夠正值資訊；因此 decision tree 另設 maximum zero share，並檢查 positive Jaccard。

## 8.2 Acceptance rules

一個正式 batch 的 PASS 至少需滿足以下預先指定規則：

1. query、historical endpoints、chunks 與 protocol hash 完整一致；
2. 每個 complete pull 的 overlap graph 可識別且連通；
3. unique pulls 與 spectral effective pulls 達到門檻；
4. zero share 未超過門檻；
5. level 與 innovation G 達到門檻；
6. near-duplicate component 不支配全批資料；
7. 隨 pulls 增加的 consensus convergence MAE/100 低於門檻；
8. 若使用 benchmark，standardized benchmark RMSE 低於門檻。

若任一 mandatory rule 明確失敗，狀態為 FAIL；若沒有失敗但有不可判定 mandatory rule，狀態為 REVIEW；全部通過才是 PASS。PASS 的意義是「允許依鎖定 protocol 建構此相對指標」，不是 construct validity、外部效度或因果識別的證明。

關鍵詞／Topic 的 construct validity 必須另行檢查：語意與語言版本、可能的非財金用途、歷史首次合理出現時間、主要 peaks 的事件對應、搜尋量是否足夠，以及不同替代 terms 的結果是否一致。測量可靠而構念錯誤的指標仍然沒有研究效度 [19]。

## 9 下游財金模型的 measurement-error correction

### 9.1 Attenuation bias

令真正的注意力訊號  $X_t$  進入財金模型

$$Y_{t+h} = \alpha + \beta X_t + \gamma' C_t + \varepsilon_{t+h}, \quad (56)$$

但研究者觀察

$$W_t = X_t + u_t, \quad \mathbb{E}(u_t \mid X_t, \mathbf{C}_t, \varepsilon_{t+h}) = 0. \quad (57)$$

在無 controls 的 classical homoskedastic case , naive OLS 滿足

$$\text{plim } \hat{\beta}_{\text{naive}} = \beta \frac{\sigma_X^2}{\sigma_X^2 + \sigma_u^2}, \quad (58)$$

故係數向零衰減。

令  $M_C = I - C(C'C)^{-1}C'$  為 controls residual-maker 。若 measurement-error covariance  $\Omega_u$  已知，則

$$\mathbb{E}(W'M_C W) = X'M_C X + \text{tr}(M_C \Omega_u). \quad (59)$$

因此 moment-corrected estimator 為

$$\hat{\beta}_{RC} = \frac{W'M_C Y}{W'M_C W - \text{tr}(M_C \hat{\Omega}_u)}. \quad (60)$$

RACER-GT 使用每日 consensus standard error 的平方形成 diagonal  $\hat{\Omega}_u$ ，並以 Newey–West long-run variance [24] 對 scalar moment 提供 HAC standard error。若修正後分母非正，套件拒絕估計，因為在該假設下 latent predictor variation 不足以識別  $\beta$ 。

## 9.2 SIMEX

當誤差標準差可估計但解析修正不穩定時，SIMEX [8, 28, 4] 對  $\lambda \geq 0$  人工加入

$$W_t^{(b,\lambda)} = W_t + \sqrt{\lambda} \hat{\sigma}_{u,t} \xi_t^{(b)}, \quad \xi_t^{(b)} \sim N(0, 1), \quad (61)$$

估計  $\hat{\beta}(\lambda)$  後，以二次曲線外推至  $\lambda = -1$ ，模擬移除 measurement error。SIMEX 對 extrapolation form 敏感，因此應與式 (60)、sample-specific pull regressions 與 full-pipeline bootstrap 並列報告，而非只選擇較顯著者。

## 10 完整演算法

---

### Algorithm 1 RACER-GT 長期日頻指標建構

---

Require: Locked query  $Q$  ; balanced retrieval design ; fixed chunks ; raw responses ; optional lower-frequency benchmark

Ensure: Final daily index 、 measurement uncertainty 、 audit trail 、 acceptance decision

- 1: Canonicalize protocol ; 計算 hash ; 產生 collection schedule 與 chunk manifest
- 2: 蒐集並保存所有 raw responses ; 記錄 day 、 stream 、 replicate 、 time 、 order 、 network events 與 hashes
- 3: Audit historical endpoints 、 query parameters 、 chunk boundaries 、 partial observations 與 missing chunks
- 4: for each complete pull  $i$  do
- 5:   由 usable overlaps 計算 robust log-ratio edges
- 6:   建立 overlap graph ; 若不連通依 protocol FAIL / REVIEW
- 7:   解 graph WLS 取得 chunk log scales 與 covariance
- 8:   校準所有 chunks ; 以 inverse-variance / Huber / median 聚合同日值
- 9:   依固定 baseline 將 pull index 平均設為 100
- 10: end for
- 11: 依預先指定 design-cell weights 計算  $\hat{\theta}_t^\pi$  作為 design-based reference
- 12: 保留 exact duplicate audit ; 建立 analytic unique-vector set
- 13: 由共同中位數與 pull bias 形成 residuals ; 建立 near-duplicate graph
- 14: 對 level 、 detection 、 innovation 執行 crossed-facet G-study 與 D-study
- 15: 估計 residual covariance  $\hat{\Sigma}$  ; 解受限或無限制 GLS latent consensus
- 16: 計算 conditional standard errors 、 spectral/Kish effective counts 與 convergence path
- 17: if lower-frequency benchmark available then
- 18:   解 soft / exact temporal benchmarking problem
- 19: end if
- 20: 執行 locked decision tree ; 輸出 PASS / REVIEW / FAIL
- 21: 將 final index 與 uncertainty 輸入下游 EIV correction / SIMEX

---

## 11 Python 套件實作

### 11.1 設計原則

RACER-GT 1.0.0 採 ingestion-first architecture : 統計套件不內建未經官方保證的網站 scraping 。網站端點、rate limits、認證與服務條款可能變動，將 retrieval client 與估計器解耦，可使研究者在官方 API、手動 CSV export 或機構核准的 collector 間替換，而不改變統計 protocol 。Collector 只需輸出固定 long-format schema 。

核心模組如表 5 。

表 5: RACER-GT 1.0.0 模組

| 模組             | 功能                                                                                                                                                       |
|----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| config.py      | Pydantic protocol schema、欄位驗證、canonical serialization 與 SHA-256 hash。                                                                                    |
| design.py      | 固定 overlap windows、balanced stream/time/chunk order 與 protocol bundle。                                                                                   |
| audit.py       | Historical-window drift、query drift、partial data、missing chunks 與 metadata ambiguity。                                                                    |
| overlap.py     | Huber edge estimator、graph connectivity、WLS scale solution、condition diagnostics 與 calibrated pull aggregation。                                          |
| duplicates.py  | Exact vector hashes、value-anchored pair metrics、residual near-duplicate graph、components/cliques/articulation diagnostics。                               |
| gstudy.py      | Balanced $T \times D \times S$ ANOVA、variance components、 $G/\Phi$ 、D-study 與 moving-block bootstrap。                                                    |
| consensus.py   | Design-cell weighted reference、exact-collapse map、baseline rescale、Ledoit–Wolf covariance、GLS / constrained weights、effective pull counts 與 uncertainty。 |
| benchmark.py   | Sparse aggregation matrix、soft quadratic benchmark 與 exact KKT benchmark。                                                                                |
| reliability.py | Pairwise level/innovation metrics、Fleiss kappa、day/stream dependence 與 sequential convergence。                                                           |
| decision.py    | 可稽核的 PASS/REVIEW/FAIL decision tree。                                                                                                                     |
| eiv.py         | Reliability-corrected OLS、HAC inference 與 quadratic SIMEX。                                                                                               |
| simulation.py  | 含 latent dynamics、day/stream effects、correlated retrieval noise、chunk normalization、rounding 與 exact duplicates 的 DGP。                                   |
| validation.py  | Single pull、mean、median 與 RACER-GT 的 Monte Carlo 比較。                                                                                                     |
| pipeline.py    | End-to-end orchestrator 與完整輸出保存。                                                                                                                         |
| cli.py         | design、audit、run、simulate、export-stata。                                                                                                                  |

## 11.2 最小使用範例

```
import pandas as pd
from racergt import RacerGTConfig, RacerGTPipeline

config = RacerGTConfig.load_yaml("protocol.lock.yaml")
raw = pd.read_csv("raw_chunks.csv")
benchmark = pd.read_csv("benchmark.csv")

result = RacerGTPipeline(config).fit(raw, benchmark=benchmark)
result.save("results")

print(result.decision.status)
design_reference = result.design_consensus.consensus
final_gt = result.final_series
```

CLI :

```
racergt design examples/config_example.yaml --out protocol_bundle \
  --anchor-date 2026-08-01
racergt audit protocol_bundle/protocol.lock.yaml raw_chunks.csv
racergt run protocol_bundle/protocol.lock.yaml raw_chunks.csv \
  --benchmark benchmark.csv --out results
```

每一次 run 產生 design-weighted reference、final latent series、calibration scales、edge residuals、duplicate groups/components、pull covariance、weights、G-study tables、reliability/convergence、benchmark fit、decision tree 與 diagnostic report。所有中間結果可供 replication，而不是只輸出一條無法稽核的平滑序列。

## 12 Monte Carlo 驗證

### 12.1 資料生成過程

本文隨套件提供可重現 simulation。基礎 latent intensity 為

$$L_t = 30 + 0.004t + 2.5 \sin(2\pi t/7) + 4 \sin(2\pi t/365.25) \\ + u_t + \sum_{q=1}^6 \text{Spike}_{qt}, \quad (62)$$

其中  $u_t = 0.92u_{t-1} + \eta_t$ 、 $\eta_t \sim N(0, 1.8^2)$ ，並加入六個非對稱衰減事件尖峰。真實 index 依研究期平均設為 100。

對 collection day  $d$  與 stream  $s$ ，pull-level log error 為

$$\zeta_{it} = a_d + b_s + 0.5g_{dt} + 0.5h_{it}, \quad (63)$$

其中  $a_d \sim N(0, 0.025^2)$ 、 $b_s \sim N(0, 0.020^2)$ ， $g_{dt}$  與  $h_{it}$  分別是具有持續性的 shared-day 與 idiosyncratic AR noise。每個 chunk 再加入  $N(0, 0.03^2)$  multiplicative noise，並依 chunk maximum 正規化為 0–100 後四捨五入。10% 的 nominal pulls 複製完整 latent realization 與 raw chunks，以模擬 exact cache/version duplicates。週、月 benchmark 由真實 index 的 period average 加入已知噪音產生。

Monte Carlo 使用 2024 年 366 個日資料、三個 collection days (0、1、7)、三 streams、120-day chunks、30-day steps，共 20 次 replications，seeds 1200–1219。這是程式驗證 DGP，不是對 Google proprietary mechanism 的宣稱。

## 12.2 比較設計：資訊集必須對齊

`PipelineResult.final_series` 在 benchmark 可用時回傳 benchmark 後的序列。若以該序列與「未接受 benchmark 的跨 pull 基準」相比，比較的就不是四個估計量，而是三個估計量與一個估計量加上一組額外的低頻資訊——尤其在模擬中，benchmark 由 latent truth 的期間平均加白噪音生成，資訊量極高。

因此每個估計量都在兩個資訊集下各評估一次：僅使用校準後的 complete pulls，以及套用完全相同的週頻與月頻 benchmark。single pull 一列報告的是所有 pull 各自表現的平均，而非固定取某一個 pull，因為後者代表「恰好取到那一個 pull」而非「只下載一次的期望表現」。

## 12.3 結果

表 6: 20 次受控 Monte Carlo 結果 (seeds 1200–1219)。MCSE 為平均 RMSE 的 Monte Carlo 標準誤。

| Estimator         | Benchmark | RMSE   | MCSE   | MAE    | Bias    | Corr.  | Innov. corr. |
|-------------------|-----------|--------|--------|--------|---------|--------|--------------|
| Single pull       | 無         | 7.3519 | 0.0573 | 5.6770 | −0.0000 | 0.9688 | 0.8878       |
| Cross-pull median | 無         | 4.1710 | 0.0819 | 3.1973 | −0.1464 | 0.9898 | 0.9556       |
| Simple mean       | 無         | 3.7253 | 0.0877 | 2.8660 | −0.0000 | 0.9919 | 0.9747       |
| RACER-GT          | 無         | 3.7421 | 0.0894 | 2.8723 | +0.0000 | 0.9918 | 0.9743       |
| Single pull       | 有         | 6.9881 | 0.0491 | 5.3877 | −0.0041 | 0.9717 | 0.8882       |
| Cross-pull median | 有         | 3.9584 | 0.0695 | 3.0283 | −0.1311 | 0.9908 | 0.9558       |
| Simple mean       | 有         | 3.5058 | 0.0754 | 2.6889 | −0.0041 | 0.9928 | 0.9748       |
| RACER-GT          | 有         | 3.5226 | 0.0770 | 2.6959 | −0.0041 | 0.9927 | 0.9745       |

表 7: 配對比較。差值為估計量 B 減估計量 A 的 RMSE，正值表示 A 較優； $n = 20$  配對。

| 估計量 A               | 估計量 B               | 差值      | $t$   | $p$                   | A 勝場  |
|---------------------|---------------------|---------|-------|-----------------------|-------|
| RACER-GT            | Single pull         | +3.6098 | 48.31 | $2.4 \times 10^{-21}$ | 20/20 |
| RACER-GT            | Cross-pull median   | +0.4289 | 14.86 | $6.5 \times 10^{-12}$ | 20/20 |
| RACER-GT            | Simple mean         | −0.0167 | −1.49 | 0.152                 | 7/20  |
| RACER-GT (有 bm.)    | Simple mean (有 bm.) | −0.0168 | −1.65 | 0.116                 | 7/20  |
| RACER-GT (有 bm.)    | RACER-GT (無 bm.)    | +0.2194 | 15.49 | $3.1 \times 10^{-12}$ | 20/20 |
| Simple mean (有 bm.) | Simple mean (無 bm.) | +0.2195 | 15.45 | $3.3 \times 10^{-12}$ | 20/20 |

由表 6 and 7 可得三項結論，其中兩項支持本框架，一項不支持。

第一，跨 pull 聚合的價值大且穩健。在同一資訊集下，RACER-GT 相對單一 pull 的 RMSE 降低

$$1 - \frac{3.7421}{7.3519} = 49.1\%, \quad (64)$$

20 次重複全部改善（配對  $t = 48.3$ ）。相對 cross-pull median 亦降低 10.3%，同樣 20 次全勝。這回答了本文的核心動機問題：只下載一次確實不夠。

第二，共變異數調整加權相對簡單平均，在本 DGP 下沒有可偵測的優勢。兩者相差 −0.0167 ( $p = 0.152$ ，20 次中 RACER-GT 僅勝 7 次)，加入 benchmark 後結論不變 (−0.0168， $p = 0.116$ )。本文不宣稱 GLS 權重在此情境下較優。

第三，temporal benchmarking 有獨立且顯著的貢獻。在估計量固定時，加入週／月頻 benchmark 使 RMSE 降低約 0.22 ( $p \approx 3 \times 10^{-12}$ ，20 次全勝)，且對 RACER-GT 與 simple mean 的效果幾乎相同 (0.2194 對 0.2195)。頻率一致化的收益來自 benchmark 本身，而非它與哪一個日頻估計量搭配。

說明 12.1 (一個可檢驗的預測). 第二點是負面結果。它最自然的解釋是本模擬的跨 pull 依賴結構過於同質：所有 pull 以固定權重 0.5 共享同一 collection-day 噪音，因此殘差

共變異數矩陣近乎等相關，而等相關矩陣的最小變異權重本來就是等權，GLS 沒有可利用的結構，只能在估計噪音上吃虧。

若此解釋成立，則當依賴強度在 *pulls* 之間不同時——例如部分 *pull* 來自同一 *cache* 而其餘不是——GLS 應當勝出。這是一個可檢驗的預測，節 12.4 直接檢驗它。

## 12.4 依賴異質性的直接檢驗

`examples/run_dependence_experiment.py` 讓一部分 *pull* 額外共享一條 *cache* 噪音。成員身分跨越 *collection day* 與 *stream*，因此該依賴無法被設計因子吸收，只能由殘差共變異數發現——這正是 GLS 權重存在的理由。`cache_cluster_fraction` 為零時的資料與表 6 使用的完全相同（逐位元一致），因此兩節的數字可直接比較。

表 8: 依賴異質性四情境，各 20 次重複。優勢欄為 simple mean 減 GLS 的 RMSE，正值表示 GLS 較優。

| 情境           | GLS    | Simple mean | Median | 優勢      | MCSE   | <i>p</i> | GLS 勝場 |
|--------------|--------|-------------|--------|---------|--------|----------|--------|
| 同質（基準）       | 3.7421 | 3.7253      | 4.1710 | -0.0167 | 0.0112 | 0.152    | 7/20   |
| 1/3 pulls，中度 | 3.7658 | 3.6801      | 4.1133 | -0.0857 | 0.0155 | < 0.0001 | 2/20   |
| 1/3 pulls，強  | 4.1684 | 4.1980      | 4.6486 | +0.0296 | 0.0439 | 0.508    | 10/20  |
| 1/2 pulls，強  | 5.1633 | 4.8802      | 5.5593 | -0.2831 | 0.0591 | 0.0001   | 2/20   |

**預測不成立。**GLS 在四個情境中沒有任何一個顯著勝出：最接近的一個（1/3 pulls、強依賴）優勢為 +0.0296 但  $p = 0.51$ 、勝場恰為 10/20，等同平手；另外兩個情境 GLS 顯著較差。異質性增加並未使排序反轉。

兩項診斷排除了對此結果的兩種誤讀。

**第一，約束不是原因。**在 1/3 pulls、強依賴情境下解除約束後（10 次重複）：受限預設解、解除上限解與完全無約束解的平均 RMSE 都是 4.1752，三者逐位相同，因為無約束解本來就落在可行域內；改用 *empirical covariance* 為 4.1785，*diagonal* 為 4.2345，同期 *simple mean* 為 4.2415。理論上為 BLUE 的無約束 GLS 同樣沒有勝出。

**第二，機制運作正確。**每個 *pull* 的平均殘差相關與其獲得的 GLS 權重之相關係數為 -0.562（10 次重複全部為負）。GLS 確實找到了共享依賴的 *pulls* 並降低其權重，方向完全正確。表 8 的 *weight dispersion* 亦隨異質性單調上升（0.0220 → 0.0409），*spectral effective pull* 數則單調下降（4.93 → 2.95），兩者都正確反映了依賴的增加。

剩下的解釋是估計誤差： $\Sigma$  必須由 9 個 *pull* 與 366 個歷史日估計，其誤差對權重造成的擾動，大於利用真實依賴結構所能換得的效率增益。這與投資組合文獻長期以來的發現一致——樣本共變異數下的 *minimum-variance* 組合在小樣本時並不優於等權，Ledoit–Wolf shrinkage [22] 正是為緩解此問題而提出，本實作已預設採用而結論未變。



**說明 12.2** (這個負面結果改變什麼、不改變什麼). 不改變的是理論： $\Sigma$  已知時 *GLS* 仍是最小變異線性無偏估計量（命題 7.1），該推導不依賴任何模擬。改變的是實務建議：在本文建議的設計規模下（21–42 *pulls*、單一年度），不應期待共變異數調整帶來可偵測的點估計改善，*simple mean* 是同樣合理的主結果選擇。

也不改變的是共變異數調整的診斷價值。上述 *spectral effective pull* 數由 4.93 降至 2.95，正確地告訴研究者「這 9 個 *pull* 現在只值約 3 個」——*simple mean* 無法提供這個判斷，也無法提供 *near-duplicate* 依賴結構、每日條件標準誤，以及可傳遞至下游 *EIV* 修正的測量不確定性。*RMSE* 無法回答「這批資料是否可用」，而那正是本框架的主要目的。

**說明 12.3** (偏誤欄的解讀). *Single pull* 與 *simple mean* 的 *mean bias* 是  $10^{-15}$  量級，這是恆等式而非估計性質：每個 *complete pull* 都被正規化為基準期平均 100，而真值亦以同一基準期平均 100 定義，故其平均必然無偏。*RACER-GT* 的偏誤同樣落在機器精度內 ( $+3.2 \times 10^{-17}$ )。*Cross-pull median* 的  $-0.1464$  則是真實的：逐日中位數在右偏分布下系統性低於平均數，而本 *DGP* 含六個事件尖峰。




圖 2: 各估計量在兩個資訊集下的平均 RMSE，誤差棒為 Monte Carlo 標準誤。同一估計量兩根柱體的差距即 *temporal benchmarking* 的貢獻。




圖 3: Level correlation、innovation correlation 與 top-5% peak recall。三項指標上 RACER-GT 與 simple mean 實質相同，與表 7 的檢定結果一致。

這些模擬只驗證程式在一組已知 DGP 下的行為。節 12.4 已就 shared dependence 這一個維度做了 factorial 檢驗，其餘維度尚未涵蓋：正式論文應針對實際關鍵字的 zero share、波動性與 sample size 重新設計，至少改變 sampling noise、rounding/censoring、graph sparsity、structural breaks、benchmark noise、exact-duplicate fraction 與 covariance misspecification。

## 13 建議的正式實驗規格

若研究目標是 2010–2026 年單一主題的日頻 GT 指標，建議的 confirmatory protocol 如表 9。表中門檻是合理起點，不是跨研究普遍常數；應在不查看財金 outcome 的 pilot simulation 中校準，再鎖定。

表 9: 建議的正式 RACER-GT protocol

| 項目                | 建議設定與理由                                                       |
|-------------------|---------------------------------------------------------------|
| Historical window | 固定 2010-01-01 至明確 month-end；Day 0–30 不可使用 expanding end date。 |
| Daily chunks      | 先以約 180 日 window、15–30 日 step 建立密集 overlap；實際回傳頻率需程式驗證。       |
| Collection days   | 0、1、2、7、14、21、30，以同時觀察短期 cache/版本相似與較長期穩定度。                   |
| Streams           | 至少三個固定 composite environments；平衡 stream order 與 time slot。    |

| 項目                  | 建議設定與理由                                                                                                          |
|---------------------|------------------------------------------------------------------------------------------------------------------|
| Replicates          | 最佳為每個 day $\times$ stream 兩次，產生 42 pulls；若資源限制為 21 pulls，明確承認 pure error 不可分離。                                   |
| Raw archive         | 保存 response、numeric vectors、retrieval timestamp、query metadata、protocol hash、network events 與 client version。    |
| Overlap calibration | Huber edges + global graph WLS；圖不連通原則上 FAIL，不以人工比例硬接。                                                            |
| Duplicates          | Exact vectors 只在 analytic covariance 中 collapse；audit set 永久保留。Near duplicates 不刪除。                              |
| G-study             | 分別估 level、detection、innovation；以 28-day moving-block bootstrap 估 interval。                                       |
| Consensus           | Ledoit–Wolf covariance；非負 weights；weight cap 0.5 作預設，另報 unrestricted sensitivity。                                |
| Frequency benchmark | 以多次擷取後的 weekly/monthly consensus 及其 SE 進行 soft benchmark；exact mode 作 robustness。                                |
| Stop rule           | Unique count、spectral effective count、 $G/\Phi$ 、convergence 與 component concentration 共同決定，不以 nominal 21 為充分條件。 |
| Downstream model    | 主結果使用 final consensus；另以 sample-specific pulls、RC-OLS、SIMEX 與 full-pipeline bootstrap 檢查。                        |

## 14 限制、敏感度分析與可延伸方向

### 14.1 無法由統計設計消除的限制

第一，若 Google 對所有 pulls 施加相同且隨時間變動的系統性演算法偏誤，重複量測無法僅靠平均或 GLS 識別；這是 common-mode bias。可利用 API overlap period、外部搜尋資料、新聞／交易事件與不同 query formulations 進行 external validation，但仍不是絕對真值。

第二，零值可能混合真實零搜尋、privacy threshold、sampling 與 rounding。RACER-GT 1.0.0 將零值保留並分離 detection reliability，但尚未內建 interval-censored latent count likelihood。對高 zero-share term，降為週頻、改用較廣 Topic 或 anchor-bank calibration，通常比強制製造日頻值更合理。

第三，G-theory 的 balanced method-of-moments 易於解釋，卻在 unbalanced missingness、負 variance components 或非 Gaussian binary detection 下不如 generalized linear mixed models。正式論文可將本實作作 preregistered primary estimator，再以 REML / Bayesian hierarchical model 作 robustness。

第四，benchmark 後的 1.0.0 信賴區間主要保留 cross-pull measurement uncertainty，尚未完整傳播 benchmark noise、scale calibration uncertainty 與 tuning-parameter uncertainty。最嚴謹方式是 nested moving-block bootstrap：每次重抽 historical blocks、重新估 edges、scales、duplicates、covariance、weights 與 benchmark，最後再重估財金模型。

第五，取得端的 rate limit 是一個實質約束，且它會反噬設計本身。本文第 12 節建議的 protocol (2010 年起、180 日 window、15–30 日 step、21–42 pulls) 隱含的請求量並不小：以 15 日 step 計，單一 pull 需 393 個 chunks，而每個 chunk 需要兩次請求 (explore 取 token、widgetdata 取數值)，故一個 pull 即為 786 次請求，21 pulls 為 16,506 次、42 pulls 為 33,012 次。在 20 秒的保守請求間隔下，這分別是約 92 與 183 小時的連續取得時間；即使是單一 pull 也需約 4.4 小時。

而 Google Trends 對此有嚴格限流。作者在一次測試中，explore 端點回傳 200，但第二次 widgetdata 請求即回傳 HTTP 429，等待 30 秒後重試仍為 429。單一觀察不足以量化 Google 的限流政策——它可能隨 IP、時段、帳號狀態與請求模式而異——但已足以說明取得可行性不是可以略過的工程細節。

限流亦不限於程式化存取。同一時段以一般瀏覽器（已登入、人工導航）開啟 Trends 網頁時，網頁自身前端發出的 widgetdata 請求同樣回傳 429，而頁面圖表卻正常顯示——顯示的是快取內容。這對研究者有直接的操作意涵：Trends 前端會以快取遮蔽失敗的請求，使用者無法從畫面判斷所見數列是否為本次取得的結果。任何以手動匯出為取得途徑的協定，都必須獨立記錄 response 狀態與 raw\_response\_hash，而不能以「圖表有顯示」作為取得成功的判準；adapter contract 要求保存原始 response 的理由於此更為明確。

真正的問題不在等待時間，而在第 4 節對 collection\_day 的定義：它是「一次完整歷史重建」所對應的序數層級，而 G-theory 的  $D$  facet 與式 (30) 的  $\sigma_{TD}^2$  都建立在這個層級上。若一次完整重建需時 4.4 小時且會被限流反覆中斷，該 pull 究竟屬於哪一個 collection day 便不再明確；跨越午夜的 pull 更會同時觸及 Djorno et al. (2026) 所述的 cache 重置邊界 (remark 3.1)，使得同一個 pull 內部的 chunks 來自兩個不同的抽樣批次。這不是量測誤差，而是 facet 定義的失效。

本文因此建議：正式研究應先以 `examples/collect_google_trends.py --preview` 估算請求預算，再據以決定 `historical window` 與 `step`，使單一 `pull` 的取得時間短於 `cache` 週期。以單一年度、180 日 `window`、30 日 `step` 計，一個 `pull` 僅需 8 個 `chunks`、16 次請求，可在數分鐘內完成——這才是使 `collection day` 保持為良定義 `facet` 的設計。以 16.6 年的窗長搭配 15 日 `step`，在目前的限流下並不可行，本文先前未指出這一點。

第六，受限 `GLS weights` 的穩定性優於 `unrestricted inverse covariance`，但其最佳性取決於預先指定 `constraint set`。應報告 `diagonal covariance`、`empirical covariance`、`Ledoit-Wolf`、`unrestricted GLS`、`equal weights` 與 `median` 的 `sensitivity table`。

第七，真實資料的驗證目前只覆蓋校準階段。節 4.6 使用的是單一 `pull`，因此第二階段以後的每一個機制——共識加權、`duplicate` 診斷、`G-theory` 變異成分、可靠度指標、`benchmark`——在真實 `Google Trends` 資料上全部未經檢驗，其證據仍完全來自模擬。而表 4 已顯示模擬器在校準階段高估了 `chunk` 噪音約 4.5 倍，這使得「模擬器在其他階段的參數是否同樣失真」成為一個開放且重要的問題：若跨 `pull` 的 `retrieval noise`、`day effect` 或 `stream effect` 也被高估，則節 12 的相對表現數字同樣需要重新檢視。本文不宜稱模擬證據可外推至真實資料的跨 `pull` 行為。要填補這個缺口，需要跨蒐集日、跨環境的重複收集；表 9 的規格下，3 個 `stream` × 7 個蒐集日 = 21 個 `pull`、168 次下載，是一個月日曆時間可完成的設計。

## 14.2 必要的穩健性檢驗

1. 不同 `chunk lengths`、`steps`、`positive thresholds` 與 `reference strategies`；
2. `Huber`、`median` 與 `inverse-variance within-pull aggregation`；
3. `Exact duplicate collapse` 與 `multiplicity-weighted sensitivity`；
4. `Raw-rule`、`residual-rule thresholds` 與 `complete-linkage` / `maximal-clique diagnostics`；
5. `G-study negative-component truncation versus REML`；
6. `Consensus covariance estimators` 與 `weight caps`；
7. `Soft versus exact benchmark`，不同 `fidelity/smoothness weights`；
8. 最新 `vintage` 與多個 `historical vintages`；
9. `Topic versus search term`、語言變體與非投資搜尋意圖排除；
10. 財金模型中的 `lag structure`、`UTC` / 市場時區、週末聚合與 `publication delay`。

### 14.3 與既有方法的關係

RACER-GT 並非取代既有研究，而是把其可互補部分放入同一個測量框架。就實證比較而言，本文只直接比較了逐段 stitching（節 4.5），結果是機制成立但精度差異不顯著；West（2020）的 anchor bank 需要多組 query 才能運作，Djorno et al.（2026）的 preprocessing 以下游預測準確度為評估標準，兩者都無法在本文的單一 series、以 latent truth 為基準的模擬下直接比較。因此本文不宜稱相對這些方法具有精度優勢；已建立的是相對「只下載一次」的大幅改善，以及一組其他方法未提供的診斷輸出。

Eichenauer et al.（2022）提供 repeated draws 與 frequency consistency 的核心洞見；Bleher and Dimpfl（2022）說明高頻長期 knitting；West（2020）以 anchor bank 處理跨 query common scale 與 rounding；Cebrián and Domenech（2024）指出 repeated pulls 的誤差與熱門程度密切相關；Medeiros and Pires（2021）提醒單一 GT realization 可使 forecasting conclusion 偶然改變。RACER-GT 的新增層次在於：將 retrieval 本身明確設計為交叉測量實驗，以 graph GLS 解 within-pull scale，以 G-theory 決定蒐集資源，以 residual covariance 對相依 pulls 降權，再把 measurement uncertainty 傳至下游財金估計。

## 15 結論

長期日頻 GT 的核心問題不是「下載幾次才算獨立」，而是如何在無法觀察 proprietary sample assignment 的條件下，定義可識別 estimand、控制 retrieval design、估計分段尺度、分解誤差來源、處理相依量測，並將不確定性保留到財金模型。RACER-GT 的基本立場是：

不以 IP 取代獨立性證明；不以多數決刪除不一致 pulls；不以單一相關係數代表可靠度；不把通過資料品質決策誤稱為 construct validity；也不在下游模型中假裝建構後的 GT 沒有測量誤差。

在明列假設下，全域 overlap-graph WLS 可識別相對 chunk scales；G-theory 可量化 collection day、stream 與其交互作用；GLS 可依 residual covariance 將高度相依 pulls 自動降權；temporal benchmarking 可使日頻形狀與較低頻率尺度相容；EIV correction 則能處理 GT 作為解釋變數時的 attenuation。

受控模擬給出的是混合結果：在本文 DGP 中，跨 pull 聚合（相對單一 pull 降低 49.1%）與 temporal benchmarking（另降低約 0.22）都有大且穩健的貢獻，而共變異數調整加權相對簡單平均則沒有可偵測的優勢。本文選擇完整報告這個負面結果，而不是只呈現有利的比較——這正是全文立場的具體實踐：研究價值不在於某一個較小的誤差數字，而在於一套可以預先註冊、稽核、重現、否決自身資料，並誠實傳遞不確定性

(包含對自己不利的證據) 的測量制度。一個只會產出好看數字的測量流程，無法告訴研究者何時不該相信它。

## A Decision tree 的預設欄位

| Rule                         | 1.0.0 example | 解釋                                   |
|------------------------------|---------------|--------------------------------------|
| Minimum unique pulls         | 12            | Exact-collapse 後的不同 numeric vectors。 |
| Spectral effective pulls     | 4             | 相依性調整的資訊濃度下限。                        |
| Maximum zero share           | 0.80          | 避免資料由 threshold zeros 支配。            |
| Minimum level $G$            | 0.80          | Historical-date level ranking 的重現性。  |
| Minimum innovation $G$       | 0.70          | $\Delta \log(1 + Y)$ 的重現性。           |
| Detection $\kappa$           | 0.60          | 只有 zero/nonzero 類別有變異時適用。            |
| Maximum component share      | 0.50          | 避免單一 dependence component 支配。        |
| Final convergence MAE/100    | 0.02          | 最後新增 pull 對 consensus 的邊際改變。         |
| Benchmark standard-ized RMSE | 研究前校準         | 取決於 benchmark SE 與 soft constraints。 |

這些值是 protocol choices，不是由統計定理產生的 universal constants。正式研究需以 pilot DGP、construct importance 與可接受 decision risk 校準。

## B 輸入資料 schema

Raw chunk table 的必要 keys 為

```
series_id, pull_id, chunk_id, historical_date, value,
collection_day, stream_id, replicate_id, window_start, window_end
```

強烈建議另存

```
retrieved_at, keyword, topic_or_term, geo, category,
search_property, language, is_partial, protocol_hash,
```

```
raw_response_hash, client_version, request_order, network_event
```

## C 軟體測試與重現指令

本版本附九組單元／整合測試，涵蓋 design、overlap calibration、duplicates/consensus、G-study、benchmark、EIV 與 full pipeline。重現：

```
python -m pip install -e '[dev]'  
pytest -q  
python examples/run_monte_carlo.py
```

套件亦提供 wheel、source archive、完整 README、資料字典、protocol template、Stata interoperability 與 Monte Carlo raw results。

## 參考文獻

- [1] Ben-Rephael, A., Da, Z., & Israelsen, R. D. (2017). It depends on where you search: Institutional investor attention and underreaction to news. *The Review of Financial Studies*, 30(9), 3009–3047. <https://doi.org/10.1093/rfs/hhx031>
- [2] Bleher, J., & Dimpfl, T. (2022). Knitting multi-annual high-frequency Google Trends to predict inflation and consumption. *Econometrics and Statistics*, 24, 1–26. <https://doi.org/10.1016/j.ecosta.2021.10.006>
- [3] Brennan, R. L. (2001). *Generalizability Theory*. Springer.
- [4] Carroll, R. J., Ruppert, D., Stefanski, L. A., & Crainiceanu, C. M. (2006). *Measurement Error in Nonlinear Models: A Modern Perspective* (2nd ed.). Chapman and Hall/CRC.
- [5] Cebrián, E., & Domenech, J. (2024). Addressing Google Trends inconsistencies. *Technological Forecasting and Social Change*, 202, 123318. <https://doi.org/10.1016/j.techfore.2024.123318>
- [6] Choi, H., & Varian, H. (2012). Predicting the present with Google Trends. *Economic Record*, 88(s1), 2–9. <https://doi.org/10.1111/j.1475-4932.2012.00809.x>



- [7] Chow, G. C., & Lin, A. (1971). Best linear unbiased interpolation, distribution, and extrapolation of time series by related series. *The Review of Economics and Statistics*, 53(4), 372–375. <https://doi.org/10.2307/1928739>
- [8] Cook, J. R., & Stefanski, L. A. (1994). Simulation-extrapolation estimation in parametric measurement error models. *Journal of the American Statistical Association*, 89(428), 1314–1328. <https://doi.org/10.1080/01621459.1994.10476871>
- [9] Cronbach, L. J., Gleser, G. C., Nanda, H., & Rajaratnam, N. (1972). *The Dependability of Behavioral Measurements: Theory of Generalizability for Scores and Profiles*. Wiley.
- [10] Da, Z., Engelberg, J., & Gao, P. (2011). In search of attention. *The Journal of Finance*, 66(5), 1461–1499. <https://doi.org/10.1111/j.1540-6261.2011.01679.x>
- [11] Da, Z., Engelberg, J., & Gao, P. (2015). The sum of all FEARS: Investor sentiment and asset prices. *The Review of Financial Studies*, 28(1), 1–32. <https://doi.org/10.1093/rfs/hhu072>
- [12] Dagum, E. B., & Cholette, P. A. (2006). *Benchmarking, Temporal Distribution, and Reconciliation Methods for Time Series*. Springer.
- [13] Denton, F. T. (1971). Adjustment of monthly or quarterly series to annual totals: An approach based on quadratic minimization. *Journal of the American Statistical Association*, 66(333), 99–102. <https://doi.org/10.1080/01621459.1971.10482227>
- [14] Eichenauer, V. Z., Indergand, R., Martínez, I. Z., & Sax, C. (2022). Obtaining consistent time series from Google Trends. *Economic Inquiry*, 60(2), 694–705. <https://doi.org/10.1111/ecin.13049>
- [15] Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5), 378–382. <https://doi.org/10.1037/h0031619>
- [16] Fuller, W. A. (1987). *Measurement Error Models*. Wiley.
- [17] Google Search Central. (2025, July 24). Introducing the Google Trends API (alpha): A new way to access Trends data. <https://developers.google.com/search/blog/2025/07/trends-api>

- [18] Google Trends Help. (n.d.). FAQ about Google Trends data. <https://support.google.com/trends/answer/4365533>
- [19] Hölzl, J., Keusch, F., & Sajons, C. (2025). The (mis)use of Google Trends data in the social sciences. *Social Science Research*, 126, 103099.
- [20] Huber, P. J. (1964). Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, 35(1), 73–101. <https://doi.org/10.1214/aoms/1177703732>
- [21] Kish, L. (1965). *Survey Sampling*. Wiley.
- [22] Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411. [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4)
- [23] Medeiros, M. C., & Pires, H. F. (2021). The proper use of Google Trends in forecasting models. *arXiv:2104.03065*. <https://doi.org/10.48550/arXiv.2104.03065>
- [24] Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708. <https://doi.org/10.2307/1913610>
- [25] Preis, T., Moat, H. S., & Stanley, H. E. (2013). Quantifying trading behavior in financial markets using Google Trends. *Scientific Reports*, 3, 1684. <https://doi.org/10.1038/srep01684>
- [26] Searle, S. R., Casella, G., & McCulloch, C. E. (1992). *Variance Components*. Wiley.
- [27] Shavelson, R. J., & Webb, N. M. (1991). *Generalizability Theory: A Primer*. Sage.
- [28] Stefanski, L. A., & Cook, J. R. (1995). Simulation-extrapolation: The measurement error jackknife. *Journal of the American Statistical Association*, 90(432), 1247–1256. <https://doi.org/10.1080/01621459.1995.10476629>
- [29] West, R. (2020). Calibration of Google Trends time series. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management* (pp. 2257–2260). <https://doi.org/10.1145/3340531.3412075>