

RACER-GT 使用手冊

安裝、工作流程、資料契約與輸出

Yi-Hao Lai

大葉大學財務金融學系

2026-07-27 • 版本 1.4.0

摘要

本手冊帶研究者從安裝走到一條通過驗收的日頻 Google Trends 指標。內容涵蓋收集器必須滿足的資料契約、四個命令列步驟、Python API、每一個輸出檔案，以及實務上最容易遇到的失效情況。方法與證明請見方法論主文與數學附錄；本文只談如何正確操作軟體。

目錄

1	安裝	3
2	四步驟工作流程	3
2.1	步驟一：鎖定 protocol	3
2.2	步驟二：蒐集與轉換	3
2.3	步驟三：稽核	4
2.4	步驟四：執行	4
2.5	Python API	4
3	資料契約	4
3.1	Raw chunk table	4
3.2	低頻 benchmark table	5
4	輸出	6

5	解讀 decision	6
6	Stata 互通	7
7	研究執行上的必要限制	7

1 安裝

RACER-GT 需要 Python 3.10 以上。

```
# 由 PyPI 安裝
python -m pip install racergt

# 由 release wheel 安裝
python -m pip install racergt-1.0.0-py3-none-any.whl

# 由原始碼安裝（開發用）
python -m pip install -e '[dev]'
pytest -q
```

本套件刻意採 *ingestion-first*：不內含任何 Google Trends 抓取程式。端點、rate limit、認證與服務條款都可能改變，統計方法若綁定非官方 client，就會繼承那份脆弱性。收集器由您選擇；套件只要求它輸出 節 3 的 schema。

2 四步驟工作流程

2.1 步驟一：鎖定 protocol

```
racergt design config.yaml --out protocol_bundle --anchor-date 2026-08-01
```

產出帶 SHA-256 protocol hash 的 `protocol.lock.yaml`、平衡後的 `day × stream × replicate` 計畫 `collection_schedule.csv`、固定查詢視窗 `chunk_windows.csv`，以及稽核 manifest。

說明 2.1 (不要手動編輯 lock 檔). `RacerGTConfig.load_yaml` 會重算 *hash* 並在不符時拋錯。手動改動被鎖定的設定因此會明確失敗，這是刻意的行為。要改設定，請改來源設定檔後重新產生。

2.2 步驟二：蒐集與轉換

依 schedule 執行。每個 response 原封不動保存，再轉為 節 3 的 long format。每個 chunk 都計算原始 response 與數值向量的 hash。若發生網路中斷、登入改變、cookie 清除或 client 更新，請記錄於 metadata；不要自行判定該 pull 無效——那會構成依賴數值的排除。

2.3 步驟三：稽核

```
racergt audit config.yaml raw_chunks.csv --out audit.json
```

稽核在任何估計之前，先比對批次與已鎖定 protocol。失敗時 exit code 為 2。

2.4 步驟四：執行

```
racergt run config.yaml raw_chunks.csv \  
  --benchmark lower_frequency_benchmark.csv \  
  --out results
```

若鎖定的 decision tree 回傳 FAIL，exit code 為 3，可直接用於自動化流程的閘門。

2.5 Python API

```
import pandas as pd  
from racergt import RacerGTConfig, RacerGTPipeline  
  
config = RacerGTConfig.load_yaml("config.yaml")  
raw = pd.read_csv("raw_chunks.csv")  
benchmark = pd.read_csv("lower_frequency_benchmark.csv")  
  
result = RacerGTPipeline(config).fit(raw, benchmark=benchmark)  
result.save("results")  
  
print(result.decision.status)      # PASS / REVIEW / FAIL  
print(result.final_series.head())
```

3 資料契約

3.1 Raw chunk table

每列對應一個 pull_id × chunk_id × historical_date。

表 1: 必要欄位。

欄位	型別	意義
series_id	string	研究指標識別碼
pull_id	string	一次完整歷史重建
chunk_id	string	固定查詢視窗，須存在於 manifest
historical_date	date	GT 觀察日期
value	float	原始 GT 相對搜尋值，通常 0–100
collection_day	integer	蒐集日的設計層級
stream_id	string	固定的複合蒐集環境
replicate_id	string	day × stream 格內的 technical replicate
window_start	date	chunk 起日
window_end	date	chunk 迄日

說明 3.1 (兩個經常被誤解的欄位). collection_day 是蒐集日的序數設計層級 (0、1、2……)，不是 *day offset*，也不是日曆日期。stream_id 代表複合環境——裝置、瀏覽器 *profile*、*cookie*、帳號狀態、網路路徑、*IP*。除非確實執行了 *crossover factorial design*，否則估出的 *stream effect* 不得報告為 *IP effect*。

強烈建議另存：retrieved_at、protocol_hash、keyword、geo、category、search_property、language、is_partial、raw_response_hash、network_event。

3.2 低頻 benchmark table

需要 series_id、period_start、period_end、value；se 為選填，缺省時採 protocol 預設值。

4 輸出

表 2: `result.save()` 產生的檔案。

路徑	內容
<code>RACER_GT_final_series.csv</code>	最終日頻指標、條件式標準誤、95% 區間
<code>complete_calibrated_pulls.csv</code>	全部校準後的 pull
<code>calibration/*_chunk_scales.csv</code>	各 chunk 的全域尺度估計
<code>calibration/*_overlap_edges.csv</code>	穩健 edge 估計與診斷
<code>duplicates/</code>	exact groups、pair metrics、components、殘差
<code>consensus/design_weighted_consensus.csv</code>	設計式參考估計量
<code>consensus/consensus_weights.csv</code>	GLS / 最小變異權重
<code>gstudy/</code>	各轉換的 ANOVA、變異成分、D-study
<code>reliability/</code>	pairwise reliability、收斂路徑、day/stream 相依
<code>decision/acceptance_decision_tree.csv</code>	每條規則的觀察值與門檻
<code>report/RACER_GT_diagnostic_report.md</code>	圖表式診斷報告
<code>summary.json</code>	protocol hash、狀態、主要診斷

說明 4.1 (兩個 consensus 檔案，但只有一條最終數列). `consensus/design_weighted_consensus.csv` 是設計式參考估計量，僅供對照，**不會**進入 `RACER_GT_final_series.csv`。後者在提供 *benchmark* 時來自 *temporal benchmark*，否則來自 *GLS consensus*。兩者若差距很大，是值得追查的警訊，不是程式錯誤。

5 解讀 decision

任一 mandatory 規則失敗即 FAIL；無失敗但有 indeterminate 則 REVIEW；否則 PASS。常見成因與處置：

表 3: 常見結果與對應處置。

現象	解讀與處置
OverlapGraphError	chunk 設計有缺口。加長視窗或縮短 step，使相鄰 chunk 至少共享 min_overlap_days 個可用日。
Spectral 有效 pull 數過低	重複取得高度相依。應增加 collection day 或 stream；增加 technical replicate 無濟於事。
Detection 規則 indeterminate	無零／非零變異， κ 無定義。此情況下規則自動轉為非強制，無需處理。
零值占比過高	該詞彙在日頻下太稀疏。改用週頻，或改查較廣的 Topic 而非 Term。
Innovation G 未達標但 level G 達標	水準可重現、日變動不可重現。不要以差分形式使用該數列。
Benchmark RMSE 過大	日頻 consensus 與低頻數列不一致。請確認兩者使用完全相同的查詢設定。

6 Stata 互通

所有表格皆可輸出為 Stata 118 格式：

```
racergt export-stata results/RACER_GT_final_series.csv final_series.dta
```

可讀格式：CSV、Parquet、XLS/XLSX；可寫格式：CSV、Parquet、XLSX、Stata 118 .dta。

7 研究執行上的必要限制

以下並非風格偏好；違反這些條件會使本框架提供的保證失效。

- 固定 IP 不構成獨立樣本的證據。
- 不得在看過財金結果後調整 reliability 門檻或挑選 pull。
- 若 pilot 監控導致 protocol 或 decision rule 改變，被監控的資料即成為 pilot 資料，正式批次必須重新開始。
- exact duplicates 必須保留於 audit archive。
- PASS 僅代表該批資料通過已鎖定的量測規則，不代表關鍵字具 construct validity，也不允許任何因果宣稱。